
GAMMA: Plataforma de Gobernanza Automatizada de Datos Maestros de Materiales mediante Machine Learning

Alejandra Alvarado, Rudy Osorio, Erick Marroquín



UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de BRIDGE Business School



**GAMMA: Plataforma de Gobernanza Automatizada
de Datos Maestros de Materiales mediante Machine
Learning**

Trabajo de graduación en modalidad de proyecto integrador presentado
por
Alejandra Alvarado, Rudy Osorio, Erick Marroquín
Para optar al grado académico de Master In Business Intelligence and
Analytics

Guatemala, Agosto del 2026

Vo.Bo.:

(f) _____
Ing. Horacio Recinos

Tribunal Examinador:

(f) _____
Ing. Horacio Recinos

(f) _____
Ing. Sergio Molina

Fecha de aprobación: Guatemala, 21 de septiembre 2026.

Este trabajo nace de un problema que el equipo enfrentaba de manera cotidiana en su propio entorno de trabajo: la creación de materiales en SAP consumía tiempo valioso en tareas de verificación que, en principio, podían automatizarse. Lo que comenzó como una limitante operativa se convirtió en la oportunidad de aplicar, sobre un problema real y medible, las herramientas de inteligencia de negocios y ciencia de datos desarrolladas a lo largo de la maestría.

Uno de los retos particulares de este trabajo fue mantener el equilibrio entre la confidencialidad de la información utilizada y el rigor académico exigido. La organización donde se desarrolló e implementó el proyecto autorizó el uso de su información bajo la condición de que no se revelara su identidad; por esa razón, a lo largo de este documento se hace referencia a ella de forma genérica, y se omiten los nombres de las personas involucradas en el proceso operativo.

Otra limitación reconocida es el alcance acotado del proyecto: los resultados presentados corresponden a una única unidad de negocio y a un período de validación específico, por lo que deben interpretarse dentro de ese contexto y no como una generalización automática a otros entornos.

Finalmente, este documento se benefició de que el proyecto no fue un ejercicio teórico, sino una herramienta que estuvo en uso activo por personas reales durante varias semanas. Esa validación con datos de producción y con retroalimentación de los usuarios finales es lo que le da a este trabajo su mayor valor.

Agradecimientos

Al Ing. Horacio Recinos e Ing. Sergio Molina, asesores de este trabajo de graduación, por su acompañamiento y orientación a lo largo de las distintas fases del proyecto.

A los miembros de la terna examinadora, Ing. Horacio Recinos e Ing. Sergio Molina, por el tiempo dedicado a la revisión y evaluación de este trabajo.

Al equipo de gestores de datos maestros y a la jefatura del área donde se desarrolló e implementó el proyecto, por abrir el espacio para validar GAMMA con datos y usuarios reales, y por la retroalimentación brindada durante el período de pruebas.

Prefacio	III
Agradecimientos	IV
Lista de Figuras	VIII
Lista de Cuadros	IX
Resumen	X
1. Introducción	1
2. Objetivos	3
2.1. Objetivo General	3
2.2. Objetivos Específicos	3
3. Justificación	5
4. Marco Teórico	6
4.1. Gobierno de datos maestros	6
4.1.1. Dimensiones de calidad del dato maestro	6
4.1.2. Impacto económico de la mala calidad de datos	7
4.1.3. Estándares para la descripción de datos maestros de materiales	7
4.2. Inteligencia de negocios y medición del desempeño del proceso	7
4.2.1. Modelado dimensional	8
4.2.2. Indicadores clave de desempeño	8
4.2.3. Valoración económica de la información	8
4.3. Metodología para proyectos de analítica	8
4.4. Arquitectura de datos por capas (medallón)	9
4.5. Procesamiento de lenguaje natural para normalización de texto	9
4.5.1. Enfoques basados en reglas y basados en modelos de lenguaje	9
4.5.2. La arquitectura Transformer	9
4.5.3. Modelos de lenguaje aplicados a tareas de preparación de datos	10
4.6. Detección de duplicados y resolución de entidades	10
4.6.1. El problema de la detección de duplicados	10
4.6.2. Similitud por q-gramas y trigramas	10
4.6.3. Umbral de similitud y compromiso entre exhaustividad y precisión	11
4.7. Representación vectorial de texto	11

4.7.1.	TF-IDF	11
4.7.2.	N-gramas de carácter	11
4.8.	Algoritmos de clasificación supervisada evaluados	12
4.8.1.	Regresión logística	12
4.8.2.	Máquinas de vectores de soporte (SVM lineal)	12
4.8.3.	Random Forest	12
4.8.4.	XGBoost	12
4.8.5.	fastText	12
4.8.6.	Transformer (embeddings contextuales)	13
4.9.	Evaluación de clasificadores multiclase	13
4.9.1.	Métricas y esquemas de promediado	13
4.9.2.	Exactitud top-k	13
4.9.3.	Desbalance de clases	13
4.9.4.	Protocolo de validación	14
4.10.	Calibración de probabilidades y predicción selectiva	14
4.10.1.	Calibración de probabilidades	14
4.10.2.	Clasificación con opción de rechazo	14
5.	Antecedentes	15
6.	Alcance	17
7.	Metodología	19
7.1.	Enfoque metodológico	19
7.2.	Materiales	19
7.2.1.	Fuentes de información	19
7.2.2.	Recursos tecnológicos	20
7.3.	Integración de la información	20
7.3.1.	Arquitectura implementada	20
7.3.2.	Proceso de ingesta	20
7.4.	Preparación de los datos	21
7.4.1.	Preprocesamiento de texto	21
7.4.2.	Criterios de construcción del conjunto de modelado	21
7.5.	Métodos analíticos	21
7.5.1.	Normalización de descripciones mediante modelo de lenguaje	21
7.5.2.	Detección de duplicados	22
7.5.3.	Diseño de la evaluación de algoritmos de clasificación	22
7.6.	Arquitectura tecnológica e implementación	23
7.6.1.	Componentes y despliegue	23
7.6.2.	Ciclo de vida de una solicitud	23
7.7.	Instrumentación y medición	24
7.8.	Protocolo de validación en producción	24
8.	Resultados	25
8.1.	Caracterización del maestro de materiales	25
8.2.	Conjunto de modelado resultante	27
8.3.	Desempeño comparado de los algoritmos	27
8.4.	Desempeño del modelo seleccionado	27
8.5.	Exactitud y cobertura según el umbral de confianza	28
8.6.	Resultados de la operación en producción	29

9. Discusión	30
9.1. Sobre la selección del algoritmo	30
9.2. Sobre el efecto del desbalance de clases	30
9.3. Sobre el transformador que no convergió	31
9.4. Sobre la naturaleza de los errores del modelo	31
9.5. Sobre el punto de operación seleccionado	32
9.6. Comparación con los antecedentes	32
9.7. Limitaciones del estudio	32
10. Conclusiones	34
11. Recomendaciones	35
Referencias	36
Bibliografía	37
Anexos	38
A. xxx	38

Lista de Figuras

1.	Cantidad de materiales aportados por cada archivo de exportación del maestro	25
2.	Veinte clases con mayor cantidad de materiales en el maestro	26
3.	Distribución de la longitud, cantidad de tokens y número de separadores de las descripciones del maestro	26
4.	Comparación de métricas entre las configuraciones evaluadas en la primera ronda	28
5.	Matriz de confusión del modelo seleccionado sobre las veinte clases de mayor volumen .	29
6.	Distribución de la confianza del modelo y compromiso entre exactitud y cobertura según el umbral	29

Lista de Cuadros

1.	Distribución de las clases del maestro según su cantidad de materiales	26
2.	Construcción del conjunto de modelado a partir del maestro exportado	27
3.	Resultados de la competencia de algoritmos sobre la partición de prueba de 7,915 materiales y 1,234 clases	27
4.	Confusiones más frecuentes del modelo seleccionado sobre la partición de prueba	28
5.	Exactitud y cobertura del modelo seleccionado según el umbral de confianza aplicado .	28

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Cras vitae eleifend ipsum, ut mattis nunc. Pellentesque ac hendrerit lacus. Cras sollicitudin eget sem nec luctus. Vivamus aliquet lorem id elit venenatis pellentesque. Nam id orci iaculis, rutrum ipsum vel, porttitor magna. Etiam molestie vel elit sed suscipit. Proin dui risus, scelerisque porttitor cursus ac, tempor eget turpis. Aliquam ultricies congue ligula ac ornare. Duis id purus eu ex pharetra feugiat. Vivamus ac orci arcu. Nulla id diam quis erat rhoncus hendrerit. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos himenaeos. Sed vulputate, metus vel efficitur fringilla, orci ex ultricies augue, sit amet rhoncus ex purus ut massa. Nam pharetra ipsum consequat est blandit, sed commodo nunc scelerisque. Maecenas ut suscipit libero. Sed vel euismod tellus.

Proin elit tellus, finibus et metus et, vestibulum ullamcorper est. Nulla viverra nisl id libero sodales, a porttitor est congue. Maecenas semper, felis ut rhoncus cursus, leo magna convallis ligula, at vehicula neque quam at ipsum. Integer commodo mattis eros sit amet tristique. Cras eu maximus arcu. Morbi condimentum dignissim enim non hendrerit. Sed molestie erat sit amet porttitor sagittis. Maecenas porttitor tincidunt erat, ac lacinia lacus sodales faucibus. Integer nec laoreet massa. Proin a arcu lorem. Donec at tincidunt arcu, et sodales neque. Morbi rhoncus, ligula porta lobortis faucibus, magna diam aliquet felis, nec ultrices metus turpis et libero. Integer efficitur erat dolor, quis iaculis metus dignissim eu.

La gestión de datos maestros de materiales es un proceso crítico para cualquier organización que opera sobre SAP, ya que la calidad de este catálogo incide directamente en procesos como la ejecución de órdenes de compra, el cierre de inventarios y la trazabilidad de activos. El presente proyecto se desarrolla sobre el módulo de materiales en SAP de una unidad de negocio del sector energético que opera en varios países de Centroamérica y el Caribe, donde un equipo de gestores de datos maestros es responsable de validar que cada material nuevo no exista ya en el sistema, que esté correctamente categorizado y que cumpla con las especificaciones mínimas exigidas por la normativa ISO 8000.

En la práctica, este proceso presenta tres problemas recurrentes que se identificaron y cuantificaron mediante un análisis exploratorio sobre 39,571 materiales del catálogo de la unidad de negocio, distribuidos en 1,234 categorías:

1. **Materiales duplicados.** Se identificaron 456 casos de duplicidad exacta en el catálogo, y un riesgo potencial de duplicidad parcial (por similitud textual) que alcanza al 94 % de los registros, producto de descripciones libres, abreviaciones inconsistentes entre gestores y el límite de 40 caracteres que impone SAP para el campo de descripción corta.
2. **Categorización incorrecta.** 246 materiales presentan una clasificación inadecuada respecto a su naturaleza real, y 94 repuestos específicamente fueron creados bajo la categoría de “suministros”, lo que distorsiona los reportes de consumo y dificulta la planificación de compras por tipo de material.
3. **Tiempo de gestión elevado.** Con un volumen promedio de 4.4 solicitudes de creación individual por día hábil (medido entre el 15 de febrero y el 17 de junio de 2026, período previo a la implementación), cada gestión permanece en promedio 3.3 horas dentro del rol del gestor —tiempo que incluye cola de trabajo, validaciones y los distintos pasos del proceso—. De ese tiempo, la búsqueda manual en SAP para descartar duplicados y verificar especificaciones —el paso que GAMMA automatiza directamente— consume entre 5 y 10 minutos por solicitud.

Estos hallazgos evidencian que el problema no es la falta de un proceso de gestión de datos maestros —la organización ya cuenta con uno—, sino la ausencia de herramientas analíticas que apoyen al gestor en el momento de la decisión: al crear un material, no existe hoy ningún mecanismo automatizado que le indique si ese material ya existe, ni qué categoría le corresponde con base en el histórico del catálogo.

Para atender esta necesidad se desarrolló **GAMMA — Gobierno Automatizado del Maestro de Materiales**, un asistente inteligente que integra tres módulos complementarios: normalización de descripciones mediante un modelo de lenguaje, detección de duplicados por similitud difusa sobre el catálogo, y clasificación automática de categoría mediante un modelo de aprendizaje supervisado entrenado sobre el histórico del catálogo. El proyecto abarca el ciclo de vida completo de un proyecto de analítica: desde el análisis exploratorio de los datos de origen, pasando por la integración y modelado, hasta el despliegue de una herramienta funcional validada por el propio equipo de gestores.

El presente documento describe la metodología seguida en cada una de estas etapas —análisis de fuentes de información, integración de datos, explotación de la información, desarrollo de modelos analíticos, visualización de resultados y arquitectura de puesta en producción— así como los resultados obtenidos y su impacto en la operación, tanto a nivel de eficiencia operativa como de retorno financiero.

2.1. Objetivo General

Desarrollar GAMMA (Gobierno Automatizado del Maestro de Materiales), una plataforma de asistencia analítica para el flujo de creación individual de materiales en SAP, mediante la articulación de procesamiento de lenguaje natural, búsqueda por similitud difusa y aprendizaje automático supervisado sobre el histórico del catálogo, para reducir el tiempo de gestión y mejorar la calidad del maestro de materiales de una unidad de negocio del sector energético con operación en Centroamérica y el Caribe.

2.2. Objetivos Específicos

1. Implementar un pipeline de integración del maestro de materiales de SAP mediante una arquitectura medallón sobre PostgreSQL, para consolidar en un repositorio único, normalizado y trazable los registros dispersos en trece archivos de exportación que constituyen el insumo de los módulos analíticos.
2. Analizar los defectos de calidad acumulados en el catálogo mediante la aplicación retroactiva de los motores de similitud difusa y de clasificación sobre los registros existentes, para cuantificar el volumen de duplicados y de errores de categorización que arrastra la operación y establecer la línea base contra la cual medir la mejora.
3. Seleccionar el algoritmo de clasificación de categoría mediante la evaluación comparativa de siete configuraciones sobre una partición estratificada del histórico del catálogo, para adoptar el que maximice la exactitud dentro de un costo de reentrenamiento sostenible en la operación.
4. Construir una plataforma web de asistencia conversacional que articule la normalización de descripciones, la detección de duplicados y la sugerencia de categoría dentro del flujo de creación individual de materiales, para asistir al gestor en el momento de la decisión conservando la validación humana antes del registro en SAP.
5. Evaluar el efecto de la herramienta sobre el proceso de creación de materiales mediante la comparación de los tiempos de gestión y las tasas de error registrados antes y después de su

implementación, para determinar el ahorro en horas-gestor y el retorno de la inversión del proyecto.

El costo del proceso actual de gestión de materiales no se limita al tiempo que invierte el equipo de gestores: se traslada a toda la cadena de procesos que depende de que un material quede correctamente registrado en el sistema. Mientras una solicitud permanece en gestión —en promedio 3.3 horas dentro del rol del gestor, sobre un volumen de 4.4 solicitudes diarias—, los procesos que suceden, como la emisión de una orden de compra o la ejecución de una tarea de mantenimiento, quedan detenidos. Reducir ese tiempo no mejora únicamente la productividad del gestor: mejora la velocidad de respuesta de la organización.

El impacto se agrava cuando el resultado de la gestión no es correcto. Un catálogo que ya arrastra 456 duplicados exactos, un riesgo de duplicidad parcial cercano al 94 % de los registros y 246 materiales con clasificación inadecuada, no solo es un problema de orden interno: distorsiona los reportes de consumo, complica la planificación de compras por tipo de material y reduce la trazabilidad de los activos para cualquier área que consulte esa información después. Cada día que el proceso continúa sin apoyo analítico, el catálogo acumula más inconsistencias, y el costo de corregirlas retroactivamente crece.

Atender este problema requiere visibilidad sobre cómo se está comportando el proceso hoy, y una forma de intervenir directamente en el momento en que ocurre el error. Un tablero que solo reporte el problema, sin cambiar la forma en que se crea el material, no resuelve la causa; y automatizar la creación sin poder medir su efecto no permite sostener la mejora en el tiempo. De ahí que la solución combine ambas capas: un modelo que asiste al gestor en el instante de la decisión, y un mecanismo de medición que permite verificar, con datos, si esa asistencia efectivamente está reduciendo el tiempo de gestión y mejorando la calidad del catálogo.

La información necesaria para construir y validar esta solución es de acceso directo dentro de la unidad de negocio, y la infraestructura tecnológica requerida se apoya íntegramente en herramientas de código abierto, lo que hace sostenible su operación más allá del período de desarrollo, sin inversión adicional significativa en licenciamiento.

Finalmente, el proyecto se justifica también en términos financieros: la reducción del tiempo de gestión y la prevención de duplicados se traduce en un ahorro cuantificable de horas-gestor, cifra que se desarrolla en detalle en la sección de Resultados y aplicación de negocio de este documento.

4.1. Gobierno de datos maestros

El gobierno de datos maestros (*Master Data Management*, MDM) es la disciplina encargada de asegurar que las entidades centrales de una organización —clientes, proveedores, materiales, entre otras— se mantengan consistentes, correctas y libres de duplicidad a través de los distintos sistemas que las consumen. DAMA International (2017) ubica el MDM como una de las áreas funcionales del gobierno de datos, y lo define como el conjunto de procesos que permiten mantener una versión autorizada y compartida de las entidades de negocio críticas. A diferencia de los datos transaccionales, que registran hechos puntuales, los datos maestros describen objetos persistentes que son referenciados por múltiples procesos a lo largo del tiempo; esa persistencia es precisamente lo que hace que un error introducido en el momento de la creación se propague y se vuelva costoso de revertir.

4.1.1. Dimensiones de calidad del dato maestro

La calidad de los datos no es un atributo único sino un constructo multidimensional. Wang y Strong (1996) establecieron, a partir de un estudio empírico con consumidores de datos, un marco jerárquico que organiza la calidad en cuatro categorías —intrínseca, contextual, de representación y de accesibilidad— y demostraron que los usuarios manejan una concepción de calidad considerablemente más amplia que la de exactitud, que era la dimensión dominante en la literatura previa. Su distinción entre calidad intrínseca (el dato es correcto en sí mismo) y calidad contextual (el dato es adecuado para la tarea en que se usa) es especialmente pertinente en un catálogo de materiales, donde una descripción puede ser literalmente cierta y aun así resultar inservible para quien necesita distinguir dos repuestos similares.

Aplicando este marco al dato maestro específicamente, Loshin (2009) señala que su calidad se mide típicamente en tres dimensiones operativas: *unicidad* (ausencia de registros duplicados), *exactitud* (que los atributos del registro describan correctamente el objeto real) y *completitud* (que los campos obligatorios estén correctamente llenados). Estas tres dimensiones son las que estructuran el diagnóstico y la intervención del presente proyecto: el módulo de detección de duplicados atiende la unicidad, el módulo de clasificación atiende la exactitud, y el módulo de normalización atiende la completitud y la consistencia de representación.

4.1.2. Impacto económico de la mala calidad de datos

El deterioro de cualquiera de estas dimensiones tiene un efecto en cascada sobre los procesos que dependen del catálogo, como la planificación de compras, el control de inventario y el mantenimiento de activos. Redman (1998) documentó que los efectos de la mala calidad de datos en una empresa típica no se limitan al costo directo de corregir los registros, sino que incluyen incremento del costo operativo, decisiones menos efectivas, deterioro de la capacidad de ejecutar la estrategia y erosión de la confianza organizacional en los sistemas de información. Esta distinción entre el costo visible de la corrección y el costo difuso de operar sobre datos defectuosos es la base conceptual sobre la que se construye la justificación financiera del presente trabajo: el ahorro atribuible a una herramienta de gobierno de datos proviene tanto del tiempo de gestión que evita como de los errores que impide introducir en primer lugar.

4.1.3. Estándares para la descripción de datos maestros de materiales

La descripción de un material en un catálogo industrial no es texto libre arbitrario: existen estándares internacionales que definen cómo debe estructurarse para que sea inequívoca y portable entre organizaciones y sistemas.

La norma *ISO 8000* constituye la familia de estándares internacionales de calidad de datos, con varias partes dedicadas específicamente al dato maestro. En particular, la norma *ISO 8000-110* especifica los requisitos para el intercambio de datos característicos de datos maestros en cuanto a sintaxis, codificación semántica y conformidad con una especificación de datos (International Organization for Standardization, 2021). El principio central es que un dato de calidad debe ser *portable*: su significado debe estar codificado de forma explícita y no depender del sistema o de la convención interna de quien lo creó.

Complementariamente, la serie *ISO 22745* define los diccionarios técnicos abiertos (*Open Technical Dictionary*, OTD) y su aplicación a los datos maestros (International Organization for Standardization, 2010). Bajo este enfoque, un material se describe mediante un identificador de concepto —el sustantivo o término principal que designa la clase de objeto— acompañado de un conjunto de pares propiedad-valor que lo especifican. Esta convención, conocida en la práctica de catalogación industrial como formato *sustantivo-modificador* (*noun-modifier*), es la que subyace al estándar corporativo empleado en la unidad de negocio de este proyecto, donde las descripciones siguen una estructura de término principal seguido de modificadores delimitados por separadores. La normalización automática que realiza GAMMA consiste, en esencia, en llevar una descripción propuesta en lenguaje libre por el gestor a esta forma estructurada.

Finalmente, para la clasificación de los materiales existe el *United Nations Standard Products and Services Code* (UNSPSC), una taxonomía abierta y multisectorial de productos y servicios administrada por el Programa de las Naciones Unidas para el Desarrollo, organizada en una jerarquía de cuatro niveles —segmento, familia, clase y comodidad— codificada como un número de ocho dígitos (United Nations Development Programme, 2023). El catálogo de la unidad de negocio mantiene una correspondencia entre sus clases internas de material y los códigos UNSPSC, lo que permite anclar la taxonomía propia a un referente externo estandarizado.

4.2. Inteligencia de negocios y medición del desempeño del proceso

Una intervención sobre un proceso operativo solo puede sostenerse en el tiempo si existe un mecanismo para medir su efecto. La inteligencia de negocios (*Business Intelligence*, BI) aporta ese

componente: el conjunto de arquitecturas, modelos y herramientas que transforman datos operativos en indicadores que soportan la decisión gerencial.

4.2.1. Modelado dimensional

Kimball y Ross (2013) establecieron el modelado dimensional como el patrón de diseño predominante para estructurar datos orientados al análisis. Su propuesta organiza la información en tablas de hechos —que registran las mediciones numéricas de un proceso de negocio, con una granularidad explícitamente declarada— y tablas de dimensión —que contienen los atributos descriptivos por los que esas mediciones se filtran y agrupan. La ventaja de este esquema, conocido como *estrella*, frente a un modelo normalizado, es que privilegia la comprensibilidad para el usuario de negocio y el desempeño de consulta por encima de la ausencia de redundancia. En el presente proyecto, este patrón orienta el diseño de la capa de consumo, donde cada solicitud de creación de material constituye el grano de la medición y los atributos de gestor, tipo de material y período conforman las dimensiones de análisis.

4.2.2. Indicadores clave de desempeño

Un indicador clave de desempeño (*Key Performance Indicator*, KPI) es una medida cuantificable, asociada a un objetivo declarado, que permite evaluar si un proceso avanza en la dirección esperada. Kimball y Ross (2013) advierten que la utilidad de un indicador depende críticamente de que su definición —numerador, denominador, granularidad temporal y población incluida— esté documentada de forma no ambigua, ya que una misma métrica calculada bajo criterios distintos produce cifras irreconciliables entre áreas. Esta consideración es la que motiva, en este trabajo, la definición explícita de la población de medición y la exclusión sistemática del tráfico de pruebas del cálculo de los indicadores.

4.2.3. Valoración económica de la información

Laney (2018) propone bajo el término *infonomics* la tesis de que la información debe tratarse como un activo económico formal, sujeto a valoración, gestión y monetización con el mismo rigor que se aplica a los activos físicos. El autor distingue entre la monetización directa —vender o intercambiar información— y la indirecta, que consiste en aprovechar la información para reducir costos, mitigar riesgos o mejorar la eficiencia de un proceso interno. Es esta segunda modalidad la que corresponde al presente proyecto: el valor generado no proviene de comercializar el catálogo de materiales, sino de que un catálogo de mayor calidad reduce el tiempo de gestión y evita los costos aguas abajo asociados a registros duplicados o mal clasificados.

4.3. Metodología para proyectos de analítica

El desarrollo de un proyecto de analítica requiere un marco de proceso que ordene sus fases y haga explícita la naturaleza iterativa del trabajo. Wirth y Hipp (2000) formalizaron el modelo *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), concebido como un proceso de referencia independiente tanto del sector industrial como de la tecnología empleada. El modelo organiza el trabajo en seis fases —comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue— y establece que la secuencia entre ellas no es estrictamente lineal: los hallazgos de una fase posterior frecuentemente obligan a revisar decisiones tomadas en una anterior. CRISP-DM continúa siendo el modelo de proceso de referencia más extendido para

proyectos de minería de datos y ciencia de datos aplicada, y es el que estructura la metodología seguida en este trabajo.

4.4. Arquitectura de datos por capas (medallón)

La arquitectura medallón es un patrón de diseño para *pipelines* de datos que organiza el flujo de información en capas sucesivas de refinamiento, denominadas Bronce, Plata y Oro (Databricks, s.f.). La capa Bronce conserva el dato tal como llega de la fuente original, sin transformaciones. La capa Plata aplica limpieza, normalización y validaciones de calidad. La capa Oro contiene datos ya agregados o modelados específicamente para su consumo final, ya sea por un tablero de indicadores, un modelo analítico o una aplicación. Este patrón permite reprocesar el pipeline completo ante un error sin perder el dato original, y desacopla la lógica de transformación de la lógica de consumo.

Este esquema por capas se inscribe en la propuesta arquitectónica del *lakehouse*, formulada por Zaharia, Ghodsi, Xin, y Armbrust (2021), que busca unificar en una sola plataforma las capacidades de gestión y confiabilidad propias del almacén de datos con la flexibilidad y el soporte a cargas de ciencia de datos característicos del lago de datos. Los autores argumentan que la separación tradicional entre ambos entornos genera problemas de obsolescencia del dato, duplicación de almacenamiento y costo total de propiedad, y que una arquitectura de capas sobre formatos abiertos con garantías transaccionales resuelve simultáneamente los requerimientos de reportería y de modelado analítico. En el presente proyecto este patrón se implementa sobre un motor relacional, aprovechando que el volumen del catálogo permite prescindir de una plataforma distribuida sin sacrificar la separación lógica entre capas.

4.5. Procesamiento de lenguaje natural para normalización de texto

Las descripciones de materiales en un catálogo industrial constituyen un tipo particular de texto: breve, técnico, con alta densidad de abreviaturas y sin una gramática formal. Se trata además de texto sujeto a una restricción estructural fuerte, ya que los sistemas ERP imponen un límite estricto de caracteres al campo de descripción corta, lo que induce a los gestores a abreviar de formas idiosincráticas y no documentadas.

4.5.1. Enfoques basados en reglas y basados en modelos de lenguaje

El procesamiento de lenguaje natural (*Natural Language Processing*, NLP) ofrece dos familias de enfoques para trabajar con este tipo de texto: una basada en reglas y diccionarios de abreviatura, precisa pero de mantenimiento manual constante y de cobertura limitada al vocabulario previamente registrado; y otra basada en modelos de lenguaje de gran escala (*Large Language Models*, LLM), que aprovecha el conocimiento general del lenguaje adquirido durante el entrenamiento para inferir la forma estándar de un término técnico sin necesidad de un diccionario exhaustivo.

4.5.2. La arquitectura Transformer

Los LLM actuales se construyen sobre la arquitectura *Transformer*, introducida por Vaswani y cols. (2017), que reemplazó los mecanismos recurrentes por un mecanismo de atención capaz de ponderar la relevancia de cada palabra de una secuencia respecto a las demás. Esta arquitectura

permite procesar la secuencia completa en paralelo y capturar dependencias entre términos distantes, lo que resultó determinante para el escalamiento de los modelos de lenguaje a los tamaños actuales.

4.5.3. Modelos de lenguaje aplicados a tareas de preparación de datos

Brown y cols. (2020) demostraron que, a partir de cierta escala, los modelos de lenguaje adquieren la capacidad de resolver tareas nuevas a partir de unas pocas demostraciones incluidas en la propia instrucción (*few-shot learning*), sin necesidad de reentrenamiento ni de ajuste de parámetros. Esta propiedad es la que hace viable aplicar un LLM a la normalización de descripciones sin construir un conjunto de entrenamiento etiquetado específico para la tarea.

La pertinencia de este enfoque para problemas de datos ha sido evaluada de forma sistemática. Narayan, Chami, Orr, y Ré (2022) formularon cinco tareas clásicas de limpieza e integración de datos —entre ellas la imputación de valores faltantes, la corrección de errores y el emparejamiento de entidades— como tareas de *prompting* sobre modelos fundacionales, y encontraron que estos alcanzan un desempeño competitivo con el estado del arte a pesar de no haber sido entrenados específicamente para dichas tareas. Este resultado respalda empíricamente la decisión de delegar la normalización de descripciones a un modelo de lenguaje en lugar de a un motor de reglas, que es el enfoque adoptado en el módulo correspondiente de GAMMA.

4.6. Detección de duplicados y resolución de entidades

4.6.1. El problema de la detección de duplicados

La existencia de múltiples representaciones de una misma entidad dentro de una base de datos es un problema clásico y ampliamente estudiado. Elmagarmid, Ipeirotis, y Verykios (2007) lo caracterizan como la situación en que registros duplicados carecen de una clave común y presentan además errores de transcripción, información incompleta o ausencia de formatos estándar, lo que impide resolverlos mediante comparación exacta. Los autores sistematizan las familias de métricas de similitud aplicables —basadas en caracteres, en tokens o en modelos probabilísticos— y las técnicas para hacer escalable la comparación, cuyo costo es cuadrático en el número de registros si se realiza de forma exhaustiva. Su caracterización aplica de forma directa al catálogo de materiales estudiado, donde las descripciones libres, las abreviaturas inconsistentes entre gestores y el límite de caracteres del campo producen exactamente el tipo de variación que hace fallar la comparación literal.

4.6.2. Similitud por q-gramas y trigramas

La búsqueda por similitud difusa (*fuzzy matching*) resuelve este problema descomponiendo cada cadena de texto en subsecuencias de caracteres consecutivos, denominadas *q-gramas*, y comparando el grado de superposición entre los conjuntos de q-gramas de dos cadenas. Cuando la longitud de la subsecuencia es tres, se les denomina *trigramas* (PostgreSQL Global Development Group, 2023). Este enfoque es tolerante a variaciones menores de escritura, a la inversión del orden de las palabras y al uso de separadores distintos, y no requiere que las cadenas comparadas compartan una estructura gramatical común.

Gravano y cols. (2001) demostraron que este tipo de emparejamiento aproximado puede expresarse mediante operaciones relacionales convencionales y ejecutarse dentro del propio motor de base de datos, aprovechando sus índices y su optimizador sin necesidad de infraestructura externa. La extensión `pg_trgm` de PostgreSQL (PostgreSQL Global Development Group, 2023) implementa este

principio de forma nativa, permitiendo indexar el catálogo completo y ejecutar búsquedas de similitud con baja latencia. Esta propiedad es determinante para el diseño de GAMMA, ya que la detección de duplicados debe resolverse de forma interactiva, en el momento en que el gestor propone una descripción.

4.6.3. Umbral de similitud y compromiso entre exhaustividad y precisión

Un motor de similitud difusa no produce una decisión binaria sino un puntaje continuo, por lo que su operación requiere fijar un umbral a partir del cual dos registros se consideran candidatos a duplicado. La elección de ese umbral define un compromiso explícito: un valor bajo maximiza la exhaustividad —detecta más duplicados reales— a costa de generar falsos positivos que el gestor debe descartar manualmente; un valor alto reduce las alertas espurias pero deja pasar duplicados con redacción divergente (Elmagarmid y cols., 2007). Dado que el umbral determina simultáneamente la utilidad operativa de la herramienta y la magnitud del problema que se reporta al medir el catálogo, su valor debe declararse explícitamente junto con cualquier cifra de duplicidad, y su efecto debe caracterizarse mediante un análisis de sensibilidad.

4.7. Representación vectorial de texto

Antes de aplicar un algoritmo de aprendizaje automático sobre texto, este debe convertirse en una representación numérica.

4.7.1. TF-IDF

Una de las técnicas más establecidas es *TF-IDF* (*Term Frequency – Inverse Document Frequency*), propuesta por Salton y Buckley (1988), que pondera cada término según su frecuencia relativa dentro de un documento y su rareza a través de todo el corpus. La intuición es que un término frecuente en un documento pero infrecuente en la colección resulta altamente discriminante, mientras que uno presente en casi todos los documentos aporta poca información para distinguirlos. Esta representación es la que se emplea como entrada de los algoritmos de clasificación evaluados en este proyecto.

4.7.2. N-gramas de carácter

La variante empleada en este trabajo no opera sobre palabras completas sino sobre subcadenas de caracteres. Cavnar y Trenkle (1994) demostraron que la categorización de texto basada en frecuencias de n-gramas de carácter es robusta frente a errores tipográficos y variaciones morfológicas, precisamente porque un error puntual afecta únicamente a los pocos n-gramas que lo contienen y deja intacto el resto de la representación. Esta propiedad es especialmente valiosa en un catálogo de materiales, donde las descripciones contienen abreviaturas no normalizadas, unidades de medida, fracciones y errores de digitación que fragmentarían una representación basada en palabras completas, pero que degradan solo parcialmente una representación basada en caracteres.

4.8. Algoritmos de clasificación supervisada evaluados

La asignación automática de una categoría a partir de la descripción de un material es un problema de clasificación de texto supervisada. Sebastiani (2002) consolidó el enfoque inductivo —construir el clasificador a partir de ejemplos previamente etiquetados— como el paradigma dominante en esta tarea, frente a la definición manual de reglas por expertos de dominio. Dada la diversidad de familias de algoritmos disponibles, se evaluaron seis enfoques distintos sobre el mismo conjunto de datos, descritos a continuación.

4.8.1. Regresión logística

Modelo lineal que estima la probabilidad de pertenencia a una clase mediante una función logística aplicada a una combinación lineal de las variables de entrada. Fue formalizado por Cox (1958) como un método de regresión para variables de respuesta binaria, y se ha extendido posteriormente a problemas multiclase.

4.8.2. Máquinas de vectores de soporte (SVM lineal)

Introducidas por Cortes y Vapnik (1995), buscan el hiperplano que separa las clases maximizando el margen entre los puntos más cercanos de cada una. En su variante lineal (**LinearSVC**), el modelo opera directamente sobre la representación vectorial del texto sin necesidad de una función núcleo (*kernel*), lo que la hace especialmente eficiente en espacios de alta dimensionalidad como los generados por TF-IDF.

4.8.3. Random Forest

Propuesto por Breiman (2001), es un método de ensamble que combina múltiples árboles de decisión entrenados sobre subconjuntos aleatorios de datos y variables, y agrega sus predicciones por votación. Su capacidad de capturar relaciones no lineales lo hace robusto frente a ruido en los datos, a costa de un mayor costo computacional que un modelo lineal.

4.8.4. XGBoost

Chen y Guestrin (2016) presentaron este sistema de *gradient boosting* sobre árboles de decisión, que construye los árboles de forma secuencial, corrigiendo en cada iteración los errores del árbol anterior. Es reconocido por su desempeño competitivo en tareas de clasificación estructurada, aunque su tiempo de entrenamiento crece considerablemente con la dimensionalidad del vocabulario.

4.8.5. fastText

Desarrollado por Joulin, Grave, Bojanowski, y Mikolov (2017), es un clasificador lineal que representa cada documento como el promedio de los vectores de sus palabras (o subpalabras), entrenado de forma conjunta con la tarea de clasificación. Fue diseñado explícitamente para ofrecer un desempeño comparable al de modelos de aprendizaje profundo con tiempos de entrenamiento varios órdenes de magnitud menores.

4.8.6. Transformer (embeddings contextuales)

Los modelos basados en la arquitectura *Transformer* (Vaswani y cols., 2017) generan representaciones vectoriales del texto que capturan el significado de cada palabra en función de su contexto, a diferencia de TF-IDF, que trata cada término de forma independiente. Estas representaciones, pre-entrenadas sobre grandes volúmenes de texto general, suelen requerir un proceso adicional de ajuste fino (*fine-tuning*) para adaptarse a vocabularios técnicos especializados como el de un catálogo industrial. Este requerimiento implica que su desempeño depende de forma crítica del presupuesto de cómputo y de la configuración del entrenamiento, un factor que debe considerarse al interpretar los resultados de una comparación entre familias de algoritmos.

4.9. Evaluación de clasificadores multiclase

La comparación entre algoritmos exige definir con precisión las métricas empleadas, particularmente cuando el problema involucra un número elevado de clases con distribución desigual.

4.9.1. Métricas y esquemas de promediado

Sokolova y Lapalme (2009) realizaron un análisis sistemático de las medidas de desempeño utilizadas en tareas de clasificación binaria, multiclase, multietiqueta y jerárquica, caracterizando qué cambios en la matriz de confusión deja invariante cada medida. Su análisis hace explícito que la elección de la métrica no es neutral: la *exactitud* (*accuracy*) global queda dominada por las clases mayoritarias, mientras que las medidas promediadas ofrecen lecturas distintas del mismo resultado. El promedio *macro* calcula la métrica de forma independiente para cada clase y luego promedia sin ponderar, otorgando el mismo peso a una clase con miles de ejemplos que a una con tres; el promedio *ponderado* (*weighted*) pondera cada clase por su frecuencia, aproximándose al comportamiento de la exactitud global. La brecha entre ambos promedios constituye por sí misma un diagnóstico del desbalance del problema, por lo que en este trabajo se reportan ambos.

4.9.2. Exactitud top-k

En un escenario de asistencia al usuario, donde el sistema propone sugerencias que una persona valida, la métrica relevante no es únicamente si la primera predicción es correcta, sino si la respuesta correcta aparece entre las primeras k opciones presentadas. La exactitud *top-k* mide esta propiedad y resulta más representativa del valor operativo del sistema cuando la interfaz muestra varias alternativas al gestor, ya que refleja la proporción de casos en que la herramienta le evita realizar la búsqueda manual.

4.9.3. Desbalance de clases

He y Garcia (2009) revisaron de forma exhaustiva la problemática del aprendizaje sobre datos desbalanceados, donde la distribución desigual de ejemplos entre clases sesga a los algoritmos hacia las clases mayoritarias y degrada el desempeño sobre las minoritarias, que con frecuencia son las de mayor interés. Los autores sistematizan las estrategias disponibles —remuestreo, aprendizaje sensible al costo y métodos de ensamble— y advierten sobre la insuficiencia de la exactitud global como criterio de evaluación en estos escenarios. Esta consideración es central en el presente proyecto, dado que el catálogo estudiado presenta una distribución fuertemente asimétrica, con un número considerable de clases representadas por muy pocos materiales.

4.9.4. Protocolo de validación

Para obtener una estimación no sesgada del desempeño, el conjunto de datos se particiona en subconjuntos de entrenamiento y prueba, de modo que la evaluación se realice exclusivamente sobre ejemplos no vistos durante el ajuste del modelo. En problemas con clases desbalanceadas se emplea una partición *estratificada*, que preserva la proporción de cada clase en ambos subconjuntos y evita que las clases minoritarias queden ausentes del conjunto de prueba (He y Garcia, 2009). Cuando el modelo seleccionado se reentrena posteriormente sobre la totalidad de los datos para su despliegue, la métrica reportada continúa siendo la obtenida sobre la partición de prueba, y así debe declararse para no atribuir al modelo en producción una estimación medida sobre una configuración distinta.

4.10. Calibración de probabilidades y predicción selectiva

Un sistema de asistencia que sugiere una categoría necesita acompañar cada sugerencia de una medida de confianza interpretable, tanto para decidir cuándo presentarla como para permitir al usuario ponderar cuánto fiarse de ella.

4.10.1. Calibración de probabilidades

Un clasificador está *calibrado* cuando las probabilidades que emite corresponden a frecuencias empíricas reales: de los casos a los que asigna una confianza de 0.80, aproximadamente el 80 % deberían resultar correctos. Las máquinas de vectores de soporte no producen probabilidades de forma nativa, sino distancias al hiperplano separador. Platt (1999) propuso resolver esta limitación ajustando una función sigmoide sobre las salidas del modelo, de manera que las distancias se transformen en estimaciones de probabilidad conservando la propiedad de dispersión del SVM original. Zadrozny y Elkan (2002) extendieron posteriormente el tratamiento a problemas multiclase, mostrando que estos pueden descomponerse en múltiples problemas binarios cuyas estimaciones se combinan. Esta técnica es la que permite emplear un clasificador de margen máximo dentro de un flujo que requiere probabilidades, como es el caso de la arquitectura adoptada en este proyecto.

4.10.2. Clasificación con opción de rechazo

Disponer de probabilidades calibradas habilita una estrategia de *predicción selectiva*: en lugar de emitir siempre una predicción, el sistema puede abstenerse cuando su confianza es insuficiente y derivar el caso al criterio humano. Chow (1970) formalizó este planteamiento derivando la relación óptima entre la tasa de error y la tasa de rechazo para un sistema de reconocimiento bayesiano, y estableciendo que existe un compromiso cuantificable entre ambas: elevar el umbral de confianza reduce el error sobre los casos aceptados a costa de reducir la cobertura del sistema.

Este marco es el que fundamenta la operación de GAMMA como herramienta de asistencia y no de automatización plena. Al caracterizar empíricamente la curva de exactitud frente a cobertura para distintos umbrales de confianza, es posible seleccionar un punto de operación que refleje la tolerancia al error de la organización, y sustentar con datos la decisión de que el gestor conserve el control de la creación final del material.

Dentro de la unidad de negocio donde se desarrolla el proyecto no existía ningún mecanismo automatizado de apoyo a la creación de materiales: la verificación de duplicados y la asignación de categoría se resolvían mediante inspección manual del gestor sobre el catálogo en SAP, apoyándose en las funciones de búsqueda estándar del módulo de materiales. Estas operan por coincidencia de cadenas y no por similitud, de modo que un material registrado con una abreviatura distinta a la que el gestor consulta permanece invisible, y la eficacia de la verificación termina dependiendo del conocimiento acumulado de cada persona sobre las convenciones históricas del catálogo. No se identificó ningún intento previo, dentro de la organización, de abordar este problema mediante analítica o aprendizaje automático.

Sí existe un antecedente de otra naturaleza. La corporación cuenta con un estándar de nomenclatura para las descripciones de materiales basado en la normativa ISO 8000, anterior a este trabajo, bajo el cual está redactada la totalidad del catálogo histórico analizado. La organización, por lo tanto, ya había intentado gobernar la calidad de su catálogo, pero lo hizo por vía normativa: definiendo una regla y esperando que cada gestor la aplicara de forma consistente en el momento de la creación. Los duplicados y las clasificaciones inadecuadas acumulados a lo largo del tiempo evidencian que una norma que no cuenta con un mecanismo que verifique su cumplimiento en el momento de la captura no basta, por sí sola, para sostener la calidad del dato.

El problema cuenta además con una oferta comercial madura. El propio fabricante del ERP ofrece *SAP Master Data Governance*, un módulo licenciado que incorpora creación de datos maestros basada en flujos de trabajo y detección de duplicados mediante algoritmos de emparejamiento configurables (SAP SE, s.f.); existe asimismo un mercado de proveedores especializados en catálogos de mantenimiento, reparación y operación (Verdantis, s.f.), con casos documentados de proyectos que han procesado más de un millón de registros (Ernst & Young, s.f.). La unidad de negocio no cuenta con ninguno de estos módulos ni servicios contratados. Estas alternativas se descartaron por dos razones. La primera es de modelo de costo: operan bajo esquemas de licenciamiento por usuario o de suscripción a servicio, que implican un desembolso recurrente indefinido, mientras que lo que se buscaba era una solución de pago único cuyo costo se concentrara en el desarrollo y no comprometiera el presupuesto operativo de los años siguientes. La segunda es de ajuste: se trata de plataformas de gobierno integral, concebidas para intervenir el ciclo completo del dato maestro y para operar sobre taxonomías genéricas, cuando lo que se requería era una herramienta a la medida, acotada al punto específico del flujo donde se origina el problema y entrenada sobre el histórico y la clasificación internos de la propia corporación.

En cuanto a los antecedentes técnicos, la clasificación automática de descripciones de producto cuenta con precedentes que se remontan a los primeros sistemas de comercio electrónico entre empresas. Ding y cols. (2002) desarrollaron *GoldenBullet*, un sistema de clasificación automática de datos de producto contra la taxonomía UNSPSC —la misma con la que el catálogo de la unidad de negocio mantiene correspondencia—, evaluando modelos de espacio vectorial, vecinos más cercanos y Naive Bayes sobre datos reales de catálogo. Su mejor configuración alcanzó una exactitud del 78 % en la primera predicción y del 88 % considerando las diez primeras sugerencias, discriminando entre 421 categorías, cifras que constituyen un punto de referencia sobre el orden de magnitud esperable en esta clase de problema. Resulta particularmente pertinente la advertencia de los autores en el sentido de que una exactitud en ese rango iguala o supera la calidad de la clasificación humana sobre el mismo material, y que perseguir cifras sensiblemente superiores implicaría sobreajustar el modelo a decisiones humanas que a su vez contienen una tasa de error no despreciable. En el estado actual de la disciplina, Cheng y cols. (2024) muestran la vigencia de una arquitectura por etapas, en la que un modelo especializado acota las categorías candidatas y una segunda instancia basada en un modelo de lenguaje resuelve entre ellas.

En el ámbito de la detección de duplicados, Albayrak, Aytakin, y Kalaycı (2022) pusieron en producción un motor para una plataforma de comercio electrónico que combina métricas de similitud textual con un clasificador entrenado sobre pares de productos etiquetados por expertos, demostrando a gran escala que el enfoque híbrido supera en precisión a los métodos no adaptativos. Su trabajo confirma que la comparación por similitud, y no la coincidencia exacta de cadenas, es el camino viable en catálogos con descripciones de texto libre; señala también que la variante más precisa exige disponer de un conjunto etiquetado de pares duplicado y no duplicado, cuya construcción supone un esfuerzo de anotación experta considerable.

En conjunto, estos antecedentes confirman que tanto la detección de duplicados como la clasificación automática de descripciones de producto cuentan con precedentes consolidados de aplicación exitosa en catálogos a escala industrial, y establecen el rango de desempeño que la literatura reporta como equivalente o superior a la clasificación humana para esta clase de tarea. Lo que no se localizó fue un antecedente que integrara ambas capacidades dentro del flujo operativo de creación de materiales de una organización y que midiera su efecto sobre el tiempo de gestión con datos de producción, que es el espacio en el que se inscribe el presente trabajo.

El proyecto se restringe al flujo de creación individual de materiales dentro de SAP, que es el mecanismo mediante el cual un gestor solicita, valida y registra un material nuevo en el catálogo de la unidad de negocio. Dentro de este flujo, GAMMA interviene en tres momentos: normaliza la descripción propuesta por el gestor, verifica su similitud contra el catálogo cargado en la plataforma para alertar sobre posibles duplicados, y sugiere la categoría más probable con base en el histórico de materiales ya clasificados. GAMMA es una herramienta de asistencia y validación: no escribe directamente en SAP ni sustituye el criterio del gestor, quien conserva el control de la decisión final. Las solicitudes ya validadas se entregan mediante exportación a un archivo de hoja de cálculo, que es el insumo con el que el material se registra posteriormente en el sistema.

La plataforma no mantiene integración en línea con el ERP, ni de lectura ni de escritura. Esta separación es deliberada y constituye el mecanismo de supervisión humana sobre el que se diseñó la solución: el gestor exporta periódicamente el maestro de materiales desde SAP hacia la plataforma, y registra en SAP las solicitudes que la plataforma ya validó, de modo que ninguna operación sobre el sistema transaccional ocurre sin la intervención de una persona. Su contrapartida es que la detección de duplicados alcanza a los materiales existentes hasta la fecha de la última carga, por lo que un registro creado en SAP con posterioridad no es considerado en la comparación hasta que el catálogo se actualice.

El modelo de clasificación se entrena y valida sobre el catálogo de una única unidad de negocio, que es el ámbito de esta primera implementación. Su extensión al resto de las unidades de la corporación queda fuera del alcance del proyecto y se plantea como la etapa siguiente, una vez confirmado su desempeño en este entorno; dentro del catálogo empleado, las categorías con muy escasa representación histórica quedan fuera del espacio de predicción del modelo. El modelo se despliega, asimismo, como un artefacto entrenado de forma previa: la incorporación de un proceso automatizado de reentrenamiento que lo realimente con las correcciones registradas por los gestores durante el uso queda fuera del alcance de esta fase y se identifica como la evolución técnica prevista para la herramienta.

Queda fuera del alcance del proyecto el flujo de creación masiva de materiales, que opera mediante un mecanismo distinto al de la creación individual y no fue intervenido. Tampoco forma parte del alcance la corrección automática de los materiales duplicados o mal categorizados que ya existían en el catálogo antes de la implementación: el proyecto cuantifica ese universo mediante la auditoría retroactiva descrita en los objetivos, pero su remediación corresponde a un esfuerzo de limpieza de datos separado, fuera del alcance de este trabajo.

El desarrollo y la validación del proyecto se realizaron con datos y usuarios de una unidad de negocio específica dentro de la organización, con un período de uso activo por parte del equipo de gestores comprendido entre el 18 de junio y el 21 de julio de 2026. Los resultados de tiempo de gestión, calidad del catálogo y satisfacción de usuario que se presentan en este documento corresponden a ese alcance y a ese período.

El proyecto se desarrolla y se limita al alcance de una única unidad de negocio dentro de una organización con presencia en múltiples países de Centroamérica y el Caribe; no se extiende a otras unidades, áreas o sistemas que la organización pudiera operar de forma independiente.

7.1. Enfoque metodológico

El desarrollo del proyecto se estructuró siguiendo el modelo de proceso CRISP-DM (Wirth y Hipp, 2000), cuyas seis fases se mapearon al trabajo realizado de la siguiente manera: la *comprensión del negocio* corresponde al levantamiento del proceso de creación de materiales y a la cuantificación de su problemática; la *comprensión de los datos*, al análisis exploratorio del maestro exportado desde SAP; la *preparación de los datos*, a la construcción del pipeline de integración y del conjunto de modelado; el *modelado*, a la evaluación comparativa de algoritmos de clasificación; la *evaluación*, a la medición del desempeño sobre datos retenidos y sobre la operación real; y el *despliegue*, a la puesta en producción de la plataforma y a su uso por parte del equipo de gestores.

La ejecución no fue lineal. Los hallazgos del análisis exploratorio —en particular la distribución fuertemente asimétrica de materiales entre categorías— obligaron a volver sobre la definición del conjunto de modelado, y los resultados de la primera competencia de algoritmos motivaron una segunda ronda de evaluación con familias adicionales.

7.2. Materiales

7.2.1. Fuentes de información

La fuente primaria del proyecto es el maestro de materiales del módulo MM de SAP correspondiente a la unidad de negocio. Al no existir integración directa con el ERP, la extracción se realizó mediante exportación manual a archivos de hoja de cálculo, organizados en trece archivos según el tipo de material. Cada registro aporta el código de material, su texto breve —la descripción normalizada de hasta cuarenta caracteres—, la denominación estándar que actúa como categoría, y la unidad de medida base.

A esta fuente se sumaron dos catálogos de referencia. El primero es el maestro de clases o

denominaciones de la corporación, con 1,538 entradas, que además del código y el nombre de cada clase aporta el grupo de artículos, el sector, el tipo de material asociado y su correspondencia con el clasificador UNSPSC. El segundo es la tabla del propio clasificador UNSPSC de Naciones Unidas (United Nations Development Programme, 2023), que permite anclar la taxonomía interna a un referente externo estandarizado.

Todas las fuentes son de naturaleza estructurada y de acceso directo dentro de la unidad de negocio. El corte del maestro empleado para el desarrollo y el entrenamiento corresponde a una fecha específica de extracción, lo que implica que el catálogo con el que opera la plataforma es una fotografía y no un reflejo en tiempo real del ERP.

7.2.2. Recursos tecnológicos

La plataforma se construyó sobre PostgreSQL 16 con la extensión `pg_trgm` habilitada, un API desarrollado en Python con FastAPI, un entorno de Jupyter Lab para la experimentación analítica y un frontend de página única servido por Nginx, todo orquestado mediante contenedores con Docker Compose. El modelado se realizó con las bibliotecas estándar del ecosistema científico de Python. La normalización de descripciones se apoya en un modelo de lenguaje de gran escala consumido por interfaz de programación.

Con la única excepción del servicio de modelo de lenguaje, que opera bajo un esquema de pago por uso, la totalidad de la infraestructura se compone de software de código abierto.

7.3. Integración de la información

7.3.1. Arquitectura implementada

El repositorio de datos se implementó siguiendo la arquitectura medallón descrita en el marco teórico, con cuatro esquemas de responsabilidad diferenciada. El esquema **bronze** concentra la trazabilidad del sistema: registros de ingesta, de predicciones, de decisiones sobre duplicados, de interacciones con el modelo de lenguaje y de errores de aplicación. El esquema **silver** contiene los datos operacionales y de referencia ya normalizados: el maestro de materiales, los catálogos de clases, tipos de material, unidades de medida y UNSPSC, además de las conversaciones y las solicitudes de alta. El esquema **gold** expone vistas agregadas para el consumo del tablero de indicadores. Un cuarto esquema alberga la administración de usuarios de la plataforma.

La elección de un motor relacional en lugar de una plataforma distribuida responde al volumen de datos involucrado: un catálogo de decenas de miles de registros no justifica la complejidad operativa de un entorno de procesamiento distribuido, y permite además resolver la detección de duplicados dentro del mismo motor, sin necesidad de un servicio de búsqueda externo.

7.3.2. Proceso de ingesta

La carga de los archivos se implementó como un conjunto de servicios del API que reciben el archivo, lo interpretan y lo depositan en las tablas correspondientes. El proceso aplica un mapeo explícito entre los encabezados originales de la exportación de SAP y los campos del modelo de datos, resuelve los casos en que la exportación repite un mismo nombre de columna, y extrae los códigos de aquellos campos que llegan como valores compuestos de código y descripción separados por un guion.

Durante la carga se resuelven las llaves foráneas contra los catálogos de referencia: cada material se vincula con su clase y su unidad de medida, y cada clase con su tipo de material y su código UNSPSC. Toda ejecución queda registrada con el nombre del archivo, el número de filas procesadas, el estado resultante, el mensaje de error en caso de fallo y el tiempo transcurrido, lo que permite auditar el origen de cualquier registro del maestro.

Sobre la columna de texto breve del maestro se construyó un índice invertido de trigramas, que es el que sostiene el desempeño de las consultas de similitud.

7.4. Preparación de los datos

7.4.1. Preprocesamiento de texto

Para el modelado se definió una función de normalización que convierte el texto a mayúsculas, descompone y elimina los signos diacríticos, sustituye por espacios los separadores propios de la convención de nomenclatura, descarta los caracteres que no son alfanuméricos ni punto o guion, y colapsa los espacios redundantes. Esta transformación conserva las dimensiones, fracciones y designaciones técnicas, que son precisamente los elementos discriminantes en una descripción de material.

Una consideración crítica de diseño es que esta función es la misma en el entrenamiento y en la inferencia. Un modelo entrenado sobre texto preprocesado de una forma y consultado con texto preprocesado de otra degrada su desempeño de manera silenciosa, sin producir ningún error visible.

7.4.2. Criterios de construcción del conjunto de modelado

Sobre el maestro consolidado se aplicaron dos criterios de exclusión. El primero descarta los materiales que no tenían categoría asignada en la fuente, por no poder emplearse ni para entrenar ni para evaluar. El segundo descarta las clases representadas por menos de tres ejemplos, por resultar insuficientes para permitir simultáneamente el entrenamiento y la evaluación de una misma categoría.

El conjunto resultante se particionó en entrenamiento y prueba en proporción aproximada de 80 y 20 por ciento. La partición se estratificó por clase, dado el desbalance observado en el análisis exploratorio.

7.5. Métodos analíticos

7.5.1. Normalización de descripciones mediante modelo de lenguaje

El módulo de normalización se resolvió mediante un modelo de lenguaje de gran escala consumido a través de su interfaz de programación, en lugar de un motor de reglas y diccionarios de abreviatura. Esta decisión se sustenta en la evidencia de que los modelos fundacionales alcanzan desempeño competitivo en tareas de limpieza y estandarización de datos sin entrenamiento específico (Narayan y cols., 2022), y en la consideración práctica de que un diccionario de abreviaturas exigiría mantenimiento manual permanente conforme aparecen materiales de familias nuevas.

El modelo se configuró con una temperatura baja, para privilegiar la consistencia sobre la variedad en la redacción, y con respuesta forzada en formato JSON, de manera que su salida pueda consumirse de forma programática sin análisis sintáctico frágil. La instrucción de sistema codifica

cuatro elementos: las reglas de la convención corporativa de nomenclatura —límite de cuarenta caracteres, estructura de tipo y subtipo seguida de atributos, uso de mayúsculas, ausencia de tildes y abreviaturas estándar—; un conjunto de ejemplos tomados del propio maestro, que operan como demostraciones en contexto (Brown y cols., 2020); el catálogo de tipos de material vigente, inyectado dinámicamente desde la base de datos; y un protocolo de comportamiento ante información incompleta.

Este último elemento merece detalle. El modelo tiene instruido no inventar especificaciones ausentes: cuando la descripción que recibe es insuficiente, en lugar de completar con valores plausibles debe devolver una lista estructurada de los campos que faltan. Se definieron además reglas de dominio explícitas, como la obligatoriedad del material de fabricación para materiales físicos y la restricción de solicitar marca y modelo únicamente cuando se trata de repuestos o componentes en los que la marca es indispensable para la identificación. El diseño busca que el modelo falle por omisión y no por invención, que es el modo de falla aceptable en un proceso de gobierno de datos.

Cada interacción con el modelo se registra íntegramente: la instrucción enviada, la respuesta cruda, la respuesta interpretada, la acción resultante, el consumo de unidades de texto y el tiempo transcurrido.

7.5.2. Detección de duplicados

La detección de duplicados se implementó como una consulta de similitud difusa ejecutada directamente sobre el maestro normalizado, aprovechando la extensión `pg_trgm` de PostgreSQL y el índice invertido de trigramas construido durante la ingesta (Gravano y cols., 2001). La consulta calcula el coeficiente de similitud entre la descripción propuesta y cada descripción del catálogo, retiene aquellas que superan un umbral configurable y devuelve las diez coincidencias de mayor puntaje ordenadas de forma descendente.

El umbral de alerta se estableció en un valor deliberadamente permisivo, bajo el criterio de que en una herramienta de asistencia el costo de un falso positivo —que el gestor descarte una sugerencia irrelevante— es sustancialmente menor que el de un falso negativo, que se materializa en un duplicado creado y en el costo recurrente de arrastrarlo en el catálogo.

Cuando la consulta arroja coincidencias, estas no se presentan al gestor como una lista cruda: se devuelven al modelo de lenguaje, que las expone en el contexto de la conversación señalando las diferencias relevantes entre el material propuesto y los candidatos encontrados. La decisión del gestor —aceptar uno de los materiales existentes o sostener que el suyo es distinto— se registra de forma explícita, junto con el conjunto de candidatos que se le presentó y el tiempo que tomó decidir.

7.5.3. Diseño de la evaluación de algoritmos de clasificación

La selección del algoritmo se resolvió mediante una competencia entre familias, evaluadas todas sobre la misma partición de datos y con las mismas métricas. En una primera ronda se evaluaron cuatro configuraciones que combinan dos representaciones vectoriales —TF-IDF de palabras y TF-IDF de n-gramas de carácter— con tres algoritmos: regresión logística, máquina de vectores de soporte lineal y bosque aleatorio. En una segunda ronda se incorporaron tres familias adicionales: potenciación de gradiente sobre árboles, un clasificador de subpalabras y un transformador multilingüe preentrenado sometido a ajuste fino.

Se privilegió la representación por n-gramas de carácter sobre la de palabras completas por la densidad de abreviaturas, fracciones y designaciones alfanuméricas del catálogo, y se configuró con ventanas de dos a cinco caracteres delimitadas por palabra, ponderación logarítmica de la frecuencia y un vocabulario acotado a cincuenta mil rasgos.

La máquina de vectores de soporte se envolvió en un procedimiento de calibración con validación cruzada de tres particiones. Esta decisión no fue accesoria: sin estimaciones de probabilidad la plataforma no puede aplicar un umbral de confianza, y sin umbral no puede distinguir las sugerencias que presenta como resueltas de las que somete a revisión explícita del gestor.

La comparación se realizó sobre exactitud global, ambos promedios de F1, exactitud sobre las tres primeras sugerencias y tiempo de entrenamiento; este último se incorporó como criterio porque un modelo que exige horas de cómputo para reentrenarse resulta inviable de mantener en la operación. La configuración ganadora se reentrenó sobre la totalidad del conjunto para su despliegue, por lo que las métricas que se reportan corresponden a la partición retenida y no al artefacto en producción.

Para determinar el punto de operación del sistema se caracterizó adicionalmente el compromiso entre exactitud y cobertura a distintos umbrales de confianza, siguiendo el planteamiento de clasificación con opción de rechazo (Chow, 1970).

7.6. Arquitectura tecnológica e implementación

7.6.1. Componentes y despliegue

La plataforma se despliega mediante contenedores orquestados con Docker Compose, en cuatro servicios: el motor de base de datos con la extensión de similitud habilitada; el API, que concentra la lógica de negocio, la autenticación y la inferencia del modelo de clasificación; el entorno de experimentación analítica; y el frontend, que además actúa como proxy inverso hacia los demás servicios.

Una decisión de arquitectura relevante fue integrar la inferencia del modelo dentro del propio API en lugar de exponerla como un servicio independiente. El artefacto entrenado se carga en memoria una sola vez al arrancar el proceso y se reutiliza en cada predicción, lo que elimina la latencia de red entre servicios y la complejidad operativa de un componente adicional, a cambio de acoplar el ciclo de vida del modelo al del API.

7.6.2. Ciclo de vida de una solicitud

Una solicitud de alta atraviesa una secuencia definida de estados. Se crea en estado pendiente en el momento en que el modelo de lenguaje produce una propuesta de descripción normalizada. A partir de ahí puede resolverse de tres maneras: confirmarse, cuando el gestor valida la descripción y la categoría; descartarse, cuando la solicitud no procede; o cerrarse como coincidencia con un material existente, cuando la revisión de duplicados determina que el material ya está en el catálogo. Las solicitudes confirmadas transitan finalmente al estado exportado una vez incluidas en el archivo de entrega.

Este último estado materializa el punto de contacto con SAP. Las solicitudes validadas se consolidan en un archivo de hoja de cálculo que incorpora la descripción normalizada, la descripción extendida, el tipo de material, la clase asignada y las marcas de tiempo del proceso; ese archivo es el insumo con el que el material se registra en el ERP. La plataforma no escribe en SAP en ningún momento.

7.7. Instrumentación y medición

La medición del efecto de la herramienta no se resolvió de forma retrospectiva sino instrumentando el sistema desde su diseño, de modo que cada solicitud deje registro de su propio recorrido.

Cada solicitud almacena marcas de tiempo diferenciadas para su creación, la finalización de la normalización, la finalización de la búsqueda de duplicados, la decisión del gestor sobre los duplicados presentados, la finalización de la predicción de categoría, y su confirmación, descarte o exportación. Junto a ellas se registran las duraciones de cada etapa automática y su suma. Esta granularidad permite separar dos magnitudes que de otro modo quedarían confundidas: el tiempo que consume la máquina y el tiempo que consume la deliberación del gestor.

Se registra asimismo la calidad de la sugerencia. Cuando la clase que el gestor selecciona difiere de la que el modelo propuso, la solicitud queda marcada como corregida, lo que permite estimar la exactitud del modelo en operación real sobre datos que no formaron parte de su evaluación. Se registra también si la sugerencia superó el umbral de confianza y la confianza efectivamente obtenida.

Sobre esta base se construyó la capa de indicadores del esquema **gold**, materializada como vistas que agregan por semana los tiempos de procesamiento, la calidad de las predicciones, las decisiones sobre duplicados, el desglose por etapa del proceso, la actividad por usuario y el ahorro estimado. El cálculo del ahorro se parametriza mediante una tabla de configuración que almacena el tiempo de referencia del proceso manual y el costo por hora del gestor, de modo que el indicador pueda recalcularse ante un cambio de supuestos sin modificar la definición de la vista.

Todas las vistas de indicadores excluyen sistemáticamente la actividad de las cuentas administrativas. Esta exclusión es deliberada: el tráfico generado durante el desarrollo, las pruebas y las demostraciones contaminaría las mediciones de tiempo y de calidad si se agregara junto al uso productivo del equipo de gestores.

7.8. Protocolo de validación en producción

La validación de la herramienta se realizó mediante su uso efectivo por parte del equipo de gestores sobre solicitudes reales de la operación, durante el período comprendido entre el 18 de junio y el 21 de julio de 2026. La medición del efecto se construye por comparación contra una línea base del proceso manual levantada con anterioridad a la implementación, entre el 15 de febrero y el 17 de junio de 2026.

8.1. Caracterización del maestro de materiales

La consolidación de los trece archivos de exportación produjo un total de 45,397 registros. La Figura 1 muestra la composición del maestro según el archivo de origen: la distribución es marcadamente desigual, con dos tipos de material —repuestos industriales y suministros— que concentran por sí solos más del sesenta por ciento de los registros, mientras que varios tipos aportan menos de cien materiales cada uno.




Figura 1: Cantidad de materiales aportados por cada archivo de exportación del maestro

Del total de registros cargados, 40,029 contaban con una clase asignada en la fuente y 5,368 carecían de ella. Entre los materiales clasificados se identificaron 1,529 clases distintas, con una mediana de nueve materiales por clase y una clase máxima que concentra 655 registros. El Cuadro 1 detalla la distribución y la Figura 2 presenta las veinte clases de mayor volumen.

Cuadro 1: Distribución de las clases del maestro según su cantidad de materiales

Materiales por clase	Clases	Participación
1 material	132	8.6 %
2 a 10 materiales	697	45.6 %
11 a 50 materiales	517	33.8 %
51 a 100 materiales	103	6.7 %
Más de 100	80	5.2 %
Total	1,529	100.0 %

Más de la mitad de las clases cuenta con diez materiales o menos, y 132 están representadas por un único registro.




Figura 2: Veinte clases con mayor cantidad de materiales en el maestro

En cuanto a la estructura del texto, las descripciones tienen una longitud media de 32.3 caracteres sobre un máximo posible de cuarenta, con una mediana de 34. La Figura 3 muestra que la distribución de longitudes se acumula abruptamente contra el límite de cuarenta caracteres. Cada descripción contiene en promedio 4.9 tokens y 2.3 separadores.




Figura 3: Distribución de la longitud, cantidad de tokens y número de separadores de las descripciones del maestro

8.2. Conjunto de modelado resultante

La aplicación de los criterios de exclusión definidos en la metodología produjo el conjunto que resume el Cuadro 2. El descarte de los materiales sin categoría en la fuente eliminó 5,368 registros, y el de las clases con menos de tres ejemplos, 458 adicionales, para un conjunto final de 39,571 materiales distribuidos en 1,234 clases.

Cuadro 2: Construcción del conjunto de modelado a partir del maestro exportado

Etapas	Materiales	Clases	Criterio aplicado
Maestro exportado	45,397	—	Trece archivos por tipo de material
Con clase asignada	40,029	1,529	Se descartan 5,368 sin categoría en la fuente
Conjunto de modelado	39,571	1,234	Se descartan clases con menos de tres ejemplos
Entrenamiento	31,656	1,234	Partición estratificada, 80 %
Prueba	7,915	1,234	Partición estratificada, 20 %

8.3. Desempeño comparado de los algoritmos

El Cuadro 3 presenta los resultados de las siete configuraciones evaluadas sobre la partición de prueba, y la Figura 4 contrasta gráficamente las métricas de la primera ronda.

Cuadro 3: Resultados de la competencia de algoritmos sobre la partición de prueba de 7,915 materiales y 1,234 clases

Configuración	Exactitud	F1 macro	F1 pond.	Top-3	Tiempo (s)
LinearSVC + TF-IDF carácter	0.8491	0.7523	0.8380	0.9404	62.9
Random Forest + TF-IDF palabra	0.8334	0.7360	0.8254	0.9263	46.7
Reg. logística + TF-IDF carácter	0.8293	0.6713	0.8126	0.9359	1,071.2
Reg. logística + TF-IDF palabra	0.8291	0.6949	0.8178	0.9275	29.1
XGBoost + TF-IDF carácter	0.8145	0.6821	0.8063	0.9200	11,025.2
fastText	0.8077	0.6897	0.8001	0.9075	43.0
Transformer (MiniLM)	0.0395	0.0003	0.0050	0.0714	1,460.0

La configuración de máquina de vectores de soporte lineal sobre TF-IDF de carácter obtuvo el mejor resultado en las cuatro métricas de desempeño, con una exactitud de 0.8491 y una exactitud sobre las tres primeras sugerencias de 0.9404, y fue la seleccionada para el despliegue.

8.4. Desempeño del modelo seleccionado

La Figura 5 presenta la matriz de confusión del modelo seleccionado sobre las veinte clases de mayor volumen. La diagonal concentra la mayor parte de los casos; las clases con vocabulario propio y estable —tornillo, camisa, codo de tubería, manguera— se resuelven casi sin error, mientras que las categorías de naturaleza genérica, como *repuesto* o *herramienta*, presentan las tasas de acierto más bajas del conjunto.

El modelo cometió 1,194 errores sobre los 7,915 materiales de prueba, equivalentes al 15.09 %. El Cuadro 4 recoge las diez confusiones más frecuentes.




Figura 4: Comparación de métricas entre las configuraciones evaluadas en la primera ronda

Cuadro 4: Confusiones más frecuentes del modelo seleccionado sobre la partición de prueba

Clase real	Clase predicha	Casos
CONTACTOR:ELECT.	CONTACTO:ELECT.	7
TUBO:NO METALICO	TUBO	6
FUENTE:ALIMENTACIÓN	FUENTE ALIMENTACION	6
CARGADOR DE BATERIAS	CARGADOR:BATERIAS	6
FUSIBLE	FUSIBLE	5
INTERRUPTOR	INTERRUPTOR:AUTOMATICO	5
REPUESTO	INTERRUPTOR:AUTOMATICO	4
FUENTE ALIMENTACION	FUENTE:ALIMENTACIÓN	4
TRANSFORMADOR	TRANSFORMADOR:CORRIENTE	4
BUJE:ELECTRICO	TORNILLO	4

8.5. Exactitud y cobertura según el umbral de confianza

El Cuadro 5 y la Figura 6 presentan el comportamiento del modelo al aplicar distintos umbrales de confianza sobre la partición de prueba.

Cuadro 5: Exactitud y cobertura del modelo seleccionado según el umbral de confianza aplicado

Umbral	Exactitud	Cobertura	Materiales cubiertos
Sin umbral	0.8491	100.00 %	7,915
0.5	0.9280	78.81 %	6,238
0.6	0.9484	70.50 %	5,580
0.7	0.9674	60.52 %	4,790
0.8	0.9862	42.25 %	3,344

El panel izquierdo de la Figura 6 muestra que las predicciones correctas se concentran en la región de confianza alta mientras que las incorrectas se distribuyen hacia valores bajos. Al umbral adoptado por la plataforma, el modelo alcanza una exactitud de 0.9862 sobre el 42.25 % de los casos.




Figura 5: Matriz de confusión del modelo seleccionado sobre las veinte clases de mayor volumen




Figura 6: Distribución de la confianza del modelo y compromiso entre exactitud y cobertura según el umbral

8.6. Resultados de la operación en producción

9.1. Sobre la selección del algoritmo

El resultado más relevante de la competencia es que la configuración más simple resultó también la mejor, y por un margen consistente en las cuatro métricas de desempeño. La máquina de vectores de soporte lineal sobre una representación de caracteres superó tanto a los métodos de ensamble como a las arquitecturas basadas en aprendizaje profundo.

La diferencia en costo computacional refuerza esa conclusión. XGBoost consumió más de tres horas de entrenamiento para quedar tres puntos porcentuales por debajo del ganador, que se entrenó en poco más de un minuto; la regresión logística sobre n-gramas de carácter tardó diecisiete veces más que el ganador para un resultado también inferior. En un sistema concebido para reentrenarse periódicamente conforme el catálogo crece, esa diferencia deja de ser un detalle de laboratorio: un modelo que exige horas de cómputo para actualizarse es un modelo que en la práctica no se actualiza.

Este hallazgo es consistente con la naturaleza del problema. Las descripciones del maestro son textos cortos, altamente estructurados y con vocabulario técnico acotado; no contienen la ambigüedad sintáctica ni las dependencias de largo alcance que justifican modelos de mayor capacidad. Un clasificador lineal sobre una representación de caracteres captura precisamente el tipo de regularidad que este texto exhibe.

9.2. Sobre el efecto del desbalance de clases

Todas las configuraciones evaluadas muestran una brecha sistemática entre el F1 macro y el ponderado, de entre nueve y quince puntos según el caso. Esa brecha es la expresión cuantitativa del desbalance descrito en los resultados: los modelos aciertan considerablemente mejor sobre las clases pobladas que sobre las minoritarias, y dado que más de la mitad de las clases cuenta con diez materiales o menos, el promedio no ponderado penaliza con fuerza ese comportamiento.

Resulta significativo que el ordenamiento entre configuraciones no sea idéntico bajo ambas mé-

tricas. La regresión logística sobre n-gramas de carácter alcanza la tercera mejor exactitud pero el peor F1 macro del conjunto, lo que indica que su desempeño se concentra desproporcionadamente en las categorías frecuentes. El modelo seleccionado, en cambio, lidera ambas métricas, lo que sugiere un comportamiento más uniforme a lo largo de la taxonomía y no solo un buen resultado agregado.

9.3. Sobre el transformador que no convergió

El resultado obtenido por el transformador multilingüe no corresponde a un modelo que compite y pierde, sino a un entrenamiento que no alcanzó a converger bajo el presupuesto de cómputo disponible. Una exactitud del 3.95 % con un F1 macro prácticamente nulo indica que el modelo no llegó a diferenciar las categorías, no que la arquitectura sea inadecuada para la tarea.

La explicación más probable combina la dimensionalidad del problema —1,234 clases de salida— con un número de épocas y una configuración de ajuste fino insuficientes para adaptar un modelo preentrenado en lenguaje general a un vocabulario técnico especializado, requerimiento que la literatura documenta como característico de esta familia (Vaswani y cols., 2017). La cifra se reporta por transparencia del procedimiento, pero no admite lectura como evidencia sobre el desempeño potencial de los transformadores en esta tarea. Su evaluación adecuada requeriría un presupuesto de cómputo que excedía el alcance del proyecto, y queda planteada como línea de trabajo posterior.

9.4. Sobre la naturaleza de los errores del modelo

El examen de las confusiones más frecuentes arroja el hallazgo de mayor alcance del análisis, y trasciende el desempeño del modelo. La mayoría de esos casos no son errores de clasificación en sentido estricto, sino manifestaciones de un problema del propio catálogo: existen pares de clases que designan el mismo concepto y difieren únicamente en puntuación, acentuación o separador.

Los pares *FUENTE:ALIMENTACIÓN* y *FUENTE ALIMENTACION*, o *CARGADOR DE BATERIAS* y *CARGADOR:BATERIAS*, son clases distintas en la taxonomía pero indistinguibles en su significado. El caso más elocuente es el de *FUSIBLE* confundido consigo mismo, que solo puede corresponder a dos códigos de clase homónimos coexistiendo en el catálogo. Ninguna representación del texto puede discriminar entre categorías que son semánticamente idénticas: una fracción del error medido es irreducible mientras la taxonomía no se depure.

Esto tiene dos implicaciones. La primera es metodológica: la exactitud del 84.91 % subestima el desempeño real del modelo, ya que una parte de sus errores consiste en asignar una etiqueta correcta que la taxonomía duplica bajo otro código. La segunda es operativa: el análisis de errores del modelo constituye, por sí mismo, un instrumento de diagnóstico de la calidad del catálogo, capaz de señalar los pares de clases candidatos a fusión. La herramienta construida para clasificar materiales resultó también un mecanismo para detectar defectos en la taxonomía que los clasifica.

Las categorías genéricas constituyen el segundo foco de error. Clases como *repuesto* o *herramienta* no designan un objeto sino una función, y por lo tanto carecen de vocabulario distintivo: un repuesto puede ser cualquier cosa. Su baja tasa de acierto no refleja una deficiencia del modelo sino una debilidad de diseño de la taxonomía, que admite categorías sin contenido descriptivo.

9.5. Sobre el punto de operación seleccionado

La caracterización del compromiso entre exactitud y cobertura permite fundamentar con datos una decisión que de otro modo sería arbitraria. Al umbral adoptado, el sistema acierta en el 98.62 % de los casos que resuelve de forma automática, a cambio de derivar a revisión del gestor algo más de la mitad de las solicitudes.

Se privilegió deliberadamente la exactitud sobre la cobertura, y la justificación es de costos asimétricos: en un proceso de gobierno de datos, una categoría incorrecta que ingresa al catálogo sin revisión genera un costo persistente —distorsiona reportes de consumo, complica la planificación de compras y se propaga a todo proceso que consulte el catálogo—, mientras que una sugerencia derivada a revisión solo consume la atención del gestor, que es exactamente el escenario que la herramienta está diseñada para atender. Conviene subrayar que incluso las solicitudes derivadas a revisión conservan valor: el gestor recibe tres candidatos ordenados por probabilidad en lugar de enfrentar el catálogo completo.

La forma de la distribución de confianza respalda la validez del procedimiento. Que las predicciones correctas se concentren en la región de confianza alta y las incorrectas se dispersen hacia valores bajos es la condición que hace útil cualquier umbral; si la confianza no discriminara entre aciertos y errores, la predicción selectiva carecería de sentido.

9.6. Comparación con los antecedentes

El desempeño obtenido admite una lectura comparativa frente al antecedente más cercano identificado en la literatura. Ding y cols. (2002), clasificando descripciones de producto contra la taxonomía UNSPSC, reportaron una exactitud del 78 % en la primera predicción y del 88 % sobre las diez primeras sugerencias, discriminando entre 421 categorías.

El modelo desarrollado en este proyecto alcanza 84.91 % y 94.04 % respectivamente, sobre 1,234 categorías y con una ventana de sugerencias considerablemente más estrecha, ya que su segunda cifra se mide sobre tres opciones y no sobre diez. Debe insistirse en que ambos resultados provienen de conjuntos de datos distintos y no constituyen una comparación controlada; su valor es el de situar el desempeño obtenido dentro del orden de magnitud que la literatura reporta para esta clase de problema.

En ese marco resulta especialmente pertinente la advertencia de esos mismos autores: una exactitud en el rango del 78 al 88 por ciento iguala o supera la calidad de la clasificación humana sobre el mismo material, y perseguir cifras sensiblemente superiores implicaría sobreajustar el modelo a decisiones humanas que a su vez contienen una tasa de error no despreciable. La observación aplica de manera directa a este proyecto, cuyo conjunto de entrenamiento son precisamente las clasificaciones históricas realizadas por los gestores, con los defectos de taxonomía que el análisis de errores puso de manifiesto.

9.7. Limitaciones del estudio

Los resultados presentados deben interpretarse dentro de varias limitaciones.

La primera concierne a la evaluación del modelo. La convención de nomenclatura del catálogo hace que el término principal de la descripción coincida con frecuencia con el nombre de la clase a la que el material pertenece, de modo que una parte del desempeño observado es atribuible a esa correspondencia léxica directa. Cuantificar qué proporción del acierto depende de ella requeriría

una evaluación por ablación, eliminando el término inicial de la descripción y midiendo la caída resultante. Ese ejercicio no se realizó y queda planteado como verificación pendiente.

La segunda es que el modelo se entrena sobre etiquetas producidas por los propios gestores, que constituyen la mejor referencia disponible pero no una verdad de campo independiente. El techo de desempeño alcanzable está determinado por la consistencia de esas decisiones históricas.

La tercera se refiere al alcance de la validación. El período de uso productivo abarca cinco semanas y una sola unidad de negocio, frente a una línea base levantada durante cuatro meses. La asimetría entre ambos períodos y el tamaño de la muestra acumulada aconsejan tratar las cifras de la operación como indicativas de una tendencia y no como estimaciones de precisión estadística.

Finalmente, los resultados de clasificación se obtuvieron sobre una fotografía del catálogo correspondiente a una fecha determinada. El desempeño del modelo sobre materiales de familias que no estaban representadas en esa extracción no puede inferirse de las mediciones presentadas.

CAPÍTULO 10

Conclusiones

CAPÍTULO 11

Recomendaciones

Referencias

- Albayrak, O. S., Aytekin, T., y Kalaycı, T. A. (2022). Duplicate product record detection engine for e-commerce platforms. *Expert Systems with Applications*, 193, 116420. doi: 10.1016/j.eswa.2021.116420
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi: 10.1023/A:1010933404324
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... Amodei, D. (2020). Language models are few-shot learners. En *Advances in neural information processing systems* (Vol. 33, pp. 1877–1901).
- Cavnar, W. B., y Trenkle, J. M. (1994). N-gram-based text categorization. En *Proceedings of the 3rd annual symposium on document analysis and information retrieval (SDAIR-94)* (pp. 161–175). Las Vegas, NV.
- Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 785–794). ACM. doi: 10.1145/2939672.2939785
- Cheng, Z., Zhang, W., Chou, C.-C., Jau, Y.-Y., Pathak, A., Gao, P., y Batur, U. (2024). E-commerce product categorization with LLM-based dual-expert classification paradigm. En *Proceedings of the 1st workshop on customizable NLP (CustomNLP4U)* (pp. 294–304). Association for Computational Linguistics. doi: 10.18653/v1/2024.customnlp4u-1.22
- Chow, C. K. (1970). On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1), 41–46. doi: 10.1109/TIT.1970.1054406
- Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. doi: 10.1007/BF00994018
- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society: Series B (Methodological)*, 20(2), 215–232. doi: 10.1111/j.2517-6161.1958.tb00292.x
- DAMA International. (2017). *DAMA-DMBOK: Data management body of knowledge* (2nd ed.). Basking Ridge, NJ: Technics Publications.
- Databricks. (s.f.). *What is the medallion lakehouse architecture?* Descargado agosto de 2026, de <https://docs.databricks.com/aws/en/lakehouse/medallion>
- Ding, Y., Korotkiy, M., Omelayenko, B., Kartseva, V., Zykov, V., Klein, M., ... Fensel, D. (2002). GoldenBullet: Automated classification of product data in e-commerce. En W. Abramowicz (Ed.), *Business information systems: Proceedings of BIS 2002*. Poznań, Polonia.
- Elmagarmid, A. K., Ipeirotis, P. G., y Verykios, V. S. (2007). Duplicate record detection: A survey. *IEEE Transactions on Knowledge and Data Engineering*, 19(1), 1–16. doi: 10.1109/TKDE.2007.250581
- Ernst & Young. (s.f.). *Case study: Transforming MRO material master data*. Descargado agosto de 2026, de https://www.ey.com/en_us/insights/energy-resources/oil-gas/transforming-mro-material-master-data-case-study
- Gravano, L., Ipeirotis, P. G., Jagadish, H. V., Koudas, N., Muthukrishnan, S., y Srivastava, D. (2001). Approximate string joins in a database (almost) for free. En *Proceedings of the 27th international conference on very large data bases (VLDB)* (pp. 491–500).
- He, H., y Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. doi: 10.1109/TKDE.2008.239
- International Organization for Standardization. (2010). *Industrial automation systems and integration — Open technical dictionaries and their application to master data — Part 1: Overview and fundamental principles (ISO 22745-1:2010)*. Ginebra, Suiza: ISO. Descargado de <https://www.iso.org/standard/53995.html>
- International Organization for Standardization. (2021). *Data quality — Part 110: Master data: Exchange of characteristic data: Syntax, semantic encoding, and conformance to data specification (ISO 8000-110:2021)*. Ginebra, Suiza: ISO. Descargado de <https://www.iso.org/standard/78501.html>
- Joulin, A., Grave, E., Bojanowski, P., y Mikolov, T. (2017). Bag of tricks for efficient text classification. En *Proceedings of the 15th conference of the European Chapter of the Association for*

- Computational Linguistics* (Vol. 2, pp. 427–431). Association for Computational Linguistics. doi: 10.18653/v1/E17-2068
- Kimball, R., y Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). Indianapolis, IN: John Wiley & Sons.
- Laney, D. B. (2018). *Infonomics: How to monetize, manage, and measure information as an asset for competitive advantage*. Nueva York, NY: Routledge.
- Loshin, D. (2009). *Master data management*. Burlington, MA: Morgan Kaufmann.
- Narayan, A., Chami, I., Orr, L., y Ré, C. (2022). Can foundation models wrangle your data? *Proceedings of the VLDB Endowment*, 16(4), 738–746. doi: 10.14778/3574245.3574258
- Platt, J. C. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. En A. J. Smola, P. Bartlett, B. Schölkopf, y D. Schuurmans (Eds.), *Advances in large margin classifiers* (pp. 61–74). Cambridge, MA: MIT Press.
- PostgreSQL Global Development Group. (2023). *pg_trgm: Support for similarity of text using trigram matching*. PostgreSQL 16 Documentation. Descargado agosto de 2026, de <https://www.postgresql.org/docs/16/pgtrgm.html>
- Redman, T. C. (1998). The impact of poor data quality on the typical enterprise. *Communications of the ACM*, 41(2), 79–82. doi: 10.1145/269012.269025
- Salton, G., y Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. doi: 10.1016/0306-4573(88)90021-0
- SAP SE. (s.f.). *SAP Master Data Governance*. SAP Help Portal. Descargado agosto de 2026, de https://help.sap.com/docs/SAP_MASTER_DATA_GOVERNANCE
- Sebastiani, F. (2002). Machine learning in automated text categorization. *ACM Computing Surveys*, 34(1), 1–47. doi: 10.1145/505282.505283
- Sokolova, M., y Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. doi: 10.1016/j.ipm.2009.03.002
- United Nations Development Programme. (2023). *United Nations Standard Products and Services Code (UNSPSC)*. Descargado agosto de 2026, de <https://www.undp.org/unspsc>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. En *Advances in neural information processing systems* (Vol. 30, pp. 5998–6008).
- Verdantis. (s.f.). *Materials master data management*. Descargado agosto de 2026, de <https://www.verdantis.com/materials-master-data-management/>
- Wang, R. Y., y Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5–33. doi: 10.1080/07421222.1996.11518099
- Wirth, R., y Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining* (pp. 29–40). Manchester, Reino Unido.
- Zadrozny, B., y Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. En *Proceedings of the 8th ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 694–699). ACM. doi: 10.1145/775047.775151
- Zaharia, M., Ghodsi, A., Xin, R., y Armbrust, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. En *Proceedings of the 11th conference on innovative data systems research (CIDR)*.

ANEXO A

xxx
