
GAMMA: Plataforma de Gobernanza Automatizada de Datos Maestros de Materiales mediante Machine Learning

Alejandra Alvarado, Erick Marroquín, Rudy Osorio



UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de BRIDGE Business School



**GAMMA: Plataforma de Gobernanza Automatizada
de Datos Maestros de Materiales mediante Machine
Learning**

Trabajo de graduación en modalidad de proyecto integrador presentado
por
Alejandra Alvarado, Erick Marroquín, Rudy Osorio
Para optar al grado académico de Master In Business Intelligence and
Analytics

Guatemala, Agosto del 2026

Vo.Bo.:

(f) _____
Ing. Horacio Recinos

Tribunal Examinador:

(f) _____
Ing. Horacio Recinos

(f) _____
Ing. Sergio Molina

Fecha de aprobación: Guatemala, 21 de septiembre 2026.

Este trabajo nace de un problema que el equipo enfrentaba de manera cotidiana en su propio entorno de trabajo: la creación de materiales en SAP consumía tiempo valioso en tareas de verificación que, en principio, podían automatizarse. Lo que comenzó como una limitante operativa se convirtió en la oportunidad de aplicar, sobre un problema real y medible, las herramientas de inteligencia de negocios y ciencia de datos adquiridas a lo largo de la maestría.

Uno de los retos particulares de este trabajo fue mantener el equilibrio entre la confidencialidad de la información utilizada y el rigor académico exigido. La organización donde se desarrolló e implementó el proyecto autorizó el uso de su información bajo la condición de que no se revelara su identidad; por esa razón, a lo largo de este documento se hace referencia a ella de forma genérica, y se omiten los nombres de las personas involucradas en el proceso operativo.

Una limitación reconocida es el alcance acotado del proyecto: los resultados presentados corresponden a una única unidad de negocio y a un período de validación de cinco semanas, por lo que deben interpretarse dentro de ese contexto y no como una generalización automática a otros entornos.

Conviene señalar, finalmente, que el proyecto no fue un ejercicio teórico. El sistema construido estuvo en uso activo por parte de los gestores de la organización durante ese período, operando sobre datos reales del maestro de materiales. Las cifras de desempeño que se presentan más adelante provienen de esa operación y no de un entorno de prueba.

Agradecimientos

Al Ing. Horacio Recinos e Ing. Sergio Molina, asesores de este trabajo de graduación, por su acompañamiento y orientación a lo largo de las distintas fases del proyecto.

A los miembros de la terna examinadora, Ing. Horacio Recinos e Ing. Sergio Molina, por el tiempo dedicado a la revisión y evaluación de este trabajo.

Al equipo de gestores de datos maestros y a la jefatura del área donde se desarrolló e implementó el proyecto, por abrir el espacio para validar GAMMA con datos y usuarios reales, y por la retroalimentación brindada durante el período de pruebas.

Prefacio	III
Agradecimientos	IV
Lista de Figuras	VIII
Lista de Cuadros	IX
Resumen	X
1. Introducción	1
2. Objetivos	3
2.1. Objetivo General	3
2.2. Objetivos Específicos	3
3. Justificación	5
4. Marco Teórico	6
4.1. Gobierno de datos maestros	6
4.1.1. Dimensiones de calidad del dato maestro	6
4.1.2. Impacto económico de la mala calidad de datos	7
4.1.3. Estándares para la descripción de datos maestros de materiales	7
4.2. Inteligencia de negocios y medición del desempeño del proceso	7
4.2.1. Modelado dimensional	8
4.2.2. Indicadores clave de desempeño	8
4.2.3. Valoración económica de la información	8
4.3. Metodología para proyectos de analítica	8
4.4. Arquitectura de datos por capas (medallón)	9
4.5. Procesamiento de lenguaje natural para normalización de texto	9
4.5.1. Enfoques basados en reglas y basados en modelos de lenguaje	9
4.5.2. La arquitectura Transformer	9
4.5.3. Modelos de lenguaje aplicados a tareas de preparación de datos	10
4.6. Detección de duplicados y resolución de entidades	10
4.6.1. El problema de la detección de duplicados	10
4.6.2. Similitud por q-gramas y trigramas	10
4.6.3. Umbral de similitud y compromiso entre exhaustividad y precisión	11
4.7. Representación vectorial de texto	11

4.7.1.	TF-IDF	11
4.7.2.	N-gramas de carácter	11
4.8.	Algoritmos de clasificación supervisada evaluados	12
4.8.1.	Regresión logística	12
4.8.2.	Máquinas de vectores de soporte (SVM lineal)	12
4.8.3.	Random Forest	12
4.8.4.	XGBoost	12
4.8.5.	fastText	12
4.8.6.	Transformer (embeddings contextuales)	13
4.9.	Evaluación de clasificadores multiclase	13
4.9.1.	Métricas y esquemas de promediado	13
4.9.2.	Exactitud top-k	13
4.9.3.	Desbalance de clases	13
4.9.4.	Protocolo de validación	14
4.10.	Calibración de probabilidades y predicción selectiva	14
4.10.1.	Calibración de probabilidades	14
4.10.2.	Clasificación con opción de rechazo	14
5.	Antecedentes	15
6.	Alcance	17
7.	Metodología	19
7.1.	Enfoque metodológico	19
7.2.	Materiales	19
7.2.1.	Fuentes de información	19
7.2.2.	Recursos tecnológicos	20
7.3.	Integración de la información	20
7.3.1.	Arquitectura implementada	20
7.3.2.	Proceso de ingesta	20
7.4.	Preparación de los datos	21
7.4.1.	Preprocesamiento de texto	21
7.4.2.	Criterios de construcción del conjunto de modelado	21
7.5.	Métodos analíticos	21
7.5.1.	Normalización de descripciones mediante modelo de lenguaje	21
7.5.2.	Detección de duplicados	22
7.5.3.	Diseño de la evaluación de algoritmos de clasificación	22
7.6.	Arquitectura tecnológica e implementación	23
7.6.1.	Componentes y despliegue	23
7.6.2.	Ciclo de vida de una solicitud	23
7.7.	Instrumentación y medición	24
7.8.	Protocolo de validación en producción	24
7.8.1.	Medición de la línea base	24
7.8.2.	Plan de adopción cultural	25
7.8.3.	Encuesta de satisfacción	25
8.	Análisis Exploratorio de Datos	26
8.1.	Caracterización del maestro de materiales	26
8.2.	Calidad de la información	28

9. Resultados	30
9.1. Conjunto de modelado resultante	30
9.2. Desempeño comparado de los algoritmos	30
9.3. Desempeño del modelo seleccionado	31
9.4. Exactitud y cobertura según el umbral de confianza	31
9.5. Resultados de la operación en producción	33
9.5.1. Tiempo de gestión	33
9.5.2. Duplicados evitados	34
9.5.3. Desglose del tiempo de proceso	34
9.5.4. Percepción de los usuarios	35
9.5.5. Impacto financiero	35
9.6. Visualización de resultados	36
9.6.1. Por qué Power BI	36
9.6.2. Tablero operativo	36
10. Discusión	39
10.1. Selección del algoritmo	39
10.2. Efecto del desbalance de clases	39
10.3. Desempeño del transformador	40
10.4. Naturaleza de los errores del modelo	40
10.5. Punto de operación seleccionado	41
10.6. Comparación con los antecedentes	41
10.7. Percepción de los usuarios	42
10.8. Retorno de inversión	42
10.9. Limitaciones del estudio	43
11. Conclusiones	44
12. Recomendaciones	46
Referencias	48
Anexos	51
A. Registro de asistencia	51
B. Instrumento y respuestas de la encuesta de satisfacción	52
C. Descriptor del sistema y accesos para revisión	63
Glosario	66

Lista de Figuras

1.	Cantidad de materiales aportados por cada archivo de exportación del maestro	26
2.	Veinte clases con mayor cantidad de materiales en el maestro	27
3.	Distribución de la longitud, cantidad de tokens y número de separadores de las descripciones del maestro	27
4.	Distribución de registros por tipo de material, catálogo completo (corte 29 mayo 2026) .	28
5.	Duplicados exactos por tipo de material, en número absoluto y como porcentaje del total	28
6.	Mapa de calidad del catálogo: duplicados, materiales bloqueados, descripciones sin separador estándar y registros sin clase, por tipo de material	29
7.	Longitud promedio del texto breve por tipo de material	29
8.	Comparación de métricas entre las configuraciones evaluadas en la primera ronda	31
9.	Matriz de confusión del modelo seleccionado sobre las veinte clases de mayor volumen .	32
10.	Distribución de la confianza del modelo y compromiso entre exactitud y cobertura según el umbral	33
11.	Percepción promedio de los gestores sobre GAMMA en la encuesta de satisfacción (n=3)	35
12.	Portada del formulario de encuesta	53
13.	Pregunta de bifurcación según uso de GAMMA	54
14.	Sección de experiencia de uso (parte 1)	55
15.	Sección de experiencia de uso (parte 2)	56
16.	Preguntas sobre reducción de tiempo y valor percibido	57
17.	Preguntas de errores encontrados y satisfacción general	58
18.	Sección de adopción y continuidad (información sensible cubierta)	59
19.	Pregunta abierta de mejoras	59
20.	Sección de percepción y expectativas para no usuarios	60
21.	Pregunta de beneficios percibidos por no usuarios	60
22.	Sección dirigida a jefatura y coordinación	61
23.	Condiciones para permanencia y comentarios adicionales (información sensible cubierta)	62

Lista de Cuadros

1.	Plan de adopción cultural ejecutado durante el período de validación	25
2.	Distribución de las clases del maestro según su cantidad de materiales	27
3.	Construcción del conjunto de modelado a partir del maestro exportado	30
4.	Resultados de la competencia de algoritmos sobre la partición de prueba de 7,915 materiales y 1,234 clases	31
5.	Confusiones más frecuentes del modelo seleccionado sobre la partición de prueba	32
6.	Exactitud y cobertura del modelo seleccionado según el umbral de confianza aplicado .	33
7.	Tiempo efectivo de gestión antes y después de GAMMA	33
8.	Desglose del tiempo de máquina por paso del proceso	34
9.	Retorno de inversión del proyecto	36
10.	Asistencia registrada por rol en las sesiones de capacitación y seguimiento	51
11.	Respuestas de los gestores que utilizaron GAMMA	52
12.	Respuestas de jefatura y coordinación	53
13.	Secciones de la plataforma habilitadas según el perfil de acceso	64
14.	Credenciales dispuestas para el tribunal examinador	64

GAMMA (Gobierno Automatizado del Maestro de Materiales) es una plataforma de asistencia inteligente que automatiza la normalización, detección de duplicados y clasificación de categoría en el flujo de creación de materiales sobre SAP, desarrollada para una unidad de negocio del sector energético con presencia en varios países de Centroamérica y el Caribe. El proyecto surge de un catálogo con 45,397 materiales distribuidos en un máximo de 1,538 categorías posibles, donde la ausencia de herramientas analíticas obligaba al gestor a validar manualmente cada solicitud, con un tiempo de gestión promedio de 3.3 horas por solicitud.

La plataforma integra tres módulos: un modelo de lenguaje para normalizar descripciones de texto libre, un motor de similitud difusa sobre PostgreSQL para detectar duplicados, y un clasificador supervisado —seleccionado tras evaluar comparativamente siete configuraciones— para sugerir la categoría correcta. El modelo ganador, una máquina de vectores de soporte lineal sobre representación de n-gramas de carácter, alcanzó una exactitud de 84.9,

La herramienta se validó en producción con el equipo de gestores entre el 18 de junio y el 21 de julio de 2026. La comparación contra la línea base mostró una reducción del tiempo de gestión de 58.4,

La gestión de datos maestros de materiales es un proceso crítico para cualquier organización que opera sobre SAP, ya que la calidad de este catálogo incide directamente en procesos como la ejecución de órdenes de compra, el cierre de inventarios y la trazabilidad de activos. El presente proyecto se desarrolla sobre el módulo de materiales en SAP de una unidad de negocio del sector energético que opera en varios países de Centroamérica y el Caribe, donde un equipo de gestores de datos maestros es responsable de validar que cada material nuevo no exista ya en el sistema, que esté correctamente categorizado y que cumpla con las especificaciones mínimas exigidas por la normativa ISO 8000.

En la práctica, este proceso presenta tres problemas recurrentes que se identificaron y cuantificaron mediante un análisis exploratorio sobre el catálogo completo de la unidad de negocio, que al corte empleado reúne 43,177 registros distribuidos en once tipos de material:

1. **Materiales duplicados.** Se identificaron 2,089 registros con duplicidad exacta en el texto breve, equivalentes al 4.8 % del catálogo, con tipos de material en los que la proporción supera el 35 %. A ello se suma un riesgo de duplicidad no detectable por búsqueda exacta: 3,649 registros —el 8.5 % del catálogo— no siguen la convención de separadores, lo que los vuelve indistinguibles de otros similares. El origen de ambos problemas es común: descripciones libres, abreviaciones inconsistentes entre gestores y el límite de 40 caracteres que impone SAP para el campo de descripción corta.
2. **Categorización incorrecta.** Existen materiales asignados a una categoría que no corresponde a su naturaleza real. El caso verificado con mayor claridad es el de 94 repuestos creados bajo la categoría de “suministros”, lo que distorsiona los reportes de consumo y dificulta la planificación de compras por tipo de material.
3. **Tiempo de gestión elevado.** Con un volumen promedio de 4.0 solicitudes de creación individual por día hábil (medido entre el 15 de febrero y el 17 de junio de 2026, período previo a la implementación), cada gestión permanece en promedio 3.3 horas dentro del rol del gestor —tiempo que incluye cola de trabajo, validaciones y los distintos pasos del proceso—. De ese tiempo, la búsqueda manual en SAP para descartar duplicados y verificar especificaciones —el paso que GAMMA automatiza directamente— consume entre 5 y 10 minutos por solicitud.

Estos hallazgos evidencian que el problema no es la falta de un proceso de gestión de datos maestros —la organización ya cuenta con uno—, sino la ausencia de herramientas analíticas que

apoyen al gestor en el momento de la decisión: al crear un material, no existe hoy ningún mecanismo automatizado que le indique si ese material ya existe, ni qué categoría le corresponde con base en el histórico del catálogo.

Para atender esta necesidad se desarrolló GAMMA (Gobierno Automatizado del Maestro de Materiales), un asistente inteligente que integra tres módulos complementarios: normalización de descripciones mediante un modelo de lenguaje, detección de duplicados por similitud difusa sobre el catálogo, y clasificación automática de categoría mediante un modelo de aprendizaje supervisado entrenado sobre el histórico del catálogo. El proyecto abarca el ciclo de vida completo de un proyecto de analítica: desde el análisis exploratorio de los datos de origen, pasando por la integración y modelado, hasta el despliegue de una herramienta funcional validada por el propio equipo de gestores.

El presente documento describe la metodología seguida en cada una de estas etapas (análisis de fuentes de información, integración de datos, explotación de la información, desarrollo de modelos analíticos, visualización de resultados y arquitectura de puesta en producción), así como los resultados obtenidos y su impacto en la operación, tanto a nivel de eficiencia operativa como de retorno financiero.

2.1. Objetivo General

Desarrollar GAMMA (Gobierno Automatizado del Maestro de Materiales), una plataforma de asistencia analítica para el flujo de creación individual de materiales en SAP, mediante la articulación de procesamiento de lenguaje natural, búsqueda por similitud difusa y aprendizaje automático supervisado sobre el histórico del catálogo, para reducir el tiempo de gestión y mejorar la calidad del maestro de materiales de una unidad de negocio del sector energético con operación en Centroamérica y el Caribe.

2.2. Objetivos Específicos

1. Implementar un pipeline de integración del maestro de materiales de SAP mediante una arquitectura medallón sobre PostgreSQL, para consolidar en un repositorio único, normalizado y trazable los registros dispersos en trece archivos de exportación que constituyen el insumo de los módulos analíticos.
2. Analizar los defectos de calidad acumulados en el catálogo mediante la aplicación retroactiva de los motores de similitud difusa y de clasificación sobre los registros existentes, para cuantificar el volumen de duplicados y de errores de categorización que arrastra la operación y establecer la línea base contra la cual medir la mejora.
3. Seleccionar el algoritmo de clasificación de categoría mediante la evaluación comparativa de siete configuraciones sobre una partición estratificada del histórico del catálogo, para adoptar el que maximice la exactitud dentro de un costo de reentrenamiento sostenible en la operación.
4. Construir una plataforma web de asistencia conversacional que articule la normalización de descripciones, la detección de duplicados y la sugerencia de categoría dentro del flujo de creación individual de materiales, para asistir al gestor en el momento de la decisión conservando la validación humana antes del registro en SAP.
5. Evaluar el efecto de la herramienta sobre el proceso de creación de materiales mediante la comparación de los tiempos de gestión y las tasas de error registrados antes y después de su

implementación, para determinar el ahorro en horas-gestor y el retorno de la inversión del proyecto.

El costo del proceso actual de gestión de materiales no se limita al tiempo que invierte el equipo de gestores: se traslada a toda la cadena de procesos que depende de que un material quede correctamente registrado en el sistema. Mientras una solicitud permanece en gestión (en promedio 3.3 horas dentro del rol del gestor, sobre un volumen de 4.0 solicitudes diarias), los procesos que suceden, como la emisión de una orden de compra o la ejecución de una tarea de mantenimiento, quedan detenidos. Reducir ese tiempo no mejora únicamente la productividad del gestor: mejora la velocidad de respuesta de la organización.

El impacto se agrava cuando el resultado de la gestión no es correcto. Un catálogo que ya arrastra 2,089 duplicados exactos, otros 3,649 registros sin la estructura que permitiría detectarlos por búsqueda exacta y materiales asignados a categorías que no corresponden a su naturaleza, no solo es un problema de orden interno: distorsiona los reportes de consumo, complica la planificación de compras por tipo de material y reduce la trazabilidad de los activos para cualquier área que consulte esa información después. Cada día que el proceso continúa sin apoyo analítico, el catálogo acumula más inconsistencias, y el costo de corregirlas retroactivamente crece.

Atender este problema requiere visibilidad sobre cómo se está comportando el proceso hoy, y una forma de intervenir directamente en el momento en que ocurre el error. Un tablero que solo reporte el problema, sin cambiar la forma en que se crea el material, no resuelve la causa; y automatizar la creación sin poder medir su efecto no permite sostener la mejora en el tiempo. De ahí que la solución combine ambas capas: un modelo que asiste al gestor en el instante de la decisión, y un mecanismo de medición que permite verificar, con datos, si esa asistencia efectivamente está reduciendo el tiempo de gestión y mejorando la calidad del catálogo.

La información necesaria para construir y validar esta solución es de acceso directo dentro de la unidad de negocio, y la infraestructura tecnológica requerida se apoya íntegramente en herramientas de código abierto, lo que hace sostenible su operación más allá del período de desarrollo, sin inversión adicional significativa en licenciamiento.

Finalmente, el proyecto se justifica también en términos financieros: la reducción del tiempo de gestión y la prevención de duplicados se traduce en un ahorro cuantificable de horas-gestor, cifra que se desarrolla en detalle en la sección de Resultados de este documento.

4.1. Gobierno de datos maestros

El gobierno de datos maestros (*Master Data Management*, MDM) es la disciplina encargada de asegurar que las entidades centrales de una organización —clientes, proveedores, materiales, entre otras— se mantengan consistentes, correctas y libres de duplicidad a través de los distintos sistemas que las consumen. DAMA International (2017) ubica el MDM como una de las áreas funcionales del gobierno de datos, y lo define como el conjunto de procesos que permiten mantener una versión autorizada y compartida de las entidades de negocio críticas. A diferencia de los datos transaccionales, que registran hechos puntuales, los datos maestros describen objetos persistentes que son referenciados por múltiples procesos a lo largo del tiempo; esa persistencia es precisamente lo que hace que un error introducido en el momento de la creación se propague y se vuelva costoso de revertir.

4.1.1. Dimensiones de calidad del dato maestro

La calidad de los datos no es un atributo único sino un constructo multidimensional. Wang y Strong (1996) establecieron, a partir de un estudio empírico con consumidores de datos, un marco jerárquico que organiza la calidad en cuatro categorías —intrínseca, contextual, de representación y de accesibilidad— y demostraron que los usuarios manejan una concepción de calidad considerablemente más amplia que la de exactitud, que era la dimensión dominante en la literatura previa. Su distinción entre calidad intrínseca (el dato es correcto en sí mismo) y calidad contextual (el dato es adecuado para la tarea en que se usa) es especialmente pertinente en un catálogo de materiales, donde una descripción puede ser literalmente cierta y aun así resultar inservible para quien necesita distinguir dos repuestos similares.

Aplicando este marco al dato maestro específicamente, Loshin (2009) señala que su calidad se mide típicamente en tres dimensiones operativas: *unicidad* (ausencia de registros duplicados), *exactitud* (que los atributos del registro describan correctamente el objeto real) y *completitud* (que los campos obligatorios estén correctamente llenados). Estas tres dimensiones son las que estructuran el diagnóstico y la intervención del presente proyecto: el módulo de detección de duplicados atiende la unicidad, el módulo de clasificación atiende la exactitud, y el módulo de normalización atiende la completitud y la consistencia de representación.

4.1.2. Impacto económico de la mala calidad de datos

El deterioro de cualquiera de estas dimensiones tiene un efecto en cascada sobre los procesos que dependen del catálogo, como la planificación de compras, el control de inventario y el mantenimiento de activos. Redman (1998) documentó que los efectos de la mala calidad de datos en una empresa típica no se limitan al costo directo de corregir los registros, sino que incluyen incremento del costo operativo, decisiones menos efectivas, deterioro de la capacidad de ejecutar la estrategia y erosión de la confianza organizacional en los sistemas de información. Esta distinción entre el costo visible de la corrección y el costo difuso de operar sobre datos defectuosos es la base conceptual sobre la que se construye la justificación financiera del presente trabajo: el ahorro atribuible a una herramienta de gobierno de datos proviene tanto del tiempo de gestión que evita como de los errores que impide introducir en primer lugar.

4.1.3. Estándares para la descripción de datos maestros de materiales

La descripción de un material en un catálogo industrial no es texto libre arbitrario: existen estándares internacionales que definen cómo debe estructurarse para que sea inequívoca y portable entre organizaciones y sistemas.

La norma *ISO 8000* constituye la familia de estándares internacionales de calidad de datos, con varias partes dedicadas específicamente al dato maestro. En particular, la norma *ISO 8000-110* especifica los requisitos para el intercambio de datos característicos de datos maestros en cuanto a sintaxis, codificación semántica y conformidad con una especificación de datos (International Organization for Standardization, 2021). El principio central es que un dato de calidad debe ser *portable*: su significado debe estar codificado de forma explícita y no depender del sistema o de la convención interna de quien lo creó.

Complementariamente, la serie *ISO 22745* define los diccionarios técnicos abiertos (*Open Technical Dictionary*, OTD) y su aplicación a los datos maestros (International Organization for Standardization, 2010). Bajo este enfoque, un material se describe mediante un identificador de concepto —el sustantivo o término principal que designa la clase de objeto— acompañado de un conjunto de pares propiedad-valor que lo especifican. Esta convención, conocida en la práctica de catalogación industrial como formato *sustantivo-modificador* (*noun-modifier*), es la que subyace al estándar corporativo empleado en la unidad de negocio de este proyecto, donde las descripciones siguen una estructura de término principal seguido de modificadores delimitados por separadores. La normalización automática que realiza GAMMA consiste, en esencia, en llevar una descripción propuesta en lenguaje libre por el gestor a esta forma estructurada.

Finalmente, para la clasificación de los materiales existe el *United Nations Standard Products and Services Code* (UNSPSC), una taxonomía abierta y multisectorial de productos y servicios administrada por el Programa de las Naciones Unidas para el Desarrollo, organizada en una jerarquía de cuatro niveles —segmento, familia, clase y comodidad— codificada como un número de ocho dígitos (United Nations Development Programme, 2023). El catálogo de la unidad de negocio mantiene una correspondencia entre sus clases internas de material y los códigos UNSPSC, lo que permite anclar la taxonomía propia a un referente externo estandarizado.

4.2. Inteligencia de negocios y medición del desempeño del proceso

Una intervención sobre un proceso operativo solo puede sostenerse en el tiempo si existe un mecanismo para medir su efecto. La inteligencia de negocios (*Business Intelligence*, BI) aporta ese

componente: el conjunto de arquitecturas, modelos y herramientas que transforman datos operativos en indicadores que soportan la decisión gerencial.

4.2.1. Modelado dimensional

Kimball y Ross (2013) establecieron el modelado dimensional como el patrón de diseño predominante para estructurar datos orientados al análisis. Su propuesta organiza la información en tablas de hechos —que registran las mediciones numéricas de un proceso de negocio, con una granularidad explícitamente declarada— y tablas de dimensión —que contienen los atributos descriptivos por los que esas mediciones se filtran y agrupan. La ventaja de este esquema, conocido como *estrella*, frente a un modelo normalizado, es que privilegia la comprensibilidad para el usuario de negocio y el desempeño de consulta por encima de la ausencia de redundancia. En el presente proyecto, este patrón orienta el diseño de la capa de consumo, donde cada solicitud de creación de material constituye el grano de la medición y los atributos de gestor, tipo de material y período conforman las dimensiones de análisis.

4.2.2. Indicadores clave de desempeño

Un indicador clave de desempeño (*Key Performance Indicator*, KPI) es una medida cuantificable, asociada a un objetivo declarado, que permite evaluar si un proceso avanza en la dirección esperada. Kimball y Ross (2013) advierten que la utilidad de un indicador depende críticamente de que su definición —numerador, denominador, granularidad temporal y población incluida— esté documentada de forma no ambigua, ya que una misma métrica calculada bajo criterios distintos produce cifras irreconciliables entre áreas. Esta consideración es la que motiva, en este trabajo, la definición explícita de la población de medición y la exclusión sistemática del tráfico de pruebas del cálculo de los indicadores.

4.2.3. Valoración económica de la información

Laney (2018) propone bajo el término *infonomics* la tesis de que la información debe tratarse como un activo económico formal, sujeto a valoración, gestión y monetización con el mismo rigor que se aplica a los activos físicos. El autor distingue entre la monetización directa —vender o intercambiar información— y la indirecta, que consiste en aprovechar la información para reducir costos, mitigar riesgos o mejorar la eficiencia de un proceso interno. Es esta segunda modalidad la que corresponde al presente proyecto: el valor generado no proviene de comercializar el catálogo de materiales, sino de que un catálogo de mayor calidad reduce el tiempo de gestión y evita los costos aguas abajo asociados a registros duplicados o mal clasificados.

4.3. Metodología para proyectos de analítica

El desarrollo de un proyecto de analítica requiere un marco de proceso que ordene sus fases y haga explícita la naturaleza iterativa del trabajo. Wirth y Hipp (2000) formalizaron el modelo *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), concebido como un proceso de referencia independiente tanto del sector industrial como de la tecnología empleada. El modelo organiza el trabajo en seis fases —comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue— y establece que la secuencia entre ellas no es estrictamente lineal: los hallazgos de una fase posterior frecuentemente obligan a revisar decisiones tomadas en una anterior. CRISP-DM continúa siendo el modelo de proceso de referencia más extendido para

proyectos de minería de datos y ciencia de datos aplicada, y es el que estructura la metodología seguida en este trabajo.

4.4. Arquitectura de datos por capas (medallón)

La arquitectura medallón es un patrón de diseño para *pipelines* de datos que organiza el flujo de información en capas sucesivas de refinamiento, denominadas Bronce, Plata y Oro (Databricks, s.f.). La capa Bronce conserva el dato tal como llega de la fuente original, sin transformaciones. La capa Plata aplica limpieza, normalización y validaciones de calidad. La capa Oro contiene datos ya agregados o modelados específicamente para su consumo final, ya sea por un tablero de indicadores, un modelo analítico o una aplicación. Este patrón permite reprocesar el pipeline completo ante un error sin perder el dato original, y desacopla la lógica de transformación de la lógica de consumo.

Este esquema por capas se inscribe en la propuesta arquitectónica del *lakehouse*, formulada por Zaharia, Ghodsi, Xin, y Armbrust (2021), que busca unificar en una sola plataforma las capacidades de gestión y confiabilidad propias del almacén de datos con la flexibilidad y el soporte a cargas de ciencia de datos característicos del lago de datos. Los autores argumentan que la separación tradicional entre ambos entornos genera problemas de obsolescencia del dato, duplicación de almacenamiento y costo total de propiedad, y que una arquitectura de capas sobre formatos abiertos con garantías transaccionales resuelve simultáneamente los requerimientos de reportería y de modelado analítico. En el presente proyecto este patrón se implementa sobre un motor relacional, aprovechando que el volumen del catálogo permite prescindir de una plataforma distribuida sin sacrificar la separación lógica entre capas.

4.5. Procesamiento de lenguaje natural para normalización de texto

Las descripciones de materiales en un catálogo industrial constituyen un tipo particular de texto: breve, técnico, con alta densidad de abreviaturas y sin una gramática formal. Se trata además de texto sujeto a una restricción estructural fuerte, ya que los sistemas ERP imponen un límite estricto de caracteres al campo de descripción corta, lo que induce a los gestores a abreviar de formas idiosincráticas y no documentadas.

4.5.1. Enfoques basados en reglas y basados en modelos de lenguaje

El procesamiento de lenguaje natural (*Natural Language Processing*, NLP) ofrece dos familias de enfoques para trabajar con este tipo de texto: una basada en reglas y diccionarios de abreviatura, precisa pero de mantenimiento manual constante y de cobertura limitada al vocabulario previamente registrado; y otra basada en modelos de lenguaje de gran escala (*Large Language Models*, LLM), que aprovecha el conocimiento general del lenguaje adquirido durante el entrenamiento para inferir la forma estándar de un término técnico sin necesidad de un diccionario exhaustivo.

4.5.2. La arquitectura Transformer

Los LLM actuales se construyen sobre la arquitectura *Transformer*, introducida por Vaswani y cols. (2017), que reemplazó los mecanismos recurrentes por un mecanismo de atención capaz de ponderar la relevancia de cada palabra de una secuencia respecto a las demás. Esta arquitectura

permite procesar la secuencia completa en paralelo y capturar dependencias entre términos distantes, lo que resultó determinante para el escalamiento de los modelos de lenguaje a los tamaños actuales.

4.5.3. Modelos de lenguaje aplicados a tareas de preparación de datos

Brown y cols. (2020) demostraron que, a partir de cierta escala, los modelos de lenguaje adquieren la capacidad de resolver tareas nuevas a partir de unas pocas demostraciones incluidas en la propia instrucción (*few-shot learning*), sin necesidad de reentrenamiento ni de ajuste de parámetros. Esta propiedad es la que hace viable aplicar un LLM a la normalización de descripciones sin construir un conjunto de entrenamiento etiquetado específico para la tarea.

La pertinencia de este enfoque para problemas de datos ha sido evaluada de forma sistemática. Narayan, Chami, Orr, y Ré (2022) formularon cinco tareas clásicas de limpieza e integración de datos —entre ellas la imputación de valores faltantes, la corrección de errores y el emparejamiento de entidades— como tareas de *prompting* sobre modelos fundacionales, y encontraron que estos alcanzan un desempeño competitivo con el estado del arte a pesar de no haber sido entrenados específicamente para dichas tareas. Este resultado respalda empíricamente la decisión de delegar la normalización de descripciones a un modelo de lenguaje en lugar de a un motor de reglas, que es el enfoque adoptado en el módulo correspondiente de GAMMA.

4.6. Detección de duplicados y resolución de entidades

4.6.1. El problema de la detección de duplicados

La existencia de múltiples representaciones de una misma entidad dentro de una base de datos es un problema clásico y ampliamente estudiado. Elmagarmid, Ipeirotis, y Verykios (2007) lo caracterizan como la situación en que registros duplicados carecen de una clave común y presentan además errores de transcripción, información incompleta o ausencia de formatos estándar, lo que impide resolverlos mediante comparación exacta. Los autores sistematizan las familias de métricas de similitud aplicables —basadas en caracteres, en tokens o en modelos probabilísticos— y las técnicas para hacer escalable la comparación, cuyo costo es cuadrático en el número de registros si se realiza de forma exhaustiva. Su caracterización aplica de forma directa al catálogo de materiales estudiado, donde las descripciones libres, las abreviaturas inconsistentes entre gestores y el límite de caracteres del campo producen exactamente el tipo de variación que hace fallar la comparación literal.

4.6.2. Similitud por q-gramas y trigramas

La búsqueda por similitud difusa (*fuzzy matching*) resuelve este problema descomponiendo cada cadena de texto en subsecuencias de caracteres consecutivos, denominadas *q-gramas*, y comparando el grado de superposición entre los conjuntos de q-gramas de dos cadenas. Cuando la longitud de la subsecuencia es tres, se les denomina *trigramas* (PostgreSQL Global Development Group, 2023). Este enfoque es tolerante a variaciones menores de escritura, a la inversión del orden de las palabras y al uso de separadores distintos, y no requiere que las cadenas comparadas compartan una estructura gramatical común.

Gravano y cols. (2001) demostraron que este tipo de emparejamiento aproximado puede expresarse mediante operaciones relacionales convencionales y ejecutarse dentro del propio motor de base de datos, aprovechando sus índices y su optimizador sin necesidad de infraestructura externa. La extensión `pg_trgm` de PostgreSQL (PostgreSQL Global Development Group, 2023) implementa este

principio de forma nativa, permitiendo indexar el catálogo completo y ejecutar búsquedas de similitud con baja latencia. Esta propiedad es determinante para el diseño de GAMMA, ya que la detección de duplicados debe resolverse de forma interactiva, en el momento en que el gestor propone una descripción.

4.6.3. Umbral de similitud y compromiso entre exhaustividad y precisión

Un motor de similitud difusa no produce una decisión binaria sino un puntaje continuo, por lo que su operación requiere fijar un umbral a partir del cual dos registros se consideran candidatos a duplicado. La elección de ese umbral define un compromiso explícito: un valor bajo maximiza la exhaustividad —detecta más duplicados reales— a costa de generar falsos positivos que el gestor debe descartar manualmente; un valor alto reduce las alertas espurias pero deja pasar duplicados con redacción divergente (Elmagarmid y cols., 2007). Dado que el umbral determina simultáneamente la utilidad operativa de la herramienta y la magnitud del problema que se reporta al medir el catálogo, su valor debe declararse explícitamente junto con cualquier cifra de duplicidad, y su efecto debe caracterizarse mediante un análisis de sensibilidad.

4.7. Representación vectorial de texto

Antes de aplicar un algoritmo de aprendizaje automático sobre texto, este debe convertirse en una representación numérica.

4.7.1. TF-IDF

Una de las técnicas más establecidas es *TF-IDF* (*Term Frequency – Inverse Document Frequency*), propuesta por Salton y Buckley (1988), que pondera cada término según su frecuencia relativa dentro de un documento y su rareza a través de todo el corpus. La intuición es que un término frecuente en un documento pero infrecuente en la colección resulta altamente discriminante, mientras que uno presente en casi todos los documentos aporta poca información para distinguirlos. Esta representación es la que se emplea como entrada de los algoritmos de clasificación evaluados en este proyecto.

4.7.2. N-gramas de carácter

La variante empleada en este trabajo no opera sobre palabras completas sino sobre subcadenas de caracteres. Cavnar y Trenkle (1994) demostraron que la categorización de texto basada en frecuencias de n-gramas de carácter es robusta frente a errores tipográficos y variaciones morfológicas, precisamente porque un error puntual afecta únicamente a los pocos n-gramas que lo contienen y deja intacto el resto de la representación. Esta propiedad es especialmente valiosa en un catálogo de materiales, donde las descripciones contienen abreviaturas no normalizadas, unidades de medida, fracciones y errores de digitación que fragmentarían una representación basada en palabras completas, pero que degradan solo parcialmente una representación basada en caracteres.

4.8. Algoritmos de clasificación supervisada evaluados

La asignación automática de una categoría a partir de la descripción de un material es un problema de clasificación de texto supervisada. Sebastiani (2002) consolidó el enfoque inductivo —construir el clasificador a partir de ejemplos previamente etiquetados— como el paradigma dominante en esta tarea, frente a la definición manual de reglas por expertos de dominio. Dada la diversidad de familias de algoritmos disponibles, se evaluaron seis enfoques distintos sobre el mismo conjunto de datos, descritos a continuación.

4.8.1. Regresión logística

Modelo lineal que estima la probabilidad de pertenencia a una clase mediante una función logística aplicada a una combinación lineal de las variables de entrada. Fue formalizado por Cox (1958) como un método de regresión para variables de respuesta binaria, y se ha extendido posteriormente a problemas multiclase.

4.8.2. Máquinas de vectores de soporte (SVM lineal)

Introducidas por Cortes y Vapnik (1995), buscan el hiperplano que separa las clases maximizando el margen entre los puntos más cercanos de cada una. En su variante lineal (**LinearSVC**), el modelo opera directamente sobre la representación vectorial del texto sin necesidad de una función núcleo (*kernel*), lo que la hace especialmente eficiente en espacios de alta dimensionalidad como los generados por TF-IDF.

4.8.3. Random Forest

Propuesto por Breiman (2001), es un método de ensamble que combina múltiples árboles de decisión entrenados sobre subconjuntos aleatorios de datos y variables, y agrega sus predicciones por votación. Su capacidad de capturar relaciones no lineales lo hace robusto frente a ruido en los datos, a costa de un mayor costo computacional que un modelo lineal.

4.8.4. XGBoost

Chen y Guestrin (2016) presentaron este sistema de *gradient boosting* sobre árboles de decisión, que construye los árboles de forma secuencial, corrigiendo en cada iteración los errores del árbol anterior. Es reconocido por su desempeño competitivo en tareas de clasificación estructurada, aunque su tiempo de entrenamiento crece considerablemente con la dimensionalidad del vocabulario.

4.8.5. fastText

Desarrollado por Joulin, Grave, Bojanowski, y Mikolov (2017), es un clasificador lineal que representa cada documento como el promedio de los vectores de sus palabras (o subpalabras), entrenado de forma conjunta con la tarea de clasificación. Fue diseñado explícitamente para ofrecer un desempeño comparable al de modelos de aprendizaje profundo con tiempos de entrenamiento varios órdenes de magnitud menores.

4.8.6. Transformer (embeddings contextuales)

Los modelos basados en la arquitectura *Transformer* (Vaswani y cols., 2017) generan representaciones vectoriales del texto que capturan el significado de cada palabra en función de su contexto, a diferencia de TF-IDF, que trata cada término de forma independiente. Estas representaciones, pre-entrenadas sobre grandes volúmenes de texto general, suelen requerir un proceso adicional de ajuste fino (*fine-tuning*) para adaptarse a vocabularios técnicos especializados como el de un catálogo industrial. Este requerimiento implica que su desempeño depende de forma crítica del presupuesto de cómputo y de la configuración del entrenamiento, un factor que debe considerarse al interpretar los resultados de una comparación entre familias de algoritmos.

4.9. Evaluación de clasificadores multiclase

La comparación entre algoritmos exige definir con precisión las métricas empleadas, particularmente cuando el problema involucra un número elevado de clases con distribución desigual.

4.9.1. Métricas y esquemas de promediado

Sokolova y Lapalme (2009) realizaron un análisis sistemático de las medidas de desempeño utilizadas en tareas de clasificación binaria, multiclase, multietiqueta y jerárquica, caracterizando qué cambios en la matriz de confusión deja invariante cada medida. Su análisis hace explícito que la elección de la métrica no es neutral: la *exactitud* (*accuracy*) global queda dominada por las clases mayoritarias, mientras que las medidas promediadas ofrecen lecturas distintas del mismo resultado. El promedio *macro* calcula la métrica de forma independiente para cada clase y luego promedia sin ponderar, otorgando el mismo peso a una clase con miles de ejemplos que a una con tres; el promedio *ponderado* (*weighted*) pondera cada clase por su frecuencia, aproximándose al comportamiento de la exactitud global. La brecha entre ambos promedios constituye por sí misma un diagnóstico del desbalance del problema, por lo que en este trabajo se reportan ambos.

4.9.2. Exactitud top-k

En un escenario de asistencia al usuario, donde el sistema propone sugerencias que una persona valida, la métrica relevante no es únicamente si la primera predicción es correcta, sino si la respuesta correcta aparece entre las primeras k opciones presentadas. La exactitud *top-k* mide esta propiedad y resulta más representativa del valor operativo del sistema cuando la interfaz muestra varias alternativas al gestor, ya que refleja la proporción de casos en que la herramienta le evita realizar la búsqueda manual.

4.9.3. Desbalance de clases

He y Garcia (2009) revisaron de forma exhaustiva la problemática del aprendizaje sobre datos desbalanceados, donde la distribución desigual de ejemplos entre clases sesga a los algoritmos hacia las clases mayoritarias y degrada el desempeño sobre las minoritarias, que con frecuencia son las de mayor interés. Los autores sistematizan las estrategias disponibles —remuestreo, aprendizaje sensible al costo y métodos de ensamble— y advierten sobre la insuficiencia de la exactitud global como criterio de evaluación en estos escenarios. Esta consideración es central en el presente proyecto, dado que el catálogo estudiado presenta una distribución fuertemente asimétrica, con un número considerable de clases representadas por muy pocos materiales.

4.9.4. Protocolo de validación

Para obtener una estimación no sesgada del desempeño, el conjunto de datos se particiona en subconjuntos de entrenamiento y prueba, de modo que la evaluación se realice exclusivamente sobre ejemplos no vistos durante el ajuste del modelo. En problemas con clases desbalanceadas se emplea una partición *estratificada*, que preserva la proporción de cada clase en ambos subconjuntos y evita que las clases minoritarias queden ausentes del conjunto de prueba (He y Garcia, 2009). Cuando el modelo seleccionado se reentrena posteriormente sobre la totalidad de los datos para su despliegue, la métrica reportada continúa siendo la obtenida sobre la partición de prueba, y así debe declararse para no atribuir al modelo en producción una estimación medida sobre una configuración distinta.

4.10. Calibración de probabilidades y predicción selectiva

Un sistema de asistencia que sugiere una categoría necesita acompañar cada sugerencia de una medida de confianza interpretable, tanto para decidir cuándo presentarla como para permitir al usuario ponderar cuánto fiarse de ella.

4.10.1. Calibración de probabilidades

Un clasificador está *calibrado* cuando las probabilidades que emite corresponden a frecuencias empíricas reales: de los casos a los que asigna una confianza de 0.80, aproximadamente el 80 % deberían resultar correctos. Las máquinas de vectores de soporte no producen probabilidades de forma nativa, sino distancias al hiperplano separador. Platt (1999) propuso resolver esta limitación ajustando una función sigmoide sobre las salidas del modelo, de manera que las distancias se transformen en estimaciones de probabilidad conservando la propiedad de dispersión del SVM original. Zadrozny y Elkan (2002) extendieron posteriormente el tratamiento a problemas multiclase, mostrando que estos pueden descomponerse en múltiples problemas binarios cuyas estimaciones se combinan. Esta técnica es la que permite emplear un clasificador de margen máximo dentro de un flujo que requiere probabilidades, como es el caso de la arquitectura adoptada en este proyecto.

4.10.2. Clasificación con opción de rechazo

Disponer de probabilidades calibradas habilita una estrategia de *predicción selectiva*: en lugar de emitir siempre una predicción, el sistema puede abstenerse cuando su confianza es insuficiente y derivar el caso al criterio humano. Chow (1970) formalizó este planteamiento derivando la relación óptima entre la tasa de error y la tasa de rechazo para un sistema de reconocimiento bayesiano, y estableciendo que existe un compromiso cuantificable entre ambas: elevar el umbral de confianza reduce el error sobre los casos aceptados a costa de reducir la cobertura del sistema.

Este marco es el que fundamenta la operación de GAMMA como herramienta de asistencia y no de automatización plena. Al caracterizar empíricamente la curva de exactitud frente a cobertura para distintos umbrales de confianza, es posible seleccionar un punto de operación que refleje la tolerancia al error de la organización, y sustentar con datos la decisión de que el gestor conserve el control de la creación final del material.

Dentro de la unidad de negocio donde se desarrolla el proyecto no existía ningún mecanismo automatizado de apoyo a la creación de materiales: la verificación de duplicados y la asignación de categoría se resolvían mediante inspección manual del gestor sobre el catálogo en SAP, apoyándose en las funciones de búsqueda estándar del módulo de materiales. Estas operan por coincidencia de cadenas y no por similitud, de modo que un material registrado con una abreviatura distinta a la que el gestor consulta permanece invisible, y la eficacia de la verificación termina dependiendo del conocimiento acumulado de cada persona sobre las convenciones históricas del catálogo. No se identificó ningún intento previo, dentro de la organización, de abordar este problema mediante analítica o aprendizaje automático.

Sí existe un antecedente de otra naturaleza. La corporación cuenta con un estándar de nomenclatura para las descripciones de materiales basado en la normativa ISO 8000, anterior a este trabajo, bajo el cual está redactada la totalidad del catálogo histórico analizado. La organización, por lo tanto, ya había intentado gobernar la calidad de su catálogo, pero lo hizo por vía normativa: definiendo una regla y esperando que cada gestor la aplicara de forma consistente en el momento de la creación. Los duplicados y las clasificaciones inadecuadas acumulados a lo largo del tiempo evidencian que una norma que no cuenta con un mecanismo que verifique su cumplimiento en el momento de la captura no basta, por sí sola, para sostener la calidad del dato.

El problema cuenta además con una oferta comercial madura. El propio fabricante del ERP ofrece *SAP Master Data Governance*, un módulo licenciado que incorpora creación de datos maestros basada en flujos de trabajo y detección de duplicados mediante algoritmos de emparejamiento configurables (SAP SE, s.f.); existe asimismo un mercado de proveedores especializados en catálogos de mantenimiento, reparación y operación (Verdantis, s.f.), con casos documentados de proyectos que han procesado más de un millón de registros (Ernst & Young, s.f.). La unidad de negocio no cuenta con ninguno de estos módulos ni servicios contratados. Estas alternativas se descartaron por dos razones. La primera es de modelo de costo: operan bajo esquemas de licenciamiento por usuario o de suscripción a servicio, que implican un desembolso recurrente indefinido, mientras que lo que se buscaba era una solución de pago único cuyo costo se concentrara en el desarrollo y no comprometiera el presupuesto operativo de los años siguientes. La segunda es de ajuste: se trata de plataformas de gobierno integral, concebidas para intervenir el ciclo completo del dato maestro y para operar sobre taxonomías genéricas, cuando lo que se requería era una herramienta a la medida, acotada al punto específico del flujo donde se origina el problema y entrenada sobre el histórico y la clasificación internos de la propia corporación.

En cuanto a los antecedentes técnicos, la clasificación automática de descripciones de producto cuenta con precedentes que se remontan a los primeros sistemas de comercio electrónico entre empresas. Ding y cols. (2002) desarrollaron *GoldenBullet*, un sistema de clasificación automática de datos de producto contra la taxonomía UNSPSC —la misma con la que el catálogo de la unidad de negocio mantiene correspondencia—, evaluando modelos de espacio vectorial, vecinos más cercanos y Naive Bayes sobre datos reales de catálogo. Su mejor configuración alcanzó una exactitud del 78 % en la primera predicción y del 88 % considerando las diez primeras sugerencias, discriminando entre 421 categorías, cifras que constituyen un punto de referencia sobre el orden de magnitud esperable en esta clase de problema. Resulta particularmente pertinente la advertencia de los autores en el sentido de que una exactitud en ese rango iguala o supera la calidad de la clasificación humana sobre el mismo material, y que perseguir cifras sensiblemente superiores implicaría sobreajustar el modelo a decisiones humanas que a su vez contienen una tasa de error no despreciable. En el estado actual de la disciplina, Cheng y cols. (2024) muestran la vigencia de una arquitectura por etapas, en la que un modelo especializado acota las categorías candidatas y una segunda instancia basada en un modelo de lenguaje resuelve entre ellas.

En el ámbito de la detección de duplicados, Albayrak, Aytakin, y Kalaycı (2022) pusieron en producción un motor para una plataforma de comercio electrónico que combina métricas de similitud textual con un clasificador entrenado sobre pares de productos etiquetados por expertos, demostrando a gran escala que el enfoque híbrido supera en precisión a los métodos no adaptativos. Su trabajo confirma que la comparación por similitud, y no la coincidencia exacta de cadenas, es el camino viable en catálogos con descripciones de texto libre; señala también que la variante más precisa exige disponer de un conjunto etiquetado de pares duplicado y no duplicado, cuya construcción supone un esfuerzo de anotación experta considerable.

En conjunto, estos antecedentes confirman que tanto la detección de duplicados como la clasificación automática de descripciones de producto cuentan con precedentes consolidados de aplicación exitosa en catálogos a escala industrial, y establecen el rango de desempeño que la literatura reporta como equivalente o superior a la clasificación humana para esta clase de tarea. Lo que no se localizó fue un antecedente que integrara ambas capacidades dentro del flujo operativo de creación de materiales de una organización y que midiera su efecto sobre el tiempo de gestión con datos de producción, que es el espacio en el que se inscribe el presente trabajo.

El proyecto se restringe al flujo de creación individual de materiales dentro de SAP, que es el mecanismo mediante el cual un gestor solicita, valida y registra un material nuevo en el catálogo de la unidad de negocio. Dentro de este flujo, GAMMA interviene en tres momentos: normaliza la descripción propuesta por el gestor, verifica su similitud contra el catálogo cargado en la plataforma para alertar sobre posibles duplicados, y sugiere la categoría más probable con base en el histórico de materiales ya clasificados. GAMMA es una herramienta de asistencia y validación: no escribe directamente en SAP ni sustituye el criterio del gestor, quien conserva el control de la decisión final. Las solicitudes ya validadas se entregan mediante exportación a un archivo de hoja de cálculo, que es el insumo con el que el material se registra posteriormente en el sistema.

La plataforma no mantiene integración en línea con el ERP, ni de lectura ni de escritura. Esta separación es deliberada y constituye el mecanismo de supervisión humana sobre el que se diseñó la solución: el gestor exporta periódicamente el maestro de materiales desde SAP hacia la plataforma, y registra en SAP las solicitudes que la plataforma ya validó, de modo que ninguna operación sobre el sistema transaccional ocurre sin la intervención de una persona. Su contrapartida es que la detección de duplicados alcanza a los materiales existentes hasta la fecha de la última carga, por lo que un registro creado en SAP con posterioridad no es considerado en la comparación hasta que el catálogo se actualice.

El modelo de clasificación se entrena y valida sobre el catálogo de una única unidad de negocio, que es el ámbito de esta primera implementación. Su extensión al resto de las unidades de la corporación queda fuera del alcance del proyecto y se plantea como la etapa siguiente, una vez confirmado su desempeño en este entorno; dentro del catálogo empleado, las categorías con muy escasa representación histórica quedan fuera del espacio de predicción del modelo. El modelo se despliega, asimismo, como un artefacto entrenado de forma previa: la incorporación de un proceso automatizado de reentrenamiento que lo realimente con las correcciones registradas por los gestores durante el uso queda fuera del alcance de esta fase y se identifica como la evolución técnica prevista para la herramienta.

Queda fuera del alcance del proyecto el flujo de creación masiva de materiales, que opera mediante un mecanismo distinto al de la creación individual y no fue intervenido. Tampoco forma parte del alcance la corrección automática de los materiales duplicados o mal categorizados que ya existían en el catálogo antes de la implementación: el proyecto cuantifica ese universo mediante la auditoría retroactiva descrita en los objetivos, pero su remediación corresponde a un esfuerzo de limpieza de datos separado, fuera del alcance de este trabajo.

El desarrollo y la validación del proyecto se realizaron con datos y usuarios de una unidad de negocio específica dentro de la organización, con un período de uso activo por parte del equipo de gestores comprendido entre el 18 de junio y el 21 de julio de 2026. Los resultados de tiempo de gestión, calidad del catálogo y satisfacción de usuario que se presentan en este documento corresponden a ese alcance y a ese período.

El proyecto se desarrolla y se limita al alcance de una única unidad de negocio dentro de una organización con presencia en múltiples países de Centroamérica y el Caribe; no se extiende a otras unidades, áreas o sistemas que la organización pudiera operar de forma independiente.

7.1. Enfoque metodológico

El desarrollo del proyecto se estructuró siguiendo el modelo de proceso CRISP-DM (Wirth y Hipp, 2000), cuyas seis fases se mapearon al trabajo realizado de la siguiente manera: la *comprensión del negocio* corresponde al levantamiento del proceso de creación de materiales y a la cuantificación de su problemática; la *comprensión de los datos*, al análisis exploratorio del maestro exportado desde SAP; la *preparación de los datos*, a la construcción del pipeline de integración y del conjunto de modelado; el *modelado*, a la evaluación comparativa de algoritmos de clasificación; la *evaluación*, a la medición del desempeño sobre datos retenidos y sobre la operación real; y el *despliegue*, a la puesta en producción de la plataforma y a su uso por parte del equipo de gestores.

La ejecución no fue lineal. Los hallazgos del análisis exploratorio —en particular la distribución fuertemente asimétrica de materiales entre categorías— obligaron a volver sobre la definición del conjunto de modelado, y los resultados de la primera competencia de algoritmos motivaron una segunda ronda de evaluación con familias adicionales.

7.2. Materiales

7.2.1. Fuentes de información

La fuente primaria del proyecto es el maestro de materiales del módulo MM de SAP correspondiente a la unidad de negocio. Al no existir integración directa con el ERP, la extracción se realizó mediante exportación manual a archivos de hoja de cálculo, organizados en trece archivos según el tipo de material. Cada registro aporta el código de material, su texto breve —la descripción normalizada de hasta cuarenta caracteres—, la denominación estándar que actúa como categoría, y la unidad de medida base.

A esta fuente se sumaron dos catálogos de referencia. El primero es el maestro de clases o

denominaciones de la corporación, con 1,538 entradas, que además del código y el nombre de cada clase aporta el grupo de artículos, el sector, el tipo de material asociado y su correspondencia con el clasificador UNSPSC. El segundo es la tabla del propio clasificador UNSPSC de Naciones Unidas (United Nations Development Programme, 2023), que permite anclar la taxonomía interna a un referente externo estandarizado.

Todas las fuentes son de naturaleza estructurada y de acceso directo dentro de la unidad de negocio. El corte del maestro empleado para el desarrollo y el entrenamiento corresponde a una fecha específica de extracción, lo que implica que el catálogo con el que opera la plataforma es una fotografía y no un reflejo en tiempo real del ERP.

7.2.2. Recursos tecnológicos

La plataforma se construyó sobre PostgreSQL 16 con la extensión `pg_trgm` habilitada, un API desarrollado en Python con FastAPI, un entorno de Jupyter Lab para la experimentación analítica y un frontend de página única servido por Nginx, todo orquestado mediante contenedores con Docker Compose. El modelado se realizó con las bibliotecas estándar del ecosistema científico de Python. La normalización de descripciones se apoya en un modelo de lenguaje de gran escala consumido por interfaz de programación.

Con la única excepción del servicio de modelo de lenguaje, que opera bajo un esquema de pago por uso, la totalidad de la infraestructura se compone de software de código abierto.

7.3. Integración de la información

7.3.1. Arquitectura implementada

El repositorio de datos se implementó siguiendo la arquitectura medallón descrita en el marco teórico, con cuatro esquemas de responsabilidad diferenciada. El esquema **bronze** concentra la trazabilidad del sistema: registros de ingesta, de predicciones, de decisiones sobre duplicados, de interacciones con el modelo de lenguaje y de errores de aplicación. El esquema **silver** contiene los datos operacionales y de referencia ya normalizados: el maestro de materiales, los catálogos de clases, tipos de material, unidades de medida y UNSPSC, además de las conversaciones y las solicitudes de alta. El esquema **gold** expone vistas agregadas para el consumo del tablero de indicadores. Un cuarto esquema alberga la administración de usuarios de la plataforma.

La elección de un motor relacional en lugar de una plataforma distribuida responde al volumen de datos involucrado: un catálogo de decenas de miles de registros no justifica la complejidad operativa de un entorno de procesamiento distribuido, y permite además resolver la detección de duplicados dentro del mismo motor, sin necesidad de un servicio de búsqueda externo.

7.3.2. Proceso de ingesta

La carga de los archivos se implementó como un conjunto de servicios del API que reciben el archivo, lo interpretan y lo depositan en las tablas correspondientes. El proceso aplica un mapeo explícito entre los encabezados originales de la exportación de SAP y los campos del modelo de datos, resuelve los casos en que la exportación repite un mismo nombre de columna, y extrae los códigos de aquellos campos que llegan como valores compuestos de código y descripción separados por un guion.

Durante la carga se resuelven las llaves foráneas contra los catálogos de referencia: cada material se vincula con su clase y su unidad de medida, y cada clase con su tipo de material y su código UNSPSC. Toda ejecución queda registrada con el nombre del archivo, el número de filas procesadas, el estado resultante, el mensaje de error en caso de fallo y el tiempo transcurrido, lo que permite auditar el origen de cualquier registro del maestro.

Sobre la columna de texto breve del maestro se construyó un índice invertido de trigramas, que es el que sostiene el desempeño de las consultas de similitud.

7.4. Preparación de los datos

7.4.1. Preprocesamiento de texto

Para el modelado se definió una función de normalización que convierte el texto a mayúsculas, descompone y elimina los signos diacríticos, sustituye por espacios los separadores propios de la convención de nomenclatura, descarta los caracteres que no son alfanuméricos ni punto o guion, y colapsa los espacios redundantes. Esta transformación conserva las dimensiones, fracciones y designaciones técnicas, que son precisamente los elementos discriminantes en una descripción de material.

Una consideración crítica de diseño es que esta función es la misma en el entrenamiento y en la inferencia. Un modelo entrenado sobre texto preprocesado de una forma y consultado con texto preprocesado de otra degrada su desempeño de manera silenciosa, sin producir ningún error visible.

7.4.2. Criterios de construcción del conjunto de modelado

Sobre el maestro consolidado se aplicaron dos criterios de exclusión. El primero descarta los materiales que no tenían categoría asignada en la fuente, por no poder emplearse ni para entrenar ni para evaluar. El segundo descarta las clases representadas por menos de tres ejemplos, por resultar insuficientes para permitir simultáneamente el entrenamiento y la evaluación de una misma categoría.

El conjunto resultante se particionó en entrenamiento y prueba en proporción aproximada de 80 y 20 por ciento. La partición se estratificó por clase, dado el desbalance observado en el análisis exploratorio.

7.5. Métodos analíticos

7.5.1. Normalización de descripciones mediante modelo de lenguaje

El módulo de normalización se resolvió mediante un modelo de lenguaje de gran escala consumido a través de su interfaz de programación, en lugar de un motor de reglas y diccionarios de abreviatura. Esta decisión se sustenta en la evidencia de que los modelos fundacionales alcanzan desempeño competitivo en tareas de limpieza y estandarización de datos sin entrenamiento específico (Narayan y cols., 2022), y en la consideración práctica de que un diccionario de abreviaturas exigiría mantenimiento manual permanente conforme aparecen materiales de familias nuevas.

El modelo se configuró con una temperatura baja, para privilegiar la consistencia sobre la variedad en la redacción, y con respuesta forzada en formato JSON, de manera que su salida pueda consumirse de forma programática sin análisis sintáctico frágil. La instrucción de sistema codifica

cuatro elementos: las reglas de la convención corporativa de nomenclatura —límite de cuarenta caracteres, estructura de tipo y subtipo seguida de atributos, uso de mayúsculas, ausencia de tildes y abreviaturas estándar—; un conjunto de ejemplos tomados del propio maestro, que operan como demostraciones en contexto (Brown y cols., 2020); el catálogo de tipos de material vigente, inyectado dinámicamente desde la base de datos; y un protocolo de comportamiento ante información incompleta.

Este último elemento merece detalle. El modelo tiene instruido no inventar especificaciones ausentes: cuando la descripción que recibe es insuficiente, en lugar de completar con valores plausibles debe devolver una lista estructurada de los campos que faltan. Se definieron además reglas de dominio explícitas, como la obligatoriedad del material de fabricación para materiales físicos y la restricción de solicitar marca y modelo únicamente cuando se trata de repuestos o componentes en los que la marca es indispensable para la identificación. El diseño busca que el modelo falle por omisión y no por invención, que es el modo de falla aceptable en un proceso de gobierno de datos.

Cada interacción con el modelo se registra íntegramente: la instrucción enviada, la respuesta cruda, la respuesta interpretada, la acción resultante, el consumo de unidades de texto y el tiempo transcurrido.

7.5.2. Detección de duplicados

La detección de duplicados se implementó como una consulta de similitud difusa ejecutada directamente sobre el maestro normalizado, aprovechando la extensión `pg_trgm` de PostgreSQL y el índice invertido de trigramas construido durante la ingesta (Gravano y cols., 2001). La consulta calcula el coeficiente de similitud entre la descripción propuesta y cada descripción del catálogo, retiene aquellas que superan un umbral configurable y devuelve las diez coincidencias de mayor puntaje ordenadas de forma descendente.

El umbral de alerta se estableció en un valor deliberadamente permisivo, bajo el criterio de que en una herramienta de asistencia el costo de un falso positivo —que el gestor descarte una sugerencia irrelevante— es sustancialmente menor que el de un falso negativo, que se materializa en un duplicado creado y en el costo recurrente de arrastrarlo en el catálogo.

Cuando la consulta arroja coincidencias, estas no se presentan al gestor como una lista cruda: se devuelven al modelo de lenguaje, que las expone en el contexto de la conversación señalando las diferencias relevantes entre el material propuesto y los candidatos encontrados. La decisión del gestor —aceptar uno de los materiales existentes o sostener que el suyo es distinto— se registra de forma explícita, junto con el conjunto de candidatos que se le presentó y el tiempo que tomó decidir.

7.5.3. Diseño de la evaluación de algoritmos de clasificación

La selección del algoritmo se resolvió mediante una competencia entre familias, evaluadas todas sobre la misma partición de datos y con las mismas métricas. En una primera ronda se evaluaron cuatro configuraciones que combinan dos representaciones vectoriales —TF-IDF de palabras y TF-IDF de n-gramas de carácter— con tres algoritmos: regresión logística, máquina de vectores de soporte lineal y bosque aleatorio. En una segunda ronda se incorporaron tres familias adicionales: potenciación de gradiente sobre árboles, un clasificador de subpalabras y un transformador multilingüe preentrenado sometido a ajuste fino.

Se privilegió la representación por n-gramas de carácter sobre la de palabras completas por la densidad de abreviaturas, fracciones y designaciones alfanuméricas del catálogo, y se configuró con ventanas de dos a cinco caracteres delimitadas por palabra, ponderación logarítmica de la frecuencia y un vocabulario acotado a cincuenta mil rasgos.

La máquina de vectores de soporte se envolvió en un procedimiento de calibración con validación cruzada de tres particiones. Esta decisión no fue accesoria: sin estimaciones de probabilidad la plataforma no puede aplicar un umbral de confianza, y sin umbral no puede distinguir las sugerencias que presenta como resueltas de las que somete a revisión explícita del gestor.

La comparación se realizó sobre exactitud global, ambos promedios de F1, exactitud sobre las tres primeras sugerencias y tiempo de entrenamiento; este último se incorporó como criterio porque un modelo que exige horas de cómputo para reentrenarse resulta inviable de mantener en la operación. La configuración ganadora se reentrenó sobre la totalidad del conjunto para su despliegue, por lo que las métricas que se reportan corresponden a la partición retenida y no al artefacto en producción.

El ajuste fino del transformador se realizó sobre las mismas descripciones normalizadas y la misma partición, con un presupuesto de quince épocas y planificación lineal de la tasa de aprendizaje con calentamiento inicial. La longitud de secuencia se derivó de los propios datos en lugar de fijarse por convención, dado que las descripciones no exceden los cuarenta caracteres.

Para determinar el punto de operación del sistema se caracterizó adicionalmente el compromiso entre exactitud y cobertura a distintos umbrales de confianza, siguiendo el planteamiento de clasificación con opción de rechazo (Chow, 1970).

7.6. Arquitectura tecnológica e implementación

7.6.1. Componentes y despliegue

La plataforma se despliega mediante contenedores orquestados con Docker Compose, en cuatro servicios: el motor de base de datos con la extensión de similitud habilitada; el API, que concentra la lógica de negocio, la autenticación y la inferencia del modelo de clasificación; el entorno de experimentación analítica; y el frontend, que además actúa como proxy inverso hacia los demás servicios.

Una decisión de arquitectura relevante fue integrar la inferencia del modelo dentro del propio API en lugar de exponerla como un servicio independiente. El artefacto entrenado se carga en memoria una sola vez al arrancar el proceso y se reutiliza en cada predicción, lo que elimina la latencia de red entre servicios y la complejidad operativa de un componente adicional, a cambio de acoplar el ciclo de vida del modelo al del API.

7.6.2. Ciclo de vida de una solicitud

Una solicitud de alta atraviesa una secuencia definida de estados. Se crea en estado pendiente en el momento en que el modelo de lenguaje produce una propuesta de descripción normalizada. A partir de ahí puede resolverse de tres maneras: confirmarse, cuando el gestor valida la descripción y la categoría; descartarse, cuando la solicitud no procede; o cerrarse como coincidencia con un material existente, cuando la revisión de duplicados determina que el material ya está en el catálogo. Las solicitudes confirmadas transitan finalmente al estado exportado una vez incluidas en el archivo de entrega.

Este último estado materializa el punto de contacto con SAP. Las solicitudes validadas se consolidan en un archivo de hoja de cálculo que incorpora la descripción normalizada, la descripción extendida, el tipo de material, la clase asignada y las marcas de tiempo del proceso; ese archivo es el insumo con el que el material se registra en el ERP. La plataforma no escribe en SAP en ningún momento.

7.7. Instrumentación y medición

La medición del efecto de la herramienta no se resolvió de forma retrospectiva sino instrumentando el sistema desde su diseño, de modo que cada solicitud deje registro de su propio recorrido.

Cada solicitud almacena marcas de tiempo diferenciadas para su creación, la finalización de la normalización, la finalización de la búsqueda de duplicados, la decisión del gestor sobre los duplicados presentados, la finalización de la predicción de categoría, y su confirmación, descarte o exportación. Junto a ellas se registran las duraciones de cada etapa automática y su suma. Esta granularidad permite separar dos magnitudes que de otro modo quedarían confundidas: el tiempo que consume la máquina y el tiempo que consume la deliberación del gestor.

Esta instrumentación temporal no estuvo disponible desde el primer día del piloto: la versión inicial de la plataforma registraba el resultado de cada solicitud —la categoría sugerida, la decisión del gestor y las coincidencias encontradas— pero no la duración de sus etapas, que se incorporó en una versión posterior ya iniciado el período de validación. La consecuencia se traslada a los resultados: los indicadores de calidad y volumen cubren la totalidad de las solicitudes atendidas, mientras que los de tiempo se calculan únicamente sobre las posteriores a esa incorporación.

Se registra asimismo la calidad de la sugerencia. Cuando la clase que el gestor selecciona difiere de la que el modelo propuso, la solicitud queda marcada como corregida, lo que permite estimar la exactitud del modelo en operación real sobre datos que no formaron parte de su evaluación. Se registra también si la sugerencia superó el umbral de confianza y la confianza efectivamente obtenida.

Sobre esta base se construyó la capa de indicadores del esquema *gold*, materializada como vistas que agregan por semana los tiempos de procesamiento, la calidad de las predicciones, las decisiones sobre duplicados, el desglose por etapa del proceso, la actividad por usuario y el ahorro estimado. El cálculo del ahorro se parametriza mediante una tabla de configuración que almacena el tiempo de referencia del proceso manual y el costo por hora del gestor, de modo que el indicador pueda recalcularse ante un cambio de supuestos sin modificar la definición de la vista.

Todas las vistas de indicadores excluyen sistemáticamente la actividad de las cuentas administrativas. Esta exclusión es deliberada: el tráfico generado durante el desarrollo, las pruebas y las demostraciones contaminaría las mediciones de tiempo y de calidad si se agregara junto al uso productivo del equipo de gestores.

7.8. Protocolo de validación en producción

La validación de la herramienta se realizó mediante su uso efectivo por parte del equipo de gestores sobre solicitudes de la operación, durante el período comprendido entre el 18 de junio y el 21 de julio de 2026. La medición del efecto se construye por comparación contra una línea base del proceso manual levantada con anterioridad a la implementación, entre el 15 de febrero y el 17 de junio de 2026.

7.8.1. Medición de la línea base

Los indicadores de la línea base —3.3 horas promedio de tiempo efectivo por gestión y 4.0 solicitudes procesadas por día hábil se extrajeron directamente del tablero de indicadores que la organización ya operaba sobre el proceso de creación de materiales, con marcas de tiempo capturadas por el propio flujo de trabajo entre el 15 de febrero y el 17 de junio de 2026. La cifra de 5 a 10 minutos de búsqueda manual en SAP, en cambio, no proviene de ese tablero: es una estimación

cualitativa declarada por el equipo de gestores sobre la porción específica del proceso que GAMMA automatiza, y se reporta como tal.

7.8.2. Plan de adopción cultural

La validación de GAMMA no se limitó a medir su desempeño técnico: se diseñó un plan de adopción dirigido a las dos audiencias cuya aceptación determina si la herramienta se sostiene más allá del período de prueba. El Cuadro 1 resume el objetivo y la acción concreta dirigida a cada una.

Cuadro 1: Plan de adopción cultural ejecutado durante el período de validación

Audiencia	Objetivo	Acción ejecutada
Gestores de datos maestros	Adopción operativa diaria de la herramienta	Capacitación en vivo el 18 de junio de 2026, con la plataforma funcionando sobre el catálogo real, más un manual de usuario entregado como referencia permanente
Jefatura y coordinación del área	Visibilidad del impacto y respaldo para la continuidad de uso	Sesión de seguimiento de resultados el 16 de julio de 2026, con las métricas acumuladas hasta esa fecha presentadas al equipo completo

Ambas sesiones ocurrieron durante el mismo período en que se midió el efecto de la herramienta, por lo que el acompañamiento y la medición no fueron procesos separados: la sesión de seguimiento del 16 de julio fue, en sí misma, parte de la instancia de acompañamiento al equipo. El registro de asistencia de ambas sesiones se incluye en anexos.

7.8.3. Encuesta de satisfacción

Al cierre del período de prueba se aplicó una encuesta de satisfacción a los usuarios y a la jefatura del área, obteniendo 5 respuestas: 3 de gestores que utilizaron GAMMA activamente y 2 de jefatura y coordinación del área, quienes evaluaron la herramienta sin haberla operado directamente. Dado el tamaño reducido de la muestra, sus resultados se interpretan como retroalimentación cualitativa dirigida y no como una medición estadísticamente representativa del equipo. El instrumento completo se incluye en anexos.

8.1. Caracterización del maestro de materiales

La consolidación de los trece archivos de exportación produjo un total de 45,397 registros. La Figura 1 muestra la composición del maestro según el archivo de origen: la distribución es marcadamente desigual, con dos tipos de material —repuestos industriales y suministros— que concentran por sí solos más del sesenta por ciento de los registros, mientras que varios tipos aportan menos de cien materiales cada uno.




Figura 1: Cantidad de materiales aportados por cada archivo de exportación del maestro

Del total de registros cargados, 40,029 contaban con una clase asignada en la fuente y 5,368 carecían de ella. Entre los materiales clasificados se identificaron 1,529 clases distintas, con una mediana de nueve materiales por clase y una clase máxima que concentra 655 registros. El Cuadro 2 detalla la distribución y la Figura 2 presenta las veinte clases de mayor volumen.

Cuadro 2: Distribución de las clases del maestro según su cantidad de materiales

Materiales por clase	Clases	Participación
1 material	132	8.6 %
2 a 10 materiales	697	45.6 %
11 a 50 materiales	517	33.8 %
51 a 100 materiales	103	6.7 %
Más de 100	80	5.2 %
Total	1,529	100.0 %

Más de la mitad de las clases cuenta con diez materiales o menos, y 132 están representadas por un único registro.




Figura 2: Veinte clases con mayor cantidad de materiales en el maestro

En cuanto a la estructura del texto, las descripciones tienen una longitud media de 32.3 caracteres sobre un máximo posible de cuarenta, con una mediana de 34. La Figura 3 muestra que la distribución de longitudes se acumula abruptamente contra el límite de cuarenta caracteres. Cada descripción contiene en promedio 4.9 tokens y 2.3 separadores.




Figura 3: Distribución de la longitud, cantidad de tokens y número de separadores de las descripciones del maestro

8.2. Calidad de la información

Se midieron cuatro dimensiones sobre cada tipo de material: el porcentaje de duplicados exactos en el texto breve, el porcentaje de materiales marcados como bloqueados en el sistema, el porcentaje de descripciones que no siguen la convención de separadores (dos puntos o punto y coma) y el porcentaje de registros sin clase asignada. La Figura 4 muestra la composición del catálogo por tipo: dos tipos, ZRPI y ZSUM, concentran por sí solos casi dos tercios de los 43,177 registros.




Figura 4: Distribución de registros por tipo de material, catálogo completo (corte 29 mayo 2026)

El análisis de duplicados exactos identificó 2,089 registros duplicados en el catálogo completo, equivalentes al 4.8 % del total. La Figura 5 muestra que este problema no se distribuye de forma pareja: ZEQU presenta la mayor tasa relativa, con 35.2 % de sus registros duplicados, mientras que ZRPI concentra el mayor volumen absoluto, con 973 casos.




Figura 5: Duplicados exactos por tipo de material, en número absoluto y como porcentaje del total

El mapa de calidad de la Figura 6 resume las cuatro dimensiones evaluadas en conjunto. ZRPA presenta el mayor porcentaje de materiales bloqueados (46.0 %), y ZHER concentra el mayor porcentaje de descripciones sin separador estándar (31.8 %). Este último hallazgo es el que más pesa en el diseño de GAMMA: una descripción sin separador es indistinguible de otra similar mediante una búsqueda exacta en SAP, por lo que los 3,649 registros del catálogo completo que carecen de esta estructura (8.5 %) representan el riesgo de duplicidad no detectada más alto de todo el conjunto.

Finalmente, la Figura 7 muestra que las descripciones se concentran contra el límite de cuarenta caracteres que impone SAP, con un promedio de 32.2 caracteres por tipo, lo que confirma la restricción estructural descrita en el Capítulo 4 como causa directa de las abreviaturas inconsistentes




Figura 6: Mapa de calidad del catálogo: duplicados, materiales bloqueados, descripciones sin separador estándar y registros sin clase, por tipo de material

entre gestores.




Figura 7: Longitud promedio del texto breve por tipo de material

Un segundo corte, que incorpora el tipo ZCON, elevó el total analizado a 44,869 registros en doce tipos y confirmó el mismo patrón: ZEQU se mantiene como el tipo con mayor tasa de duplicados (35.2%) y ZCON se ubica en un rango intermedio (4.8%), consistente con el resto del catálogo. Este análisis preliminar sobre el catálogo completo es el que motivó extender la extracción a los trece archivos y 45,397 registros descritos en el Capítulo 9, y sustentó la decisión de resolver la detección de duplicados mediante similitud difusa y no mediante coincidencia exacta de cadenas.

9.1. Conjunto de modelado resultante

La aplicación de los criterios de exclusión definidos en la metodología produjo el conjunto que resume el Cuadro 3. El descarte de los materiales sin categoría en la fuente eliminó 5,368 registros, y el de las clases con menos de tres ejemplos, 458 adicionales, para un conjunto final de 39,571 materiales distribuidos en 1,234 clases.

Cuadro 3: Construcción del conjunto de modelado a partir del maestro exportado

Etapas	Materiales	Clases	Criterio aplicado
Maestro exportado	45,397	—	Trece archivos por tipo de material
Con clase asignada	40,029	1,529	Se descartan 5,368 sin categoría en la fuente
Conjunto de modelado	39,571	1,234	Se descartan clases con menos de tres ejemplos
Entrenamiento	31,656	1,234	Partición estratificada, 80 %
Prueba	7,915	1,234	Partición estratificada, 20 %

9.2. Desempeño comparado de los algoritmos

El Cuadro 4 presenta los resultados de las siete configuraciones evaluadas sobre la partición de prueba, y la Figura 8 contrasta gráficamente las métricas de la primera ronda.

La configuración de máquina de vectores de soporte lineal sobre TF-IDF de carácter obtuvo el mejor resultado en las cuatro métricas de desempeño, con una exactitud de 0.8491 y una exactitud sobre las tres primeras sugerencias de 0.9404, y fue la seleccionada para el despliegue.

Cuadro 4: Resultados de la competencia de algoritmos sobre la partición de prueba de 7,915 materiales y 1,234 clases

Configuración	Exactitud	F1 macro	F1 pond.	Top-3	Tiempo (s)
LinearSVC + TF-IDF carácter	0.8491	0.7523	0.8380	0.9404	62.9
Random Forest + TF-IDF palabra	0.8334	0.7360	0.8254	0.9263	46.7
Reg. logística + TF-IDF carácter	0.8293	0.6713	0.8126	0.9359	1,071.2
Reg. logística + TF-IDF palabra	0.8291	0.6949	0.8178	0.9275	29.1
XGBoost + TF-IDF carácter	0.8145	0.6821	0.8063	0.9200	11,025.2
fastText	0.8077	0.6897	0.8001	0.9075	43.0
Transformer (MiniLM)	0.7479	0.4010	0.7012	0.8710	3,147.4




Figura 8: Comparación de métricas entre las configuraciones evaluadas en la primera ronda

9.3. Desempeño del modelo seleccionado

La Figura 9 presenta la matriz de confusión del modelo seleccionado sobre las veinte clases de mayor volumen. La diagonal concentra la mayor parte de los casos; las clases con vocabulario propio y estable —tornillo, camisa, codo de tubería, manguera— se resuelven casi sin error, mientras que las categorías de naturaleza genérica, como *repuesto* o *herramienta*, presentan las tasas de acierto más bajas del conjunto.

El modelo cometió 1,194 errores sobre los 7,915 materiales de prueba, equivalentes al 15.09 %. El Cuadro 5 recoge las diez confusiones más frecuentes.

9.4. Exactitud y cobertura según el umbral de confianza

El Cuadro 6 y la Figura 10 presentan el comportamiento del modelo al aplicar distintos umbrales de confianza sobre la partición de prueba.

El panel izquierdo de la Figura 10 muestra que las predicciones correctas se concentran en la región de confianza alta mientras que las incorrectas se distribuyen hacia valores bajos. Al umbral




Figura 9: Matriz de confusión del modelo seleccionado sobre las veinte clases de mayor volumen

Cuadro 5: Confusiones más frecuentes del modelo seleccionado sobre la partición de prueba

Clase real	Clase predicha	Casos
CONTACTOR:ELECT.	CONTACTO:ELECT.	7
TUBO:NO METALICO	TUBO	6
FUENTE:ALIMENTACIÓN	FUENTE ALIMENTACION	6
CARGADOR DE BATERIAS	CARGADOR:BATERIAS	6
FUSIBLE	FUSIBLE	5
INTERRUPTOR	INTERRUPTOR:AUTOMATICO	5
REPUESTO	INTERRUPTOR:AUTOMATICO	4
FUENTE ALIMENTACION	FUENTE:ALIMENTACIÓN	4
TRANSFORMADOR	TRANSFORMADOR:CORRIENTE	4
BUJE:ELECTRICO	TORNILLO	4

adoptado por la plataforma, el modelo alcanza una exactitud de 0.9862 sobre el 42.25 % de los casos.

Cuadro 6: Exactitud y cobertura del modelo seleccionado según el umbral de confianza aplicado

Umbral	Exactitud	Cobertura	Materiales cubiertos
Sin umbral	0.8491	100.00 %	7,915
0.5	0.9280	78.81 %	6,238
0.6	0.9484	70.50 %	5,580
0.7	0.9674	60.52 %	4,790
0.8	0.9862	42.25 %	3,344




Figura 10: Distribución de la confianza del modelo y compromiso entre exactitud y cobertura según el umbral

9.5. Resultados de la operación en producción

Los resultados de esta sección se apoyan en dos universos de observación distintos, y conviene precisar la diferencia antes de presentarlos. La plataforma asistió 210 solicitudes durante el período de validación, y sobre ese total se calculan los indicadores del tablero. La medición del tiempo de gestión, en cambio, se realiza sobre 98 solicitudes: la instrumentación que registra las marcas de tiempo de cada etapa se incorporó en una versión posterior de la plataforma, ya iniciado el piloto, de modo que las solicitudes atendidas antes de ese cambio quedaron registradas con su resultado pero sin su duración. La diferencia entre ambas cifras no responde por tanto a criterios de exclusión sino al momento en que cada instrumento entró en operación.

9.5.1. Tiempo de gestión

El Cuadro 7 compara el tiempo efectivo de gestión antes y después de la implementación.

Cuadro 7: Tiempo efectivo de gestión antes y después de GAMMA

	Pre-GAMMA	Post-GAMMA
Período	15 feb–17 jun 2026	18 jun–21 jul 2026
n	353	98
Media (horas)	3.34	1.39
Mediana (horas)	2.82	1.28
IC 95 %	(3.08, 3.61)	(1.19, 1.59)
Solicitudes/día hábil	4.0	5.8

La reducción del tiempo promedio de gestión fue de 58.4 % (54.7 % en la mediana). Una prueba U de Mann-Whitney confirma que la diferencia es estadísticamente significativa ($p < 0.0001$), y los intervalos de confianza al 95 % de ambos períodos no se traslapan. El equipo, además, sostuvo un volumen diario mayor en el período post-GAMMA (5.8 frente a 4.0 solicitudes/día hábil), lo que descarta que la reducción de tiempo se explique por una caída en la carga de trabajo atendida.

9.5.2. Duplicados evitados

El módulo de detección de duplicados registra cada decisión del gestor sobre los candidatos que le presenta. Durante el período de validación se registraron 81 decisiones de este tipo. En 17 de ellas el gestor confirmó que el material solicitado ya existía en el catálogo, con lo que la solicitud se cerró contra el código existente y no derivó en una alta nueva; en las 64 restantes descartó los candidatos y la creación siguió su curso.

Esas 17 son la medida directa del efecto preventivo de la herramienta: son altas que se habrían incorporado al maestro como duplicado y no lo hicieron. Equivalen al 21.0 % de los casos en que el sistema encontró candidatos con similitud suficiente para presentarlos, lo que indica que la búsqueda difusa opera en un rango razonable: no señala tantos falsos positivos como para volverse ruido, ni tan pocos como para pasar por alto la duplicidad que el catálogo evidencia en su línea base.

Conviene precisar el alcance de la cifra. Las 17 corresponden a duplicados que el gestor confirmó como tales; no incluyen los que la búsqueda no logró recuperar, que por construcción no quedan registrados. El valor debe leerse entonces como una cota inferior de la duplicidad prevenida y no como una medición de la exhaustividad del módulo.

9.5.3. Desglose del tiempo de proceso

La instrumentación cronometra por separado cada uno de los tres módulos que intervienen en una solicitud. El Cuadro 8 presenta el promedio por paso sobre las solicitudes del período.

Cuadro 8: Desglose del tiempo de máquina por paso del proceso

Paso	Segundos	% del total
Normalización de la descripción (modelo de lenguaje)	4.37	70.5
Búsqueda de duplicados (similitud de trigramas)	1.78	28.7
Clasificación de categoría	0.09	1.5
Total de máquina	6.20	100.0

Dos lecturas se desprenden del desglose. La primera es la distribución interna: la normalización mediante modelo de lenguaje concentra siete de cada diez segundos de cómputo, mientras que el clasificador —el componente que constituye el núcleo analítico del trabajo— consume el 1.5 % del tiempo. Ese dato confirma en producción lo que la comparación de algoritmos había establecido en laboratorio: el costo de inferencia de la configuración seleccionada es despreciable frente al resto del flujo, de modo que la elección de un modelo lineal no impone ninguna penalización perceptible al usuario. Una arquitectura de mayor capacidad habría desplazado ese costo sin ofrecer, según la evaluación del capítulo anterior, un desempeño superior.

La segunda lectura concierne a la interpretación de la reducción de tiempo reportada. Los 6.20 segundos de cómputo representan el 0.12 % de las 1.39 horas que dura en promedio una gestión asistida. La mejora observada no proviene, por lo tanto, de que la máquina ejecute rápido tareas que antes eran lentas: proviene de que el gestor recibe la descripción normalizada, los candidatos a

duplicado y la categoría sugerida ya resueltos en el momento de decidir, en lugar de construir esa información mediante consultas manuales sucesivas sobre SAP. Lo que la herramienta reduce es el trabajo de búsqueda y verificación que precedía a la decisión, no el tiempo de la decisión misma.

El tiempo de deliberación del gestor sobre cada paso no se reporta aquí. La instrumentación lo obtiene como diferencia entre marcas de tiempo, procedimiento que sobreestima la duración en las sesiones que el gestor deja abiertas y retoma más tarde: en algunas semanas el promedio resultante supera las veinte horas por decisión, valor que corresponde a la interrupción de la sesión y no al esfuerzo dedicado. Aislar el tiempo efectivo de deliberación exigiría una regla de expiración de sesión que la instrumentación actual no implementa, y se plantea como mejora del sistema de medición.

9.5.4. Percepción de los usuarios

La encuesta de satisfacción aplicada al cierre del período de prueba recoge la valoración de gestores y jefatura sobre la herramienta (Figura 11).




Figura 11: Percepción promedio de los gestores sobre GAMMA en la encuesta de satisfacción (n=3)

Entre los gestores que usaron la herramienta activamente, la facilidad de uso en el primer contacto obtuvo la calificación más alta (5.0/5), seguida de la satisfacción general y la utilidad de la sugerencia de descripción (4.33/5 ambas). La reducción de tiempo percibida promedió 4.0/5, en la misma dirección que la reducción medida en el tablero de indicadores. La precisión percibida de la clasificación de categoría obtuvo la calificación más baja del grupo (3.67/5), aunque por encima del punto medio de la escala coherente con que el modelo de clasificación evaluado alcanza una exactitud del 84.9 % en su primera sugerencia, es decir, en aproximadamente uno de cada seis casos la sugerencia inicial no es la correcta. Jefatura y coordinación, por su parte, calificaron la alineación de GAMMA con los objetivos de calidad del área en 4.5/5 en promedio.

9.5.5. Impacto financiero

El Cuadro 9 resume el retorno de inversión del proyecto, calculado sobre el costo real de despliegue —incluyendo el hospedaje del servidor durante el período de construcción, pruebas y puesta en producción, y las horas de capacitación de los gestores frente al ahorro anual proyectado a partir de la reducción de tiempo medida.

Cuadro 9: Retorno de inversión del proyecto

	Basado en promedio	Basado en mediana
Ahorro anual	Q507,310	Q400,491
Costo total del proyecto	Q1,641.65	Q1,641.65
ROI año 1	308x	243x
Período de recuperación	1.2 días	1.5 días

9.6. Visualización de resultados

Un reporte de visualización convierte cada pregunta operativa en una medida con una fuente identificable en el modelo de datos: `user_id`, `type_description`, `week`. Eso permite comparar un periodo contra otro con la misma definición de métrica, y separar lo que hace el agente (tiempo de máquina, cobertura de tipos) de lo que decide el gestor (acuerdo modelo-gestor, tasa de descarte). Sin esa separación, cualquier conversación sobre el desempeño del piloto termina mezclando el trabajo de la herramienta con el criterio de quien la usa.

9.6.1. Por qué Power BI

Se eligió Power BI por dos razones concretas.

La primera es que conecta de forma directa a las tablas del modelo (`materials_by_type`, `requests_users`, `kpi_duplicates`, `kpi_step_breakdown`) sin una capa intermedia, y permite programar la actualización de los datos según la cadencia del pipeline en la capa Gold. Esto importa porque el modelo de datos de GAMMA todavía cambia semana a semana mientras se homologan las fechas de las tablas de duplicados y de desglose de tiempo con el resto del modelo. Un archivo `.pbix` con el modelo semántico documentado se puede ajustar cuando una tabla nueva se integra, sin reconstruir el reporte desde cero.

La segunda es que la empresa ya tiene licencia Premium completa. No hay costo adicional de herramienta, no hay que capacitar a jefatura en una herramienta nueva, y los workspaces, permisos y flujos de publicación que ya usan para otros reportes aplican directamente a este.

Por eso el archivo `.pbix` con el modelo semántico y los tableros descritos en este documento es uno de los entregables del proyecto, junto con esta guía de interpretación. El archivo queda editable, lo que permite ampliar el reporte conforme el modelo de datos madure, sin depender de que el equipo original lo reconstruya.

9.6.2. Tablero operativo

El tablero operativo responde a dos slicers, categoría de materialz "gestor", salvo donde se indique lo contrario.

Tarjetas KPI

Seis tarjetas resumen el periodo del piloto de un vistazo.

- **Códigos por gestor** (80.0): conteo de códigos de material procesados por gestor.

- **Solicitudes asistidas** (210): total de solicitudes asistidas en el periodo (OP-01).
- **Confianza del modelo** (0.61): certeza interna del modelo de clasificación. No es una medida de exactitud — refleja qué tan seguro está el modelo, no si acierta.
- **Cobertura de tipos** (82.4 %): proporción de tipos de material del M402 que el agente ha procesado al menos una vez (EJ-08). No dice qué tan bien se procesan esos tipos, solo si ya fueron tocados.
- **Acuerdo modelo-gestor** (89.0 %): con qué frecuencia el gestor conserva la sugerencia del modelo en lugar de corregirla (OP-11). Un valor alto significa que el gestor rara vez la anula, no que la sugerencia sea correcta.
- **Complejidad de clase** (76.7 %): proporción de registros procesados que terminan con una clase asignada.

Confianza del modelo y acuerdo modelo-gestor responden preguntas distintas y no deben leerse como confirmación mutua. En este periodo divergen: 89.0 % de acuerdo frente a solo 0.61 de confianza del modelo. Esa brecha se debe revisar en la auditoría mensual de exactitud, no tratarse como una contradicción — significa que el modelo duda de sí mismo más de lo que los gestores lo corrigen.

Tiempo de máquina por tipo

Gráfico de barras horizontales, una barra por `type_description`, valores en segundos. Mide el tiempo que tardan los tres módulos del agente (normalización, búsqueda de duplicados, clasificación) en procesar una solicitud, promediado por tipo. Excluye el tiempo de revisión del gestor.

Los tipos con un catálogo original más sucio (Z EQU, Z QUI) tienden a tardar más porque el módulo de duplicados encuentra más candidatos que comparar. Un pico aislado en un solo tipo apunta a un problema de calidad de datos en ese tipo, no a una degradación general del agente.

Desempeño por gestor

Tabla matricial, una fila por `user_id`, columnas: solicitudes asistidas, tiempo de máquina, acuerdo modelo-gestor, completitud de clase.

<code>user_id</code>	Solicitudes	Tiempo máquina (s)	Acuerdo	Complejidad
2	195	6.3	88.2 %	82.6 %
5	15	4.4	100.0 %	—
Total	210	6.2	89.0 %	76.7 %

Esta es la vista de jefatura de equipo: compara gestores lado a lado en las mismas cuatro dimensiones. Un gestor con volumen alto y acuerdo bajo puede estar corrigiendo activamente al modelo, lo cual es bueno, o trabajando con prisa y sin revisar, lo cual no lo es — esa distinción se debe confirmar con el gestor, no asumir a partir de la tabla. Una completitud de clase baja en un gestor específico también puede reflejar que maneja tipos de material con clases poco definidas en el catálogo, en lugar de un problema de su propio desempeño.

Confirmadas, Descartadas y Exportadas

Gráfico de dona con tres estados: confirmadas (161, 48.79 %), descartadas (160, 48.48 %), exportadas (9, 2.73 %).

Estos estados siguen el ciclo de vida de una solicitud dentro del chatbot: se confirma, se descarta (el gestor decide no continuar) o se exporta (llega al archivo XLSX para carga en SAP). Los estados no son mutuamente excluyentes en el tiempo — una misma solicitud puede pasar por más de uno en su recorrido. Una proporción alta de descartadas frente a exportadas puede indicar que el agente presenta sugerencias que no convencen al gestor, o que hay fricción en el flujo conversacional.

10.1. Selección del algoritmo

El resultado más relevante de la competencia es que la configuración más simple resultó también la mejor, y por un margen consistente en las cuatro métricas de desempeño. La máquina de vectores de soporte lineal sobre una representación de caracteres superó tanto a los métodos de ensamble como a las arquitecturas basadas en aprendizaje profundo.

La diferencia en costo computacional refuerza esa conclusión. XGBoost consumió más de tres horas de entrenamiento para quedar tres puntos porcentuales por debajo del ganador, que se entrenó en poco más de un minuto; la regresión logística sobre n-gramas de carácter tardó diecisiete veces más que el ganador para un resultado también inferior; y el transformador multilingüe requirió cincuenta veces el tiempo del ganador —sobre una unidad de procesamiento gráfico, mientras que el ganador se entrena sobre procesador convencional— para quedar diez puntos porcentuales por debajo. En un sistema concebido para reentrenarse periódicamente conforme el catálogo crece, esa diferencia deja de ser un detalle de laboratorio: un modelo que exige horas de cómputo para actualizarse es un modelo que en la práctica no se actualiza.

Este hallazgo es consistente con la naturaleza del problema. Las descripciones del maestro son textos cortos, altamente estructurados y con vocabulario técnico acotado; no contienen la ambigüedad sintáctica ni las dependencias de largo alcance que justifican modelos de mayor capacidad. Un clasificador lineal sobre una representación de caracteres captura precisamente el tipo de regularidad que este texto exhibe.

10.2. Efecto del desbalance de clases

Todas las configuraciones evaluadas muestran una brecha sistemática entre el F1 macro y el ponderado, de entre nueve y quince puntos en las configuraciones clásicas y de treinta puntos en el transformador. Esa brecha es la expresión cuantitativa del desbalance descrito en los resultados: los modelos aciertan considerablemente mejor sobre las clases pobladas que sobre las minoritarias, y

dado que más de la mitad de las clases cuenta con diez materiales o menos, el promedio no ponderado penaliza con fuerza ese comportamiento.

Resulta significativo que el ordenamiento entre configuraciones no sea idéntico bajo ambas métricas. La regresión logística sobre n-gramas de carácter alcanza la tercera mejor exactitud pero el peor F1 macro del conjunto, lo que indica que su desempeño se concentra desproporcionadamente en las categorías frecuentes. El modelo seleccionado, en cambio, lidera ambas métricas, lo que sugiere un comportamiento más uniforme a lo largo de la taxonomía y no solo un buen resultado agregado.

10.3. Desempeño del transformador

El transformador multilingüe es el caso que con mayor claridad delimita el alcance de la conclusión anterior. Es el único de los siete candidatos que modela el texto de forma contextual en lugar de tratarlo como un conjunto no ordenado de rasgos, y por lo tanto el único que podría, en principio, capturar regularidades que la representación vectorial descarta por construcción.

El modelo converge de forma sostenida a lo largo de las quince épocas y alcanza una exactitud del 74.79 %, de modo que aprende efectivamente la tarea. La comparación adquiere entonces sentido: queda diez puntos porcentuales de exactitud y treinta y cinco puntos de F1 macro por debajo de la configuración lineal, empleando cincuenta veces su tiempo de entrenamiento y sobre hardware especializado, mientras que la configuración ganadora se entrena sobre procesador convencional.

La distancia en F1 macro es la más elocuente, porque señala dónde se produce la pérdida: el modelo resuelve razonablemente las categorías de mayor volumen y se desploma en la cola larga de la taxonomía. Esa asimetría es consistente con la exigencia de datos por clase que la literatura documenta para esta familia (Vaswani y cols., 2017), y constituye la evidencia más directa de la tesis central del capítulo: con una mediana de nueve materiales por categoría, la capacidad adicional del modelo no encuentra información con la cual estimarse.

Corresponde acotar el alcance de esta afirmación. El resultado se obtuvo bajo un presupuesto fijo de quince épocas con decaimiento lineal de la tasa de aprendizaje, de modo que no constituye el techo de desempeño de la arquitectura y un presupuesto mayor probablemente lo mejoraría en algunos puntos. Lo que resulta implausible es que un presupuesto mayor cierre una brecha de treinta y cinco puntos en F1 macro, porque esa brecha no se origina en el tiempo de entrenamiento sino en la cantidad de ejemplos disponibles por categoría, que es una propiedad fija del conjunto de datos.

10.4. Naturaleza de los errores del modelo

El examen de las confusiones más frecuentes arroja el hallazgo de mayor alcance del análisis, y trasciende el desempeño del modelo. La mayoría de esos casos no son errores de clasificación en sentido estricto, sino manifestaciones de un problema del propio catálogo: existen pares de clases que designan el mismo concepto y difieren únicamente en puntuación, acentuación o separador.

Los pares *FUENTE:ALIMENTACIÓN* y *FUENTE ALIMENTACION*, o *CARGADOR DE BATERIAS* y *CARGADOR:BATERIAS*, son clases distintas en la taxonomía pero indistinguibles en su significado. El caso más elocuente es el de *FUSIBLE* confundido consigo mismo, que solo puede corresponder a dos códigos de clase homónimos coexistiendo en el catálogo. Ninguna representación del texto puede discriminar entre categorías que son semánticamente idénticas: una fracción del error medido es irreducible mientras la taxonomía no se depure.

Esto tiene dos implicaciones. La primera es metodológica: la exactitud del 84.91 % subestima el desempeño real del modelo, ya que una parte de sus errores consiste en asignar una etiqueta correcta

que la taxonomía duplica bajo otro código. La segunda es operativa: el análisis de errores del modelo constituye, por sí mismo, un instrumento de diagnóstico de la calidad del catálogo, capaz de señalar los pares de clases candidatos a fusión. La herramienta construida para clasificar materiales resultó también un mecanismo para detectar defectos en la taxonomía que los clasifica.

Las categorías genéricas constituyen el segundo foco de error. Clases como *repuesto o herramienta* no designan un objeto sino una función, y por lo tanto carecen de vocabulario distintivo: un repuesto puede ser cualquier cosa. Su baja tasa de acierto no refleja una deficiencia del modelo sino una debilidad de diseño de la taxonomía, que admite categorías sin contenido descriptivo.

10.5. Punto de operación seleccionado

La caracterización del compromiso entre exactitud y cobertura permite fundamentar con datos una decisión que de otro modo sería arbitraria. Al umbral adoptado, el sistema acierta en el 98.62 % de los casos que resuelve de forma automática, a cambio de derivar a revisión del gestor algo más de la mitad de las solicitudes.

Se privilegió deliberadamente la exactitud sobre la cobertura, y la justificación es de costos asimétricos: en un proceso de gobierno de datos, una categoría incorrecta que ingresa al catálogo sin revisión genera un costo persistente —distorciona reportes de consumo, complica la planificación de compras y se propaga a todo proceso que consulte el catálogo—, mientras que una sugerencia derivada a revisión solo consume la atención del gestor, que es exactamente el escenario que la herramienta está diseñada para atender. Conviene subrayar que incluso las solicitudes derivadas a revisión conservan valor: el gestor recibe tres candidatos ordenados por probabilidad en lugar de enfrentar el catálogo completo.

La forma de la distribución de confianza respalda la validez del procedimiento. Que las predicciones correctas se concentren en la región de confianza alta y las incorrectas se dispersen hacia valores bajos es la condición que hace útil cualquier umbral; si la confianza no discriminara entre aciertos y errores, la predicción selectiva carecería de sentido.

10.6. Comparación con los antecedentes

El desempeño obtenido admite una lectura comparativa frente al antecedente más cercano identificado en la literatura. Ding y cols. (2002), clasificando descripciones de producto contra la taxonomía UNSPSC, reportaron una exactitud del 78 % en la primera predicción y del 88 % sobre las diez primeras sugerencias, discriminando entre 421 categorías.

El modelo desarrollado en este proyecto alcanza 84.91 % y 94.04 % respectivamente, sobre 1,234 categorías y con una ventana de sugerencias considerablemente más estrecha, ya que su segunda cifra se mide sobre tres opciones y no sobre diez. Debe insistirse en que ambos resultados provienen de conjuntos de datos distintos y no constituyen una comparación controlada; su valor es el de situar el desempeño obtenido dentro del orden de magnitud que la literatura reporta para esta clase de problema.

En ese marco resulta especialmente pertinente la advertencia de esos mismos autores: una exactitud en el rango del 78 al 88 por ciento iguala o supera la calidad de la clasificación humana sobre el mismo material, y perseguir cifras sensiblemente superiores implicaría sobreajustar el modelo a decisiones humanas que a su vez contienen una tasa de error no despreciable. La observación aplica de manera directa a este proyecto, cuyo conjunto de entrenamiento son precisamente las clasificaciones históricas realizadas por los gestores, con los defectos de taxonomía que el análisis de errores

puso de manifiesto.

10.7. Percepción de los usuarios

La encuesta de satisfacción confirma, en la voz de quienes usaron la herramienta, la misma dirección que muestran los datos del tablero: facilidad de uso alta, reducción de tiempo percibida y satisfacción general por encima del punto medio de la escala.

Un matiz relevante es la brecha entre la precisión percibida de la clasificación (3.67/5, la calificación más baja entre las dimensiones evaluadas) y la exactitud medida del modelo (84.91 % en la primera sugerencia). Esta brecha no es necesariamente una contradicción: es consistente con el hallazgo discutido en la sección de naturaleza de los errores del modelo, donde las categorías genéricas —*repuesto*, *herramienta*— concentran desproporcionadamente los aciertos fallidos. Un usuario que interactúa repetidamente con esas categorías percibirá una tasa de error mayor que el promedio global del modelo, sin que eso implique que la cifra agregada esté mal medida; ambas lecturas son válidas y describen fenómenos distintos.

En cuanto a jefatura y coordinación, la calificación de viabilidad de adopción continua (3.5/5, más baja que la alineación con objetivos de calidad, 4.5/5) es reveladora: la brecha no está en si GAMMA funciona, sino en si la organización cuenta hoy con la estructura para sostenerla sin el equipo de graduación detrás. Ambas personas señalaron como condición necesaria que un equipo técnico interno adopte formalmente el mantenimiento de la herramienta un punto que se retoma en las recomendaciones de este trabajo.

10.8. Retorno de inversión

El ROI de 308x sobre el promedio (243x sobre la mediana) es una cifra que exige contexto antes de interpretarse como una medida general de viabilidad de este tipo de herramientas. Su magnitud es, en gran parte, un artefacto del denominador: el costo total del proyecto (Q1,641.65) refleja únicamente el gasto marginal de un proyecto de graduación —hospedaje del servidor y horas de capacitación—, sin incorporar el costo de desarrollo. De haberse contratado con un proveedor externo, ese desarrollo habría representado una inversión significativa, ausente en este cálculo por tratarse de trabajo académico no facturado. Un ROI calculado sobre ese costo real de desarrollo sería considerablemente menor, y esa es la lectura relevante para cualquier decisión de replicar el proyecto por la vía comercial en lugar de académica.

Existe además un riesgo de extrapolación. El ahorro anual se proyecta a partir de una reducción de tiempo medida sobre cinco semanas de uso, aplicada sobre un volumen de referencia de 2,963 solicitudes anuales correspondiente a 2025, no al año en curso. Cada uno de esos supuestos introduce incertidumbre que el cálculo puntual no refleja.

Estas salvedades no invalidan la cifra, la contextualizan: la reducción de tiempo en la que se basa el ahorro es estadísticamente significativa (Mann-Whitney, $p < 0.0001$), lo que respalda que el efecto medido es real y no ruido de muestra pequeña. Esto considerando que el equipo sostuvo una tasa diaria de solicitudes más alta en el período post-GAMMA (5.8 frente a 4.0 por día hábil pre-GAMMA).

10.9. Limitaciones del estudio

Los resultados presentados deben interpretarse dentro de varias limitaciones.

La primera concierne a la evaluación del modelo. La convención de nomenclatura del catálogo hace que el término principal de la descripción coincida con frecuencia con el nombre de la clase a la que el material pertenece, de modo que una parte del desempeño observado es atribuible a esa correspondencia léxica directa. Cuantificar qué proporción del acierto depende de ella requeriría una evaluación por ablación, eliminando el término inicial de la descripción y midiendo la caída resultante. Ese ejercicio no se realizó y queda planteado como verificación pendiente.

La segunda es que el modelo se entrena sobre etiquetas producidas por los propios gestores, que constituyen la mejor referencia disponible pero no una verdad de campo independiente. El techo de desempeño alcanzable está determinado por la consistencia de esas decisiones históricas.

La tercera se refiere al alcance de la validación. El período de uso productivo abarca cinco semanas y una sola unidad de negocio, frente a una línea base levantada durante cuatro meses. La asimetría entre ambos períodos y el tamaño de la muestra acumulada aconsejan tratar las cifras de la operación como indicativas de una tendencia y no como estimaciones de precisión estadística. A ello se suma que las solicitudes atendidas se concentran fuertemente en un gestor, que procesó 195 de las 210 del período. Esa concentración no expresa una adopción parcial de la herramienta sino el tamaño real del equipo, pero implica que los indicadores de operación reflejan de manera predominante el criterio de una sola persona y no un promedio entre gestores.

Finalmente, los resultados de clasificación se obtuvieron sobre una fotografía del catálogo correspondiente a una fecha determinada. El desempeño del modelo sobre materiales de familias que no estaban representadas en esa extracción no puede inferirse de las mediciones presentadas.

1. Se consolidó el maestro de materiales en un repositorio único, normalizado y trazable. El pipeline de integración construido sobre PostgreSQL con arquitectura medallón unificó los 45,397 registros dispersos en trece archivos de exportación de SAP, resolviendo durante la carga las llaves foráneas contra los catálogos de clases, tipos de material, unidades de medida y UNS-PSC. La separación en esquemas de responsabilidad diferenciada permitió que la trazabilidad no fuera un añadido posterior sino una propiedad estructural: toda ejecución de ingesta queda registrada con su archivo de origen, el número de filas procesadas, el estado resultante y el tiempo transcurrido, de modo que cualquier registro del maestro puede auditarse hasta su fuente. El repositorio resultante es el insumo común de los tres módulos analíticos y sustituyó la consulta dispersa sobre hojas de cálculo que caracterizaba la operación previa.
2. El análisis del catálogo confirmó defectos de calidad de magnitud relevante y aportó un hallazgo no anticipado sobre la taxonomía. La caracterización del maestro reveló que 5,368 registros carecían por completo de categoría asignada en la fuente, y que la distribución de materiales entre clases es fuertemente asimétrica: más de la mitad de ellas cuenta con diez materiales o menos. El análisis de calidad por tipo de material identificó además 2,089 duplicados exactos y 3,649 descripciones que no siguen la convención de separadores del catálogo. Este último dato resultó determinante para el diseño de la solución: sin esa estructura, una descripción es indistinguible de otra similar mediante una búsqueda exacta en SAP, lo que sustentó resolver la detección de duplicados por similitud difusa y no por coincidencia de cadenas. El hallazgo de mayor alcance, sin embargo, no estaba previsto en el planteamiento: el examen de las confusiones del clasificador mostró que una fracción de sus errores no corresponde a fallas del modelo sino a pares de clases que designan el mismo concepto y difieren únicamente en puntuación o separador. La herramienta construida para clasificar materiales resultó también un instrumento de diagnóstico de la taxonomía que los clasifica, capaz de señalar los pares de clases candidatos a fusión.
3. La configuración más simple de las siete evaluadas resultó también la más exacta, y por un margen consistente. La máquina de vectores de soporte lineal sobre TF-IDF de n-gramas de carácter obtuvo la mejor marca en las cuatro métricas de desempeño (exactitud de 0.8491, F1 macro de 0.7523, F1 ponderado de 0.8380 y exactitud sobre las tres primeras sugerencias de 0.9404) superando a la regresión logística, al bosque aleatorio, a la potenciación de gradiente, al clasificador de subpalabras y al transformador multilingüe preentrenado. La configuración ganadora se entrena en 62.9 segundos sobre procesador convencional, frente a las más de tres horas de la potenciación de gradiente y a los 3,147 segundos del transformador, ambos con

resultados inferiores. El modelo seleccionado no solo acierta más sino que se comporta de forma más uniforme a lo largo de una taxonomía en la que más de la mitad de las clases cuenta con diez materiales o menos.

4. GAMMA integra los tres módulos analíticos en el flujo de creación y mantiene la decisión final en manos del gestor. La plataforma encadena la normalización de la descripción mediante modelo de lenguaje, la búsqueda de duplicados por similitud de trigramas sobre el maestro consolidado y la sugerencia de categoría del clasificador, y los presenta durante la creación del material y no en un reporte posterior. Como cada sugerencia lleva una probabilidad asociada, la plataforma resuelve por sí sola los casos en que esa probabilidad supera el umbral configurado —el 42 % del volumen, con una exactitud del 98.6 %— y deriva el resto a revisión. Ninguna sugerencia llega a SAP sin la confirmación del gestor: el sistema asiste la decisión, no la sustituye. El comportamiento en operación respaldó ese diseño: sobre las 210 solicitudes asistidas durante el período de validación, el gestor conservó la categoría sugerida en el 89.0 % de los casos. La encuesta de cierre apuntó en la misma dirección; los gestores destacaron la facilidad de uso y la jefatura la alineación con los objetivos de calidad del área, mientras que la precisión de la categoría sugerida fue el aspecto peor valorado.
5. La herramienta redujo a menos de la mitad el tiempo de gestión, con un retorno de la inversión inmediato. El tiempo efectivo del gestor pasó de 3.34 a 1.39 horas por solicitud, una reducción del 58 % que las pruebas estadísticas confirman como significativa y no atribuible al azar ni al menor tamaño del período de validación. La reducción tampoco se explica por una carga de trabajo menor: durante ese mismo período el equipo atendió más solicitudes por día hábil que antes de la implementación. Bajo el escenario conservador, el ahorro proyectado asciende a Q400,491 anuales frente a un costo total del proyecto de Q1,641.65, de modo que la inversión se recupera en cerca de un día y medio de operación.

En cuanto al objetivo general, GAMMA se desarrolló, se desplegó y operó sobre solicitudes reales del proceso de creación individual de materiales, articulando efectivamente el procesamiento de lenguaje natural, la búsqueda por similitud difusa y el aprendizaje automático supervisado sobre el histórico del catálogo. La reducción del tiempo de gestión quedó demostrada con significancia estadística sobre la operación real, y el retorno de la inversión resulta inmediato bajo cualquiera de los escenarios considerados.

El aporte a la calidad del maestro quedó igualmente respaldado, aunque por una vía distinta. El acuerdo del 89.0 % entre la sugerencia del modelo y la decisión final del gestor constituye una validación del clasificador independiente de su evaluación de laboratorio: mide su desempeño contra las decisiones efectivas de quienes conocen el catálogo, y no contra una partición retenida de los mismos datos con que fue entrenado. Que ambas mediciones converjan —84.91 % sobre datos retenidos y 89.0 % sobre la operación— indica que el desempeño estimado en el laboratorio se sostuvo al enfrentar materiales reales.

Resta, no obstante, una distinción que conviene declarar. Que el modelo acierte en operación y que los tres controles intervengan antes de cada alta establece que la herramienta previene la incorporación de nuevos defectos; no establece todavía en qué medida el catálogo mejora como consecuencia. Esa segunda afirmación exige contrastar la evolución de los indicadores de duplicidad y de categorización sobre un horizonte de operación más extenso que las cinco semanas del piloto, y constituye la continuación natural del trabajo.

Para la operación

Depurar la taxonomía de clases antes de ampliar el alcance de la herramienta. El análisis de errores del modelo identificó pares de clases que designan el mismo concepto y difieren únicamente en puntuación, acentuación o separador. Mientras esas duplicidades persistan, una fracción del error de clasificación es irreducible por cualquier modelo, y los reportes de consumo por categoría seguirán fragmentando información que corresponde a un mismo concepto. La depuración no requiere desarrollo adicional: el propio análisis de confusiones señala los candidatos a fusión, y su corrección mejora simultáneamente la calidad del catálogo y el desempeño medido de la herramienta.

Hacer exigible la convención de separadores en el momento de la captura. El análisis de calidad identificó 3,649 descripciones que no siguen la convención de dos puntos o punto y coma, con tipos de material en los que esa proporción supera el treinta por ciento. Una descripción sin esa estructura es indistinguible de otra similar mediante una búsqueda exacta, de modo que cada registro capturado sin separador incorpora al catálogo un riesgo de duplicidad que ninguna consulta posterior detecta con certeza. Validar la estructura en el momento de la captura evita que el pasivo siga creciendo mientras se depura el acumulado, y la plataforma ya realiza esa normalización antes de proponer la descripción al gestor.

Resolver la categorización de los materiales sin clase asignada. Los 5,368 registros que carecen de categoría en la fuente quedaron fuera del conjunto de modelado y, por lo tanto, fuera del alcance del clasificador. Constituyen un volumen suficiente para justificar una campaña de categorización asistida por la propia plataforma, que puede procesarlos por lotes aprovechando la sugerencia de categoría y la revisión del gestor.

Consolidar la operación en esta línea de negocio antes de escalar a otras unidades. El equipo de gestores del área es reducido, de modo que el volumen atendido durante la validación no refleja una adopción parcial sino el tamaño real de la operación. Lo que corresponde entonces no es ampliar el número de usuarios dentro de la misma unidad, sino sostener el uso durante un período más extenso que permita acumular decisiones suficientes para medir la calidad del catálogo con la misma solidez con que ya se midió el tiempo de gestión. Ese resultado es el criterio con el que debería decidirse la extensión de la herramienta a otras líneas de negocio de la corporación: escalar antes de consolidar trasladaría a un ámbito mayor conclusiones que todavía descansan sobre cinco semanas de operación en una sola unidad.

Contrastar el umbral de confianza con el comportamiento real de la operación. El umbral vigente se fijó a partir de la partición de prueba, donde el modelo acierta el 98.6 % de los casos que resuelve por sí solo. Conviene verificar que esa promesa se cumple en la práctica, y la plataforma ya registra lo necesario para hacerlo: cada vez que un gestor modifica la categoría sugerida, la corrección queda almacenada. El contraste consiste en comparar la proporción de correcciones sobre las solicitudes que el sistema resolvió automáticamente contra el margen de error que el umbral admite. Si las correcciones resultan más frecuentes de lo previsto, el umbral es demasiado permisivo y conviene elevarlo, a costa de derivar más solicitudes a revisión del gestor; si resultan menos frecuentes, puede reducirse para automatizar un volumen mayor sin comprometer la calidad. Esta revisión debe repetirse después de cada reentrenamiento, porque un modelo nuevo altera la distribución de confianzas sobre la que el umbral fue ajustado.

Explotar la instrumentación de calidad que el sistema ya captura. Las vistas del esquema gold registran la tasa de corrección, las decisiones sobre duplicados y el desglose por etapa del proceso, información que durante el período de validación no se explotó. Incorporarla al seguimiento habitual del área convierte el tablero en un instrumento de gestión y no solo en un reporte del proyecto.

Para la continuidad técnica

Adoptar una partición agrupada por descripción en el procedimiento de evaluación. La duplicidad del catálogo permite que registros con descripción idéntica queden repartidos entre entrenamiento y prueba, lo que introduce un sesgo optimista en las métricas reportadas. Sustituir la partición aleatoria por una que asigne todos los registros de una misma descripción a una sola de las particiones corrige el sesgo en la fuente y hace que cada reentrenamiento futuro publique métricas comparables entre versiones.

Sustituir la partición única por validación cruzada. Las métricas actuales provienen de una sola partición, de modo que no admiten intervalos de confianza y las diferencias observadas entre configuraciones no pueden declararse estadísticamente distinguibles. Una validación cruzada estratificada permitiría acompañar cada métrica de su dispersión y sostener con evidencia las comparaciones entre algoritmos.

Realizar la evaluación por ablación del término principal. La convención de nomenclatura hace que la primera palabra de la descripción coincida con frecuencia con el nombre de la clase. Medir la caída de desempeño al eliminar ese término cuantificaría qué proporción del acierto depende de la correspondencia léxica directa y cuánto de la capacidad discriminativa del modelo.

Documentar o reproducir el método de la auditoría retroactiva del catálogo. Las cifras de duplicidad y de categorización incorrecta empleadas para dimensionar el problema requieren una metodología declarada —en particular, el umbral de similitud con el que fueron obtenidas— que permita reproducirlas sobre el catálogo completo. Reportarlas al mismo umbral con el que opera la plataforma tendría la ventaja adicional de vincular directamente la línea base con el comportamiento de la herramienta.

Evaluar la incorporación del clasificador al flujo de carga masiva. El trabajo se acotó deliberadamente a la creación individual de materiales. El mismo modelo, aplicado a las cargas masivas que hoy ingresan sin verificación de categoría, extendería el alcance del gobierno de datos sin requerir desarrollo analítico adicional.

- Albayrak, O. S., Aytakin, T., y Kalaycı, T. A. (2022). Duplicate product record detection engine for e-commerce platforms. *Expert Systems with Applications*, 193, 116420. doi: 10.1016/j.eswa.2021.116420
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. doi: 10.1023/A:1010933404324
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... Amodei, D. (2020). Language models are few-shot learners. En *Advances in neural information processing systems* (Vol. 33, pp. 1877–1901).
- Cavnar, W. B., y Trenkle, J. M. (1994). N-gram-based text categorization. En *Proceedings of the 3rd annual symposium on document analysis and information retrieval (SDAIR-94)* (pp. 161–175). Las Vegas, NV.
- Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 785–794). ACM. doi: 10.1145/2939672.2939785
- Cheng, Z., Zhang, W., Chou, C.-C., Jau, Y.-Y., Pathak, A., Gao, P., y Batur, U. (2024). E-commerce product categorization with LLM-based dual-expert classification paradigm. En *Proceedings of the 1st workshop on customizable NLP (CustomNLP4U)* (pp. 294–304). Association for Computational Linguistics. doi: 10.18653/v1/2024.customnlp4u-1.22
- Chow, C. K. (1970). On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, 16(1), 41–46. doi: 10.1109/TIT.1970.1054406
- Cortes, C., y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. doi: 10.1007/BF00994018
- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society: Series B (Methodological)*, 20(2), 215–232. doi: 10.1111/j.2517-6161.1958.tb00292.x
- DAMA International. (2017). *DAMA-DMBOK: Data management body of knowledge* (2nd ed.). Basking Ridge, NJ: Technics Publications.
- Databricks. (s.f.). *What is the medallion lakehouse architecture?* Descargado agosto de 2026, de <https://docs.databricks.com/aws/en/lakehouse/medallion>
- Ding, Y., Korotkiy, M., Omelayenko, B., Kartseva, V., Zykov, V., Klein, M., ... Fensel, D. (2002). GoldenBullet: Automated classification of product data in e-commerce. En W. Abramowicz (Ed.), *Business information systems: Proceedings of BIS 2002*. Poznań, Polonia.
- Elmagarmid, A. K., Ipeirotis, P. G., y Verykios, V. S. (2007). Duplicate record detection: A survey. *IEEE Transactions on Knowledge and Data Engineering*, 19(1), 1–16. doi: 10.1109/TKDE.2007.250581
- Ernst & Young. (s.f.). *Case study: Transforming MRO material master data*. Descargado agosto de 2026, de https://www.ey.com/en_us/insights/energy-resources/oil-gas/transforming-mro-material-master-data-case-study

- Gravano, L., Ipeirotis, P. G., Jagadish, H. V., Koudas, N., Muthukrishnan, S., y Srivastava, D. (2001). Approximate string joins in a database (almost) for free. En *Proceedings of the 27th international conference on very large data bases (VLDB)* (pp. 491–500).
- He, H., y Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. doi: 10.1109/TKDE.2008.239
- International Organization for Standardization. (2010). *Industrial automation systems and integration — Open technical dictionaries and their application to master data — Part 1: Overview and fundamental principles (ISO 22745-1:2010)*. Ginebra, Suiza: ISO. Descargado de <https://www.iso.org/standard/53995.html>
- International Organization for Standardization. (2021). *Data quality — Part 110: Master data: Exchange of characteristic data: Syntax, semantic encoding, and conformance to data specification (ISO 8000-110:2021)*. Ginebra, Suiza: ISO. Descargado de <https://www.iso.org/standard/78501.html>
- Joulin, A., Grave, E., Bojanowski, P., y Mikolov, T. (2017). Bag of tricks for efficient text classification. En *Proceedings of the 15th conference of the European Chapter of the Association for Computational Linguistics* (Vol. 2, pp. 427–431). Association for Computational Linguistics. doi: 10.18653/v1/E17-2068
- Kimball, R., y Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). Indianapolis, IN: John Wiley & Sons.
- Laney, D. B. (2018). *Infonomics: How to monetize, manage, and measure information as an asset for competitive advantage*. Nueva York, NY: Routledge.
- Loshin, D. (2009). *Master data management*. Burlington, MA: Morgan Kaufmann.
- Narayan, A., Chami, I., Orr, L., y Ré, C. (2022). Can foundation models wrangle your data? *Proceedings of the VLDB Endowment*, 16(4), 738–746. doi: 10.14778/3574245.3574258
- Platt, J. C. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. En A. J. Smola, P. Bartlett, B. Schölkopf, y D. Schuurmans (Eds.), *Advances in large margin classifiers* (pp. 61–74). Cambridge, MA: MIT Press.
- PostgreSQL Global Development Group. (2023). *pg_trgm: Support for similarity of text using trigram matching*. PostgreSQL 16 Documentation. Descargado agosto de 2026, de <https://www.postgresql.org/docs/16/pgtrgm.html>
- Redman, T. C. (1998). The impact of poor data quality on the typical enterprise. *Communications of the ACM*, 41(2), 79–82. doi: 10.1145/269012.269025
- Salton, G., y Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5), 513–523. doi: 10.1016/0306-4573(88)90021-0
- SAP SE. (s.f.). *SAP Master Data Governance*. SAP Help Portal. Descargado agosto de 2026, de https://help.sap.com/docs/SAP_MASTER_DATA_GOVERNANCE
- Sebastiani, F. (2002). Machine learning in automated text categorization. *ACM Computing Surveys*, 34(1), 1–47. doi: 10.1145/505282.505283
- Sokolova, M., y Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), 427–437. doi: 10.1016/j.ipm.2009.03.002
- United Nations Development Programme. (2023). *United Nations Standard Products and Services Code (UNSPSC)*. Descargado agosto de 2026, de <https://www.undp.org/unspsc>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. En *Advances in neural information processing systems* (Vol. 30, pp. 5998–6008).
- Verdantis. (s.f.). *Materials master data management*. Descargado agosto de 2026, de <https://www.verdantis.com/materials-master-data-management/>
- Wang, R. Y., y Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4), 5–33. doi: 10.1080/07421222.1996.11518099
- Wirth, R., y Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining* (pp. 29–40). Manchester, Reino Unido.

- Zadrozny, B., y Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. En *Proceedings of the 8th ACM SIGKDD international conference on knowledge discovery and data mining* (pp. 694–699). ACM. doi: 10.1145/775047.775151
- Zaharia, M., Ghodsi, A., Xin, R., y Armbrust, M. (2021). Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics. En *Proceedings of the 11th conference on innovative data systems research (CIDR)*.

Registro de asistencia

La validación de GAMMA incluyó dos sesiones formales con el equipo: una capacitación inicial al arranque del período de uso, y una sesión de seguimiento de resultados. El Cuadro 10 resume la asistencia registrada en ambas, agrupada por rol para preservar la confidencialidad de las personas involucradas.

Cuadro 10: Asistencia registrada por rol en las sesiones de capacitación y seguimiento

Rol	Capacitación inicial (18 jun 2026)	Seguimiento (16 jul 2026)
Equipo UVG - MBIA	3	3
Jefatura	1	1
Coordinación	1	1
Gestores	5	5
Total	10	10

Instrumento y respuestas de la encuesta de satisfacción

La encuesta se aplicó mediante un formulario con lógica de ramificación según el rol y la experiencia de uso del respondiente. Se obtuvieron 5 respuestas: 3 de gestores que utilizaron GAMMA activamente, y 2 de jefatura y coordinación del área.

Respuestas de gestores (n=3)

Cuadro 11: Respuestas de los gestores que utilizaron GAMMA

Pregunta	Gestor 1	Gestor 2	Gestor 3
Facilidad de uso (1-5)	5	5	5
Utilidad de la sugerencia de descripción (1-5)	5	4	4
Precisión de la clasificación sugerida (1-5)	4	3	4
Reducción de tiempo percibida (1-5)	5	3	4
Satisfacción general (1-5)	5	4	4
¿Recomendaría GAMMA? (1-5)	5	4	5

Módulos utilizados: Gestor 1 usó los tres módulos y la exportación a Excel; Gestor 2 usó normalización, duplicados y clasificación; Gestor 3 usó únicamente normalización.

Parte más valiosa: los tres gestores coincidieron en señalar la detección de duplicados; Gestor 1 y Gestor 3 mencionaron además la normalización y la sugerencia de categoría.

Errores encontrados: Gestor 1 reportó un error por límite de tokens del modelo de lenguaje en un caso puntual; Gestor 2 no reportó errores; Gestor 3 calificó la herramienta como “eficaz y completa”.

Comentarios abiertos: los tres gestores sugirieron explorar la extensión de GAMMA a otros contextos organizacionales; Gestor 2 sugirió además una función de consulta masiva.

Respuestas de jefatura y coordinación (n=2)

Cuadro 12: Respuestas de jefatura y coordinación

Pregunta	Jefatura	Coordinación
Alineación con objetivos de calidad (1-5)	4	5
Viabilidad de adopción continua (1-5)	3	4

Condiciones para permanencia: ambas respuestas coincidieron en que un equipo técnico interno debería adoptar formalmente el mantenimiento de la herramienta; también se mencionó la integración con otras herramientas del flujo interno y la extensión a otros contextos organizacionales.

Comentarios adicionales: se destacó el diseño de la interfaz de usuario como un acierto orientado a la experiencia del gestor.

Capturas del instrumento

GAMMA – Retroalimentación de Implementación

Esta encuesta forma parte del proceso de evaluación de **GAMMA (Gobierno Automatizado del Maestro de Materiales)**, herramienta desarrollada por el equipo de graduación Master In Business Intelligence and Analytics de la Universidad del Valle de Guatemala en colaboración con [REDACTED]. Tu retroalimentación es fundamental para documentar el grado de aceptación en el entorno empresarial real.

Tiempo estimado: 5 minutos.

** Indica que la pregunta es obligatoria*

¿Cuál es tu rol en el área de datos maestros? *

☐ Gestor/Analista de datos maestros

☐ Coordinadora de datos maestros

☐ Jefe de datos maestros

Figura 12: Portada del formulario de encuesta

GAMMA – Retroalimentación de Implementación

* Indica que la pregunta es obligatoria

¿Has utilizado GAMMA durante el período de prueba (junio–julio 2026)? *

- ☐ Sí, la he utilizado
- ☐ Aún no la he utilizado, pero planeo hacerlo
- ☐ No la he utilizado

Figura 13: Pregunta de bifurcación según uso de GAMMA

Experiencia de uso

(Solo para quienes han usado GAMMA)

¿Qué tan fácil fue usar GAMMA por primera vez, sin necesitar ayuda? *

☐ 1 – Muy difícil

☐ 2 – Difícil

☐ 3 – Neutral

☐ 4 – Fácil

☐ 5 – Muy fácil

¿Cuáles de estos módulos de GAMMA utilizaste? *


☐ Normalización de descripción (texto breve SAP)

☐ Detección de duplicados (búsqueda en el catálogo)

☐ Clasificación de categoría (sugerencia de clase SAP)

☐ Exportación Excel - XLSX para carga en SAP

Figura 14: Sección de experiencia de uso (parte 1)



¿Qué tan útil fue la sugerencia de descripción corta SAP que generó GAMMA? *

☐ 1 – Nada útil

☐ 2 – Poco útil

☐ 3 – Moderadamente útil

☐ 4 – Útil

☐ 5 – Muy útil

¿Qué tan precisa fue la clasificación de categoría (clase de material) sugerida por GAMMA? *

☐ 1 – Nada precisa, tuve que corregirla siempre


☐ 2 – Poco precisa

☐ 3 – Moderadamente precisa

☐ 4 – Precisa en la mayoría de casos

☐ 5 – Muy precisa, rara vez necesité corregirla

Figura 15: Sección de experiencia de uso (parte 2)



Comparado con el proceso anterior (búsqueda manual en SAP), ¿GAMMA redujo el tiempo que dedicas a procesar una solicitud de creación? *

☐ 1 – No, tomó más tiempo

☐ 2 – Tomó aproximadamente el mismo tiempo

☐ 3 – Redujo un poco el tiempo

☐ 4 – Redujo considerablemente el tiempo

☐ 5 – Redujo significativamente el tiempo

¿Qué parte de GAMMA te resultó más valiosa? *

☐ Que detecta duplicados automáticamente antes de crear


☐ Que normaliza la descripción al formato SAP

☐ Que sugiere la categoría correcta

☐ Que genera el archivo Excel listo para SAP

☐ El historial de solicitudes procesadas

Figura 16: Preguntas sobre reducción de tiempo y valor percibido



The image shows a digital survey form with two questions. The first question asks if the user has found any errors or unexpected behavior in GAMMA. The second question asks for general satisfaction with GAMMA as a daily work tool, with a 5-point Likert scale.

¿Encontraste algún error, comportamiento inesperado o algo que GAMMA no pudo manejar bien? *

Tu respuesta _____

En general, ¿qué tan satisfecha/o estás con GAMMA como herramienta de apoyo a tu trabajo diario? *

☐ 1 – Muy insatisfecha/o

☐ 2 – Insatisfecha/o

☐ 3 – Neutral

☐ 4 – Satisfecha/o

☐ 5 – Muy satisfecha/o

Figura 17: Preguntas de errores encontrados y satisfacción general

Adopción y continuidad

(Solo para quienes han usado GAMMA)

¿Continuarías usando GAMMA en tu trabajo diario? *

☐ Sí, definitivamente

☐ Sí, con algunas mejoras

☐ No estoy segura/o

☐ No

¿Recomendarías GAMMA a otros gestores de datos maestros materiales en [REDACTED] *

☐ 1 – Definitivamente no

☐ 2 – Probablemente no

☐ 3 – No estoy segura/o

☐ 4 – Probablemente sí

☐ 5 – Definitivamente sí

Figura 18: Sección de adopción y continuidad (información sensible cubierta)

¿Qué mejorarías o agregarías a GAMMA?

Tu respuesta

[Atrás](#) [Enviar](#) [Borrar formulario](#)

Figura 19: Pregunta abierta de mejoras

Percepción y expectativas

¿Por qué no has utilizado GAMMA todavía? *

☐ No he tenido solicitudes de creación de Energía durante el período de prueba

☐ No he tenido tiempo de probarlo

☐ No tenía claridad sobre cómo usarlo

☐ Otros: _____

Basándote en lo que conoces de GAMMA, ¿qué tan útil crees que sería para tu trabajo (si estuviese implementado en tu unidad de negocio)? *

☐ 1 – Nada útil

☐ 2 – Poco útil

☐ 3 – Moderadamente útil

☐ 4 – Útil

☐ 5 – Muy útil

Figura 20: Sección de percepción y expectativas para no usuarios

¿Cuál de estos beneficios te parece más relevante para tu trabajo diario? *

☐ Que detecte duplicados automáticamente

☐ Que normalice la descripción al formato SAP

☐ Que sugiera la categoría correcta

☐ Que genere el archivo para armar la carga masiva en SAP

☐ Que guarde el historial de solicitudes

Figura 21: Pregunta de beneficios percibidos por no usuarios

Jefatura y coordinación

¿En qué medida consideras que GAMMA está alineada con los objetivos de calidad del maestro de materiales y ANS del área? *

☐ 1 – Nada alineada

☐ 2 – Poco alineada

☐ 3 – Moderadamente alineada

☐ 4 – Bien alineada

☐ 5 – Completamente alineada

¿Qué tan viable ves la adopción continua de GAMMA en el equipo gestor después del período de pruebas? *

☐ 1 – No es viable


☐ 2 – Poco viable

☐ 3 – Moderadamente viable

☐ 4 – Viable con algunos ajustes

☐ 5 – Completamente viable

Figura 22: Sección dirigida a jefatura y coordinación



¿Qué condiciones serían necesarias para que GAMMA sea una herramienta permanente en el área? *

- ☐ Que el equipo de TI [REDACTED] lo adopte y mantenga
- ☐ Que se integre formalmente con [REDACTED]
- ☐ Que demuestre reducción medible de tiempos con más datos
- ☐ Que cubra todos los mandantes, no solo e [REDACTED]
- ☐ Ya está lista para uso permanente tal como está

¿Tienes algún comentario adicional sobre GAMMA o sobre este proceso de implementación?

Tu respuesta

Figura 23: Condiciones para permanencia y comentarios adicionales (información sensible cubierta)

Descriptor del sistema y accesos para revisión

Este anexo describe la plataforma desplegada y las credenciales dispuestas para que el tribunal examinador pueda acceder a ella y verificar de forma directa los resultados reportados en este trabajo.

Descripción del sistema

GAMMA es una aplicación web de página única que asiste al gestor durante la creación individual de materiales en SAP. Se despliega mediante contenedores orquestados con Docker Compose sobre un servidor privado virtual, en cuatro servicios: el motor de base de datos PostgreSQL con la extensión de similitud por trigramas habilitada; el API desarrollado en FastAPI, que concentra la lógica de negocio, la autenticación y la inferencia del modelo de clasificación; el entorno de experimentación analítica en Jupyter Lab; y el frontend, que además actúa como proxy inverso hacia los demás servicios.

La interacción principal ocurre en una interfaz conversacional. El gestor describe el material en lenguaje natural y el sistema encadena los tres módulos analíticos: normaliza la descripción a la convención de nomenclatura del catálogo mediante un modelo de lenguaje, busca coincidencias en el maestro consolidado por similitud de trigramas, y sugiere las tres categorías más probables acompañadas de su nivel de confianza. Ninguna sugerencia se registra sin confirmación explícita del gestor.

Perfiles de acceso

La plataforma distingue dos perfiles. El Cuadro 13 resume las secciones habilitadas para cada uno.

El perfil de **gestor** corresponde al usuario operativo y reproduce la experiencia del equipo durante el período de validación. El perfil de **administrador** añade la documentación técnica, el detalle de la evaluación del modelo, el historial de versiones y la capacidad de ejecutar un reentrenamiento.

Cuadro 13: Secciones de la plataforma habilitadas según el perfil de acceso

Sección	Gestor	Administrador
Asistente conversacional (flujo de creación)	Sí	Sí
Tablero de indicadores	Sí	Sí
Ayuda y documentación de uso	Sí	Sí
Arquitectura de la solución	—	Sí
Referencia técnica (API y esquema de datos)	—	Sí
Modelo (operación, arquitectura y evaluación)	—	Sí
Entorno de experimentación analítica	—	Sí
Administración de cuentas	—	Sí

Credenciales de revisión

Las cuentas del Cuadro 14 se crearon exclusivamente para la revisión de este trabajo y son independientes de las cuentas de la operación. No permiten consultar información identificable de los usuarios del período de validación.

Cuadro 14: Credenciales dispuestas para el tribunal examinador

Perfil	Usuario	Contraseña
Gestor	revisor.gestor@gamma.gt	[COMPLETAR]
Administrador	revisor.admin@gamma.gt	[COMPLETAR]

Dirección de acceso: [COMPLETAR URL]

Instrucciones de conexión

1. Abrir la dirección de acceso en un navegador de escritorio actualizado. La aplicación no requiere instalación ni complementos.
2. Iniciar sesión con una de las cuentas del Cuadro 14.
3. La sesión permanece activa mediante un testigo de autenticación almacenado en el navegador. Para alternar entre ambos perfiles debe cerrarse la sesión desde el menú de usuario antes de ingresar con la otra cuenta.

Recorrido sugerido

Para verificar los resultados reportados se propone la siguiente secuencia.

Con el perfil de gestor:

1. Ingresar al asistente conversacional y solicitar la creación de un material describiéndolo en lenguaje natural, sin ajustarse a la convención de nomenclatura. Se observará la descripción normalizada propuesta, las coincidencias detectadas en el maestro y las tres categorías sugeridas con su nivel de confianza.

2. Repetir el ejercicio con la descripción de un material que probablemente ya exista en el catálogo, para observar el comportamiento del módulo de detección de duplicados.
3. Consultar el tablero de indicadores, donde se presentan los tiempos de gestión, el volumen procesado y los indicadores de calidad sobre los que se construyeron los resultados de este trabajo.

Con el perfil de administrador:

1. Consultar la sección de Modelo, que reúne el diagrama del flujo de clasificación, la comparación de las siete configuraciones evaluadas, el análisis de umbral de confianza y el historial de versiones del artefacto.
2. Consultar la Referencia técnica, que expone la documentación interactiva del API y el diagrama entidad-relación de los cuatro esquemas de la arquitectura medallón.
3. Consultar la sección de Arquitectura para el detalle de los componentes y su despliegue.

Consideraciones

Las credenciales anteriores tienen vigencia limitada al período de revisión y evaluación de este trabajo, y serán desactivadas una vez concluido. El catálogo con el que opera la instancia corresponde a la extracción del maestro empleada durante el desarrollo, de modo que las consultas reflejan ese corte y no el estado vigente del ERP de la organización. Las solicitudes de creación generadas durante la revisión quedan registradas en la instancia pero no se transfieren a ningún sistema productivo.

Arquitectura medallón Patrón de diseño de *pipelines* de datos que organiza el flujo de información en capas sucesivas de refinamiento (Bronce, Plata y Oro), desde el dato crudo hasta las vistas listas para consumo.

Calibración de probabilidades Procedimiento que ajusta las salidas de un modelo de clasificación para que reflejen probabilidades reales, permitiendo aplicar umbrales de confianza sobre sus predicciones.

Chatbot Interfaz de software que permite interactuar con un sistema mediante una conversación en lenguaje natural, en lugar de formularios o menús tradicionales.

CRISP-DM *Cross Industry Standard Process for Data Mining*: modelo de proceso estándar para proyectos de analítica y minería de datos, estructurado en seis fases iterativas.

Dato maestro Información que describe una entidad central de negocio (como un material, cliente o proveedor) que es referenciada de forma persistente por múltiples procesos y sistemas.

Duplicado difuso Par de registros que refieren al mismo objeto pero cuya descripción textual no es idéntica, por diferencias de abreviatura, orden de palabras o separadores.

ERP *Enterprise Resource Planning*: sistema de información que integra los procesos centrales de una organización (finanzas, inventario, compras, entre otros) en una plataforma única.

Exactitud top- k Métrica que considera una predicción correcta si la clase real se encuentra entre las k categorías de mayor probabilidad sugeridas por el modelo, no solo en la primera.

F1 macro Métrica de desempeño de un clasificador que promedia el F1 de cada clase por igual, sin ponderar por su frecuencia, lo que penaliza el bajo desempeño en clases minoritarias.

Gestor de datos maestros Persona responsable de crear, validar y mantener los registros del catálogo de materiales, asegurando su unicidad, exactitud y correcta categorización.

LLM *Large Language Model* o modelo de lenguaje de gran escala: modelo de aprendizaje automático entrenado sobre grandes volúmenes de texto, capaz de generar y transformar lenguaje natural.

MDM *Master Data Management* o gestión de datos maestros: disciplina encargada de mantener consistentes, correctas y libres de duplicidad las entidades centrales de una organización.

pg_trgm Extensión de PostgreSQL que permite calcular la similitud entre cadenas de texto mediante la comparación de trigramas de caracteres.

Pipeline de datos Secuencia automatizada de procesos que extrae, transforma y carga datos desde una fuente de origen hasta su destino final de consumo.

ROI *Return on Investment* o retorno de inversión: relación entre el beneficio obtenido de un proyecto y el costo invertido en él.

SVM lineal Máquina de vectores de soporte con núcleo lineal: algoritmo de clasificación que busca el hiperplano que separa las clases maximizando el margen entre los puntos más cercanos de cada una.

TF-IDF *Term Frequency – Inverse Document Frequency*: técnica que representa un texto de forma numérica ponderando cada término según su frecuencia relativa y su rareza en el corpus.

Trigrama Subsecuencia de tres caracteres consecutivos extraída de una cadena de texto, utilizada como unidad básica para calcular similitud textual.

Umbral de confianza Valor mínimo de probabilidad que debe alcanzar una predicción del modelo para presentarse como sugerencia automática; por debajo de él, la decisión se deriva a revisión del gestor.

UNSPSC *United Nations Standard Products and Services Code*: taxonomía abierta y multisectorial para la clasificación de productos y servicios, administrada por el Programa de las Naciones Unidas para el Desarrollo.

VPS *Virtual Private Server* o servidor privado virtual: instancia de servidor alojada en la nube, utilizada para el despliegue de la plataforma.